МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ
НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ
«КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ
імені ІГОРЯ СІКОРСЬКОГО»

А.С. Момот,
М.С. Мамута

РОБОТОТЕХНІКА ТА ІНТЕЛЕКТУАЛЬНІ СИСТЕМИ ПРАКТИКУМ

Навчальний посібник

Рекомендовано Методичною радою КПІ ім. Ігоря Сікорського
як навчальний посібник для здобувачів ступеня магістра
за освітньою програмою «Комп'ютерно-інтегровані
системи та технології в приладобудуванні»
спеціальності 174 «Автоматизація, комп'ютерно-інтегровані технології та
робототехніка»

Електронне мережне навчальне видання

Київ
КПІ ім. Ігоря Сікорського
2022

Рецензенти: *Войцехович Валерій Степанович,* канд. фіз.-мат. наук, старший науковий співробітник відділу когерентної і квантової оптики Інституту фізики НАН України

Безугла Наталя Василівна, канд. техн. наук, доцент, доцент кафедри виробництва приладів КПІ ім. Ігоря Сікорського

Відповідальний редактор *Боровицький Володимир Миколайович,* док. техн. наук, доцент, професор кафедри комп'ютерно-інтегрованих оптичних та навігаційних систем КПІ ім. Ігоря Сікорського

Гриф надано Методичною радою КПІ ім. Ігоря Сікорського
(протокол №5 від 26.05.2022 р.)
за поданням Вченої ради приладобудівного факультету
(протокол №4/22 від 26.04.2022 р.)

Практикум містить теоретичний матеріал, приклади та комплекс завдань для комп'ютерного практикуму та самостійної роботи студентів з дисципліни «Робототехніка та інтелектуальні системи». Надано інформацію про аналіз та синтез нейронних мереж, проаналізовано методи оптимізації навчання нейронних мереж та надано рекомендації з їх використання. Висвітлено особливості побудови і використання повнозв'язних, згорткових та рекурентних мереж, а також прийоми навчання глибинних нейронних мереж, зокрема метод перенесення навчання та метод тонких налаштувань. Практикум може бути корисний студентам та фахівцям з інтелектуального аналізу даних.

Реєстр. № НП 21/22-402. Обсяг 6,8 авт. арк.

Національний технічний університет України
«Київський політехнічний інститут імені Ігоря Сікорського»
проспект Перемоги, 37, м. Київ, 03056
https://kpi.ua
Свідоцтво про внесення до Державного реєстру видавців, виготовлювачів
і розповсюджувачів видавничої продукції ДК № 5354 від 25.05.2017 р.

ЗМІСТ

ВСТУП

Навчальний посібник призначено для забезпечення інформаційними та методичними матеріалами дисципліни "Робототехніка та інтелектуальні системи".

Дисципліна "Робототехніка та інтелектуальні системи" викладається на першому курсі магістратури та має обсяг в 36 годин лекцій та 36 годин комп'ютерного практикуму. Увага приділена базовим можливостям глибинного навчання, зокрема побудові та оптимізації нейронних мереж в пакеті Anaconda з використанням мови програмування Phyton.

В посібнику надано загальні відомості про аналіз та синтез нейронних мереж, висвітлено особливості побудови та навчання повнозв’язних, згорткових та рекурентних нейронних мереж, проаналізовано основні методи оптимізації навчання нейронних мереж, розглянуто прийоми глибинного навчання, а саме: перенесення навчання та тонкі налаштування нейронних мереж. Посібник орієнтований як на ознайомлення з базовими можливостями глибинного навчання, так і на вивчення перспективних методів та алгоритмів глибинного навчання та їх практичної реалізації. З метою кращого засвоєння матеріалу практикум містить приклади програмної реалізації нейронних мереж різної архітектури з детальним аналізом їх побудови та оптимізації та завдання для самостійного виконання.

Метою навчального посібника є допомога студентам в самостійному вивченні відповідних розділів навчальної дисципліни та в набутті навичок застосування штучних нейронних мереж під час проектування інтелектуальних приладів та систем. Посібник може використовуватись для самостійної роботи та дистанційного навчання.

ПРАКТИКУМ 1. БІБЛІОТЕКА PANDAS

1.1. Теоретичні відомості

Pandas – це бібліотека, яка надає зручні інструменти для зберігання даних і роботи з ними. Використовується в області аналізу даних та машинного навчання.

Pandas чудово підходить для роботи з одновимірними і двовимірними таблицями даних, надає можливість працювати з файлами CSV, таблицями Excel, SQL та багатьма іншими форматами.

- Повна документація за бібліотекою: *https://pandas.pydata.org/pandas-docs/stable/*

Для початку роботи, бібліотеку необхідно імпортувати:

```
import pandas as pd
```

Зазвичай у парі з Pandas використовується бібліотека NumPy.

```
import numpy as np
```

Структура даних Series

Series – це маркована одновимірна структура даних, яку можна уявити як таблицю з одним рядком. З Series можна працювати як зі звичайним масивом (звертатися за номером індексу), а також як з асоційованим масивом, тобто використовувати ключ для доступу до елементів даних.

Створити структуру Series можна на базі різних типів даних:

– словники;

– списки;

– масиви з numpy: ndarray;

– скалярні величини.

Конструктор класу Series виглядає наступним чином:

– *data* – масив, словник або скалярне значення, на базі якого буде побудована Series;
– *index* – список міток, який буде використовуватися для доступу до елементів Series. Довжина списку повинна дорівнювати довжині *data*;
– *dtype* – об'єкт numpy.dtype, який визначає тип даних;
– *copy* – створює копію масиву даних, якщо параметр дорівнює True, в іншому випадку нічого не робить.

У більшості випадків під час створення Series використовують тільки перші два параметра. Розглянемо різні варіанти, як це можна зробити.

Створення Series зі списку

Найпростіший спосіб створити Series – це передати в якості єдиного параметра в конструктор класу список.

```
s1 = pd.Series([1, 2, 3, 4, 5])
print(s1)

>>

0    1
1    2
2    3
3    4
4    5
```

Для доступу до елементів Series, в даному випадку, можна використовувати тільки позитивні цілі числа - лівий стовпець чисел, який починається з нуля. Це і є індекси елементів структури, які показані в правому стовпці.

```
s1[1]

>>

2
```

Тепер передамо в якості другого параметру список рядків (в нашому випадку – окремі символи). Це дозволить нам звертатися до елементів структури Series не тільки за числовим індексом, а й за міткою, що зробить роботу з таким об'єктом схожою на роботу зі словником.

```
s2 = pd.Series([1, 2, 3, 4, 5], ['a', 'b', 'c', 'd', 'e'])
print(s2)

>>

a    1
b    2
c    3
d    4
e    5
```

Зверніть увагу на лівий стовпець, в ньому містяться мітки, які ми передали в якості параметра *index* під час створення структури. Правий стовпець – це, як і раніше, елементи структури.

```
s2['b']

>>

2
```

Створення Series з масиву ndarray

Створимо масив з п'яти чисел, аналогічний списку з попереднього розділу.

```
ndarr = np.array([1, 2, 3, 4, 5])
type(ndarr)

>>

numpy.ndarray
```

Тепер створимо Series з символьними знаками.

```
s3 = pd.Series(ndarr, ['a', 'b', 'c', 'd', 'e'])
print(s3)

>>
```

```
a    1
b    2
c    3
d    4
e    5
```

Створення Series зі словника

Ще один спосіб створити структуру Series - це використовувати словник для одночасного задання міток і значень.

```
d = {'a':1, 'b':2, 'c':3}
s4 = pd.Series(d)
print(s4)

>>

a    1
b    2
c    3
```

Ключі зі словника *d* стануть мітками структури *s4*, а значення словника - значеннями в структурі.

Створення Series з використанням константи

Розглянемо ще один спосіб створення структури. Цього разу значення в комірках структури будуть однаковими.

```
a = 7
s5 = pd.Series(a, ['a', 'b', 'c'])
print(s5)

>>

a    7
b    7
c    7
```

У створеній структурі Series є три елементи з однаковим значенням.

Робота з елементами Series

До елементів Series можна звертатися за чисельним індексом. У разі такого підходу робота зі структурою не відрізняється від роботи зі списками.

```
s6 = pd.Series([1, 2, 3, 4, 5], ['a', 'b', 'c', 'd', 'e'])
s6[2]

>>

3
```

Можна використовувати мітку, тоді робота з Series буде схожою на роботу зі словником.

```
s6['d']

>>

4
```

Можна отримувати зрізи.

```
s6[:2]

>>

a    1
b    2
```

В поле для індексу можна помістити умовний вираз. Це дозволить вивести лише ті елементи, які задовольняють вказаній умові.

```
s6[s6 <= 3]

>>

a    1
b    2
c    3
```

З структурами Series можна працювати так само, як з векторами: додавати, множити вектор на число тощо.

```
s7 = pd.Series([10, 20, 30, 40, 50], ['a', 'b', 'c', 'd', 'e'])
s6 + s7

>>
```

```
a    11
b    22
c    33
d    44
e    55
```

```
s6 * 3

>>

a     3
b     6
c     9
d    12
e    15
```

Структура даних DataFrame

Якщо Series являє собою одновимірну структуру, яку можна уявити як таблицю з одним рядком, то **DataFrame** – це вже двовимірна структура, повноцінна таблиця з великою кількістю рядків і стовпців.

Конструктор класу DataFrame виглядає так:

– *data* - масив ndarray, словник або інший DataFrame;

– *index* - список міток для записів (назви рядків таблиці);

– *columns* - список міток для полів (назви стовпців таблиці);

– *dtype* - об'єкт *numpy.dtype*, який визначає тип даних;

– *copy* - створює копію масиву даних, якщо параметр дорівнює True, в іншому випадку нічого не робить.

Структуру DataFrame можна створити на базі:

– словника, в якості елементів якого повинні виступати: одновимірні ndarray, списки, інші словники, структури Series;

– структури Series;

– двовимірних ndarray;

– структурованих ndarray;

– інших DataFrame.

Створення DataFrame зі словника

В даному випадку буде використовуватися одновимірний словник, елементами якого будуть списки, структури Series тощо.

Для початку розглянемо Series.

```
d = {"price": pd.Series([1, 2, 3], index=['v1', 'v2', 'v3']),
     "count": pd.Series([10, 12, 7], index=['v1', 'v2', 'v3'])}
df1 = pd.DataFrame(d)
print(df1)

>>

    price  count
v1      1     10
v2      2     12
v3      3      7
```

Тепер побудуємо аналогічний словник, але на елементах ndarray.

```
d2 = {"price": np.array([1, 2, 3]),
      "count": np.array([10, 12, 7])}
df2 = pd.DataFrame(d2, index=['v1', 'v2', 'v3'])
print(df2)

>>

    price  count
v1      1     10
v2      2     12
v3      3      7
```

Як видно - результат аналогічний попередньому. Замість ndarray також можна використовувати звичайний список.

```
d3 = {"price": [1, 2, 3],
      "count": [10, 12, 7]}
df3 = pd.DataFrame(d3, index=['v1', 'v2', 'v3'])
print(df3)

>>
```

```
    price  count
v1      1     10
v2      2     12
v3      3      7
```

Створення DataFrame зі списку словників

До цього моменту ми створювали DataFrame зі словника, елементами якого були структури Series, списки і масиви. Тепер ми створимо DataFrame зі списку, елементами якого є словники.

```
d4 = [{"price": 3, "count":8}, {"price": 4, "count": 11}]
df4 = pd.DataFrame(d4, index=['v1', 'v2'])
print(df4)

>>

    price  count
v1      3      8
v2      4     11
```

Створення DataFrame з двовимірного масиву

Створити DataFrame можна також і з двовимірного масиву. В наступному прикладі це буде ndarray з бібліотеки NumPy.

```
nda1 = np.array([[1, 2, 3], [10, 20, 30]])
df4 = pd.DataFrame(nda1)
print(df4)

>>

    0   1   2
0   1   2   3
1  10  20  30
```

Робота з елементами DataFrame

Основні способи роботи з DataFrame:

- *df['col']* - вибір стовпця; повертає Series
- *df.loc['label']* - вибір рядка за міткою; повертає Series
- *df.iloc[loc]* - вибір рядка за індексом; повертає Series

- *df[0:4]* - зріз за рядками; повертає DataFrame
- *df[bool_vec]* - вибір рядків, які відповідають умові; повертає DataFrame

Створимо DataFrame для розгляду цих операцій.

```
d = {"price": np.array([1, 2, 3]),
     "count": np.array([10, 20, 30]),
     "weight": np.array([2.3, 5.7, 8.9])}
df = pd.DataFrame(d, index=['a', 'b', 'c'])
print(df)

>>

   price  count  weight
a      1     10     2.3
b      2     20     5.7
c      3     30     8.9
```

Вибір стовпця:

```
df['count']

>>

a    10
b    20
c    30
```

Вибір рядка за міткою:

```
df.loc['a']

>>

price      1.0
count     10.0
weight     2.3
```

Вибір рядка за індексом:

```
df.iloc[1]

>>

price      2.0
count     20.0
weight     5.7
```

Зріз за рядками:

```
df[0:2]

>>

   price  count  weight
a      1     10     2.3
b      2     20     5.7
```

Зріз за індексами стовпців:

```
df.iloc[:, 0:2]

>>

   price  count
a      1     10
b      2     20
c      3     30
```

Зріз за іменами стовпців:

```
df.loc[:, 'price':'count']

>>

   price  count
a      1     10
b      2     20
c      3     30
```

Вибір рядків, які відповідають умові:

```
df[df['count'] >= 20]

>>

   price  count  weight
b      2     20     5.7
c      3     30     8.9
```

1.2. Операції з даними в Pandas

Доступ до даних DataFrame з використанням міток

Розглянемо різні варіанти використання міток, які можуть бути як іменами стовпців таблиці, так і іменами рядків. Для початку створимо новий DataFrame.

```
d = {"price":[1, 2, 3], "count": [10, 20, 30], "percent": [24, 51, 7
1]}
df = pd.DataFrame(d, index=['a', 'b', 'c'])
df

>>

   price  count  percent
a      1     10       24
b      2     20       51
c      3     30       71
```

Звернення до конкретного стовпця - отримання всіх елементів стовпця *'count'*:

```
df['count']

>>

a    10
b    20
c    30
```

Звернення з використанням масиву стовпців - отримання елементів стовпців *'count'* і *'price'*:

```
df[['count','price']]

>>

   count  price
a     10      1
b     20      2
c     30      3
```

Звернення за зрізами міток - отримання елементів з мітками від *'a'* до *'b'*:

```
df['a':'b']

>>

   price  count  percent
a      1     10       24
b      2     20       51
```

Звернення з використанням функції - отримання всіх елементів, у яких значення в стовпці *'count'* більше 15:

```
df[lambda x: x['count'] > 15]

>>

   price  count  percent
b      2     20       51
c      3     30       71
```

Звернення через логічний вираз. Під час формування логічного виразу необхідно вказувати імена стовпців, за якими буде здійснюватися вибірка (так як і при роботі з функціями).

Отримати всі елементи, у яких *'price'* більше або дорівнює 2:

```
df[df['price'] >= 2]

>>

   price  count  percent
b      2     20       51
c      3     30       71
```

Використання атрибутів для доступу до даних

Для доступу до даних можна використовувати атрибути структур, в якості яких виступають мітки.

Створимо нову структуру Series:

```
s = pd.Series([10, 20, 30, 40, 50], ['a', 'b', 'c', 'd', 'e'])
```

Для доступу до елементу через атрибут необхідно вказати його через крапку після імені змінної.

Оскільки структура `s` має мітки *'a', 'b', 'c', 'd', 'e'*, то для доступу до елементу з міткою *'a'* ми можемо використовувати синтаксис `s.a`.

```
s.a

>>

10
```

```
s.c

>>

30
```

Такий самий підхід можна застосувати для змінної типу DataFrame.

Отримаємо доступ до стовпця *'price'*:

```
d = {"price":[1, 2, 3], "count": [10, 20, 30], "percent": [24, 51, 71]}
df = pd.DataFrame(d, index=['a', 'b', 'c'])

df.price

>>

a    1
b    2
c    3
```

Отримання випадкової вибірки зі структур Pandas

Бібліотека *pandas* надає можливість отримати випадковий набір даних з уже існуючої структури. Такий функціонал має як Series, так і DataFrame. У даних структур є метод *sample()*, який повертає випадкову підвибірку.

Повернемось до структури Series. Для того, щоб вибрати випадковим чином елемент з Series використовується наступний синтаксис:

```
s.sample()

>>

a    10
```

Можна зробити вибірку з декількох елементів, для цього потрібно передати потрібну кількість через параметр *n*.

```
s.sample(n=3)

>>

a    10
c    30
e    50
```

Також є можливість вказати частку (відсоток) від загального числа об'єктів в структурі, використовуючи параметр *frac*.

```
s.sample(frac=0.3)

>>

b    20
d    40
```

Цікавою особливістю є те, можна передати вектор ваг, довжина якого повинна дорівнювати кількості елементів в структурі. Сума ваг повинна дорівнювати одиниці. Вага, в даному випадку, це ймовірність появи елемента у вибірці.

У нашій тестовій структурі п'ять елементів, сформуємо вектор ваг для неї і зробимо вибірку з трьох елементів.

```
w = [0.1, 0.2, 0.5, 0.1, 0.1]
s.sample(n = 3, weights=w)

c    30
e    50
b    20
```

Даний функціонал також доступний і для структури DataFrame.

```
d = {"price":[1, 2, 3, 5, 6], "count": [10, 20, 30, 40, 50], "percent":
[24, 51, 71, 25, 42]}
df = pd.DataFrame(d)

df.sample()
```

```
>>

   price  count  percent
0      1     10       24
```

У разі роботи з DataFrame можна вказати вісь.

```
df.sample(axis=1)    # стовпці

>>

   price
0      1
1      2
2      3
3      5
4      6
```

```
df.sample(n=2, axis=1)

>>

   price  percent
0      1       24
1      2       51
2      3       71
3      5       25
4      6       42
```

```
df.sample(n=2)    # за замовчуванням axis = 0 (рядки)

>>

   price  count  percent
2      3     30       71
1      2     20       51
```

Додавання нових елементів до структур

Подібне додаванню нового об'єкта до словників.

```
s = pd.Series([10, 20, 30, 40, 50], ['a', 'b', 'c', 'd', 'e'])
s

>>

a    10
b    20
c    30
```

```
d    40
e    50
```

```
s['f'] = 60    # додамо новий елемет з міткою 'f'
s

>>

a    10
b    20
c    30
d    40
e    50
f    60
```

Додавання нового елемента в структуру DataFrame аналогічне:

```
d = {"price":[1, 2, 3, 5, 6], "count": [10, 20, 30, 40, 50], "percent":
[24, 51, 71, 25, 42]}
df = pd.DataFrame(d)
df

>>

   price  count  percent
0      1     10       24
1      2     20       51
2      3     30       71
3      5     40       25
4      6     50       42
```

```
df['value'] = [3, 14, 7, 91, 5]
df

>>

   price  count  percent  value
0      1     10       24      3
1      2     20       51     14
2      3     30       71      7
3      5     40       25     91
4      6     50       42      5
```

Індексація з використанням логічних виразів

На практиці дуже часто доводиться отримувати певну підвибірку з існуючого набору даних. Наприклад, отримати всі товари, знижка на які більше п'яти відсотків. Або вибрати з бази інформацію про співробітників чоловічої статі старше 30 років. Це дуже схоже на процес фільтрації під час роботи з таблицями або отримання вибірки з бази даних. Схожий функціонал реалізований в *pandas* і ми вже тйого використовували, коли розглядали різні підходи до індексації.

Умовний вираз записується замість індексу в квадратних дужках при зверненні до елементів структури.

Під час роботи з Series можливі наступні варіанти використання:

```
s = pd.Series([10, 20, 30, 40, 50, 10, 10], ['a', 'b', 'c', 'd', 'e',
'f', 'g'])
s[s>30]

>>

d    40
e    50
```

```
s[s==10]

>>

a    10
f    10
g    10
```

```
s[(s>=30) & (s<50)]

>>

c    30
d    40
```

Під час роботи з DataFrame необхідно вказувати стовпець за яким буде проводитися фільтрація (вибірка).

```
d = {"price":[1, 2, 3, 5, 6], "count": [10, 20, 30, 40, 50], "percent":
[24, 51, 71, 25, 42], "cat":["A", "B", "A", "A", "C"]}
df = pd.DataFrame(d)
df

>>

   price  count  percent cat
0      1     10       24   A
1      2     20       51   B
2      3     30       71   A
3      5     40       25   A
4      6     50       42   C
```

```
df[df["price"] > 3]

>>

   price  count  percent cat
3      5     40       25   A
4      6     50       42   C
```

В якості логічного виразу можна використовувати досить складні конструкції з використанням *map*, *filter*, лямбда-функцій тощо.

```
fn = df["cat"].map(lambda x: x == "A")
df[fn]

>>

   price  count  percent cat
0      1     10       24   A
2      3     30       71   A
3      5     40       25   A
```

Використання isin для роботи з даними в Pandas

За структурам даних Pandas можна будувати масиви з даними типу *boolean*, за яким можна перевірити наявність або відсутність того чи іншого елемента.

```
s = pd.Series([10, 20, 30, 40, 50, 10, 10], ['a', 'b', 'c', 'd', 'e',
'f', 'g'])
s.isin([10, 20])

>>

a     True
b     True
c    False
d    False
e    False
f     True
g     True
```

Робота з DataFrame аналогічна роботі зі структурою Series.

```
df = pd.DataFrame({"price":[1, 2, 3, 5, 6],
                   "count": [10, 20, 30, 40, 50],
                   "percent": [24, 51, 71, 25, 42]})
df.isin([1, 3, 25, 30, 10])

>>

   price  count  percent
0   True   True    False
1  False  False    False
2   True   True    False
3  False  False     True
4  False  False    False
```

Виявлення пропущених даних

Дуже часто великі обсяги даних, які готуються для подальшого аналізу, мають пропуски. Для того, щоб можна було використовувати алгоритми машинного навчання, які будують моделі за цими даними, необхідно ці пропуски чимось заповнити.

Створимо структуру DataFrame, яка буде містити пропуски.

Для цього імпортуємо необхідну бібліотеку:

```
from io import StringIO
```

Після цього створимо об'єкт в форматі csv.

```
data = 'price,count,percent\n1,10,\n2,20,51\n3,30,'
df = pd.read_csv(StringIO(data))
```

Отриманий об'єкт *df* - це DataFrame з пропусками.

```
df

>>

   price  count  percent
0      1     10      NaN
1      2     20     51.0
2      3     30      NaN
```

В даному прикладі, у об'єктів з індексами 0 і 2 відсутні дані в полі *percent*. Відсутні дані позначаються як ***NaN***. Додамо до існуючої структури ще один запис, у якого буде відсутнє значення в полі *count*.

```
df.loc[3] = {'price':4, 'count':None, 'percent':26.3}
df

>>

   price count  percent
0      1    10      NaN
1      2    20     51.0
2      3    30      NaN
3      4  None     26.3
```

Для початку використаємо методи з бібліотеки *pandas*, які дозволяють швидко перевірити наявність елементів *NaN* в структурах. Якщо таблиця невелика, то можна використовувати метод *isnull()*.

```
pd.isnull(df)

>>

   price  count  percent
0  False  False     True
1  False  False    False
2  False  False     True
3  False   True    False
```

Таким чином ми отримуємо таблицю того ж розміру, але на місці реальних даних в ній знаходяться логічні змінні. Вони приймають значення *False*, якщо значення поля в об'єкта існує, або *True*, якщо значення в даному полі - це *NaN*. На додаток до цього можна подивитися детальну інформацію про об'єкт. Для цього можна скористатися методом `info()`.

```
df.info()

>>

<class 'pandas.core.frame.DataFrame'>
Int64Index: 4 entries, 0 to 3
Data columns (total 3 columns):
 #   Column   Non-Null Count  Dtype
---  ------   --------------  -----
 0   price    4 non-null      int64
 1   count    3 non-null      object
 2   percent  2 non-null      float64
dtypes: float64(1), int64(1), object(1)
memory usage: 128.0+ bytes
```

У нашому прикладі видно, що об'єкт `df` має три стовпці (*count, percent* і *price*), водночас у стовпці *price* всі об'єкти значимі - НЕ *NaN*, в стовпці *count* – один *NaN*об'єкт, в поле *percent* – два *NaN*об'єкти.

Можна скористатися таким підходом для отримання кількості *NaN* елементів в записах:

```
df.isnull().sum()

>>

price      0
count      1
percent    2
```

Заміна пропущених даних

Пропущені дані об'єктів можна замінити на конкретні числові значення. Для цього можна використовувати метод `fillna()`. Використаємо структуру `df`, створену в попередньому розділі.

```
df

>>

   price count  percent
0      1    10      NaN
1      2    20     51.0
2      3    30      NaN
3      4  None     26.3
```

```
df.fillna(0)

>>

   price  count  percent
0      1     10      0.0
1      2     20     51.0
2      3     30      0.0
3      4      0     26.3
```

Цей метод не змінює поточну структуру. Він повертає структуру DataFrame, створену на базі існуючої, з заміною *NaN* значень на ті, які передані до методу в якості аргументу. Наприклад, дані можна заповнити середнім значенням по стовпцю.

```
df.fillna(df.mean())

>>

   price  count  percent
0      1   10.0    38.65
1      2   20.0    51.00
2      3   30.0    38.65
3      4   20.0    26.30
```

В залежності від завдання, використовується той чи інший метод заповнення відсутніх елементів. В якості заміни може бути нульове значення, математичне сподівання, медіана тощо.

Для заміни *NaN* елементів на конкретні значення також можна використовувати інтерполяцію, яка реалізована в методі `interpolate()`. Алгоритм інтерполяції задається через аргументи методу.

Видалення стовпців/об'єктів з пропущеними даними

Досить часто використовують інший підхід до відсутніх даних - це видалення записів (рядків) або колонок (стовпців), в яких зустрічаються пропуски. Для того, щоб видалити всі об'єкти, які містять значення *NaN*, застосовують метод `dropna()` без аргументів.

```
df.dropna()

>>

   price count  percent
1      2    20     51.0
```

Замість записів можна видалити колонки. Для цього потрібно викликати метод `dropna()` з аргументом `axis=1`.

```
df.dropna(axis=1)

>>

   price
0      1
1      2
2      3
3      4
```

Pandas дозволяє задати поріг на кількість не-*NaN* елементів. У наведеному нижче прикладі будуть видалені всі стовпці, в яких кількість не-*NaN*елементів менше трьох.

```
df.dropna(axis = 1, thresh=3)

>>
```

```
   price count
0      1    10
1      2    20
2      3    30
3      4  None
```

Об'єднання різних DataFrame

Іноді виникає необхідність об'єднання декількох DataFrame в одну таблицю. Розглянемо три окремі DataFrame:

```
df1 = pd.DataFrame(
    {
        'A': ['A0', 'A1', 'A2', 'A3'],
        'B': ['B0', 'B1', 'B2', 'B3'],
        'C': ['C0', 'C1', 'C2', 'C3'],
        'D': ['D0', 'D1', 'D2', 'D3']
    },
    index=[0, 1, 2, 3])

df2 = pd.DataFrame(
    {
        'A': ['A4', 'A5', 'A6', 'A7'],
        'B': ['B4', 'B5', 'B6', 'B7'],
        'C': ['C4', 'C5', 'C6', 'C7'],
        'D': ['D4', 'D5', 'D6', 'D7']
    },
    index=[4, 5, 6, 7])

df3 = pd.DataFrame(
    {
        'A': ['A8', 'A9', 'A10', 'A11'],
        'B': ['B8', 'B9', 'B10', 'B11'],
        'C': ['C8', 'C9', 'C10', 'C11'],
        'D': ['D8', 'D9', 'D10', 'D11']
    },
    index=[8, 9, 10, 11])
```

```
df1

>>

    A   B   C   D
0  A0  B0  C0  D0
1  A1  B1  C1  D1
```

```
2  A2  B2  C2  D2
3  A3  B3  C3  D3
```

```
df2

>>

    A   B   C   D
4  A4  B4  C4  D4
5  A5  B5  C5  D5
6  A6  B6  C6  D6
7  A7  B7  C7  D7
```

```
df3

>>

      A    B    C    D
8    A8   B8   C8   D8
9    A9   B9   C9   D9
10  A10  B10  C10  D10
11  A11  B11  C11  D11
```

Тепер об'єднаємо їх в один DataFrame, використовуючи метод *concat()*. Якщо не задавати додаткових атрибутів, об'єднання відбудеться у стовпчик (за стовпцями).

```
pd.concat([df1,df2,df3])

>>

      A    B    C    D
0    A0   B0   C0   D0
1    A1   B1   C1   D1
2    A2   B2   C2   D2
3    A3   B3   C3   D3
4    A4   B4   C4   D4
5    A5   B5   C5   D5
6    A6   B6   C6   D6
7    A7   B7   C7   D7
8    A8   B8   C8   D8
```

```
9    A9   B9   C9   D9
10  A10  B10  C10  D10
11  A11  B11  C11  D11
```

Якщо ж вказати вісь *axis=1*, то об'єднання відбудеться за рядками.

```
pd.concat([df1,df2,df3],axis=1)

>>
```

```
      A    B    C    D    A    B    C    D    A    B    C    D
0    A0   B0   C0   D0  NaN  NaN  NaN  NaN  NaN  NaN  NaN  NaN
1    A1   B1   C1   D1  NaN  NaN  NaN  NaN  NaN  NaN  NaN  NaN
2    A2   B2   C2   D2  NaN  NaN  NaN  NaN  NaN  NaN  NaN  NaN
3    A3   B3   C3   D3  NaN  NaN  NaN  NaN  NaN  NaN  NaN  NaN
4   NaN  NaN  NaN  NaN   A4   B4   C4   D4  NaN  NaN  NaN  NaN
5   NaN  NaN  NaN  NaN   A5   B5   C5   D5  NaN  NaN  NaN  NaN
6   NaN  NaN  NaN  NaN   A6   B6   C6   D6  NaN  NaN  NaN  NaN
7   NaN  NaN  NaN  NaN   A7   B7   C7   D7  NaN  NaN  NaN  NaN
8   NaN  NaN  NaN  NaN  NaN  NaN  NaN  NaN   A8   B8   C8   D8
9   NaN  NaN  NaN  NaN  NaN  NaN  NaN  NaN   A9   B9   C9   D9
10  NaN  NaN  NaN  NaN  NaN  NaN  NaN  NaN  A10  B10  C10  D10
11  NaN  NaN  NaN  NaN  NaN  NaN  NaN  NaN  A11  B11  C11  D11
```

Іноді DataFrame можуть мати спільні стовпці. Наприклад, створимо два нових DataFrame з однаковим стовпцем *key*.

```
left = pd.DataFrame({
    'key': ['K0', 'K1', 'K2', 'K3'],
    'A': ['A0', 'A1', 'A2', 'A3'],
    'B': ['B0', 'B1', 'B2', 'B3']
})


right = pd.DataFrame({
    'key': ['K0', 'K1', 'K2', 'K3'],
    'C': ['C0', 'C1', 'C2', 'C3'],
    'D': ['D0', 'D1', 'D2', 'D3']
})
```

```
left

>>
```

```
  key   A   B
0  K0  A0  B0
1  K1  A1  B1
2  K2  A2  B2
3  K3  A3  B3
```

```
right

>>

  key   C   D
0  K0  C0  D0
1  K1  C1  D1
2  K2  C2  D2
3  K3  C3  D3
```

Тепер об'єднаємо їх в один DataFrame за стовпцем *key*. Для цього використовується метод *merge()*.

```
pd.merge(left, right, how='inner', on='key')

>>

  key   A   B   C   D
0  K0  A0  B0  C0  D0
1  K1  A1  B1  C1  D1
2  K2  A2  B2  C2  D2
3  K3  A3  B3  C3  D3
```

1.3. Оглядовий аналіз даних з Pandas

Зчитування даних з csv файлу

Розглянемо найпростіший спосіб обробки даних, які зберігаються в форматі *.csv*, а також побудову елементарних графіків.

Для початку роботи імпортуємо необхідні бібліотеки.

```
import pandas as pd
import matplotlib.pyplot as plt

# Красиві графіки
plt.style.use('ggplot')
# Розмір зображень
plt.rcParams['figure.figsize'] = (15, 5)
```

Будемо розглядати дані про велосипедистів Монреалю.

- Завантажити файл з даними: *https://raw.githubusercontent.com/jvns/pandas-cookbook/master/data/bikes.csv*

Цей набір даних описує, скільки людей знаходилося на 9 різних велосипедних доріжках Монреаля кожного дня.

Зчитати файл можна за допомогою методу *read_csv()*. Але в нашому випадку необхідно ще додатково задати атрибути, які зроблять наступне:

- Замінять роздільник з коми на крапку з комою
- Замінять кодування на 'latin1' (за замовчуванням ставиться 'utf8')
- Оброблять дати у стовпці 'Date'
- Вкажуть, що спочатку йде день, а потім місяць (формат YYYY-DD-MM)
- Замінять індекс на значення у стовпці 'Date'

```
fixed_df = pd.read_csv('../bikes.csv',  # тут вказуємо шлях до файлу
                       sep=';', encoding='latin1',
                       parse_dates=['Date'], dayfirst=True,
                       index_col='Date')
```

Переглянемо перші три записи з таблиці:

```
fixed_df[:3]

>>

            Berri 1  Brébeuf (données non disponibles)  Côte-Sainte-Catherine  \
Date
2012-01-01       35                                NaN                     0
2012-01-02       83                                NaN                     1
2012-01-03      135                                NaN                     2

            Maisonneuve 1  Maisonneuve 2  du Parc  Pierre-Dupuy  Rachel1  \
Date
2012-01-01             38             51       26            10       16
2012-01-02             68            153       53             6       43
2012-01-03            104            248       89             3       58

            St-Urbain (données non disponibles)
Date
2012-01-01                                  NaN
2012-01-02                                  NaN
2012-01-03                                  NaN
```

Щоб переглянути стовпці, можна звернутись до них, як до елементів словника. Виведемо перші 10 записів стовпця 'Maisonneuve 1'.

```
fixed_df['Maisonneuve 1'][:10]

>>

Date
2012-01-01     38
2012-01-02     68
2012-01-03    104
2012-01-04    116
2012-01-05    124
2012-01-06     98
2012-01-07     80
2012-01-08     62
2012-01-09    165
2012-01-10    238
```

Тепер побудуємо графік, просто використавши метод *plot()* для всіх записів з одного стовпця (рис. 1.1).

```
fixed_df['Maisonneuve 1'].plot()
```

```
>>
```

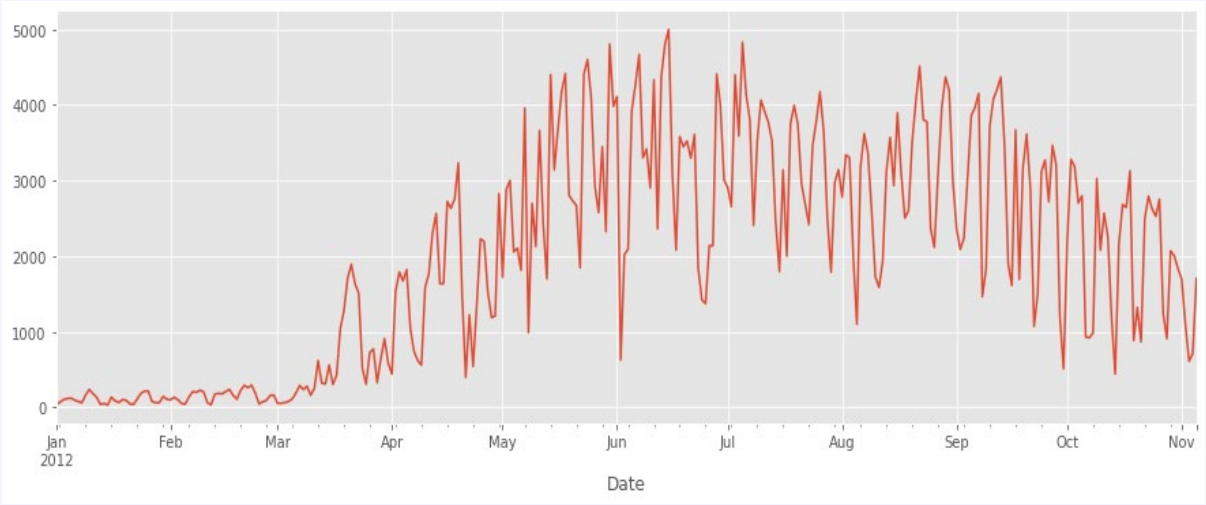

Рис. 1.1. Кількість велосипедистів на велосипедній доріжці Монреаля 'Maisonneuve 1' щодня протягом 2012 року

Найбільш важливим етапом аналізу даних є їх **інтерпретація**. Про що нам говорить такий графік? Очевидно, що не дуже багато людей полюбляють кататися на велосипеді взимку та на початку весни :)

Також можна побудувати графік одразу для всіх стовпців (рис. 1.2). Для цього бажано трохи збільшити зображення.

```
fixed_df.plot(figsize=(15, 10))
>>
```

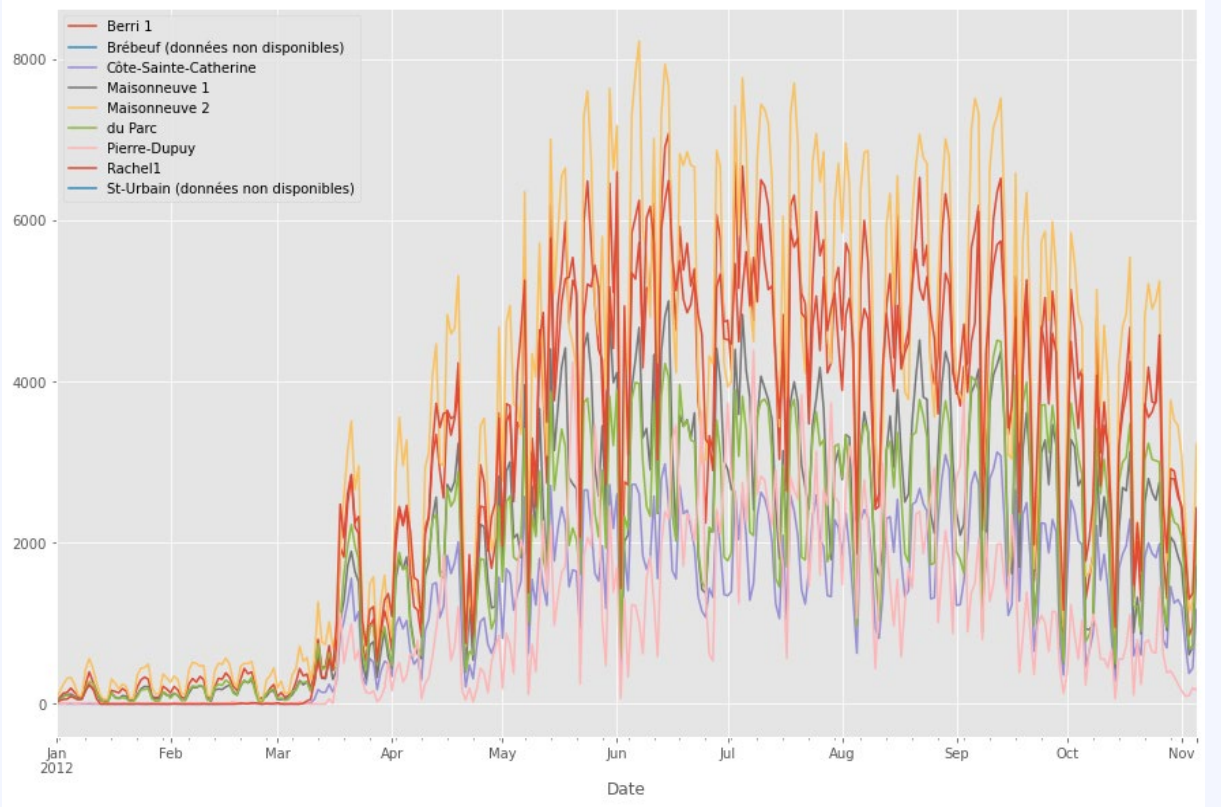

Рис. 1.2. Кількість велосипедистів на всіх 9 велосипедних доріжках Монреаля щодня протягом 2012 року

Що ми тут бачимо? На всіх велосипедних доріжках дані ведуть себе однаково. Якщо це поганий день для велосипедистів, то він поганий всюди.

Наступним кроком з'ясуємо, люди в Монреалі частіше використовують велосипед по буднях чи у вихідні дні? Як приклад, будемо розглядати доріжку Berri. Створимо для неї окремий DataFrame із використанням методу *copy()*.

```
berri_bikes = fixed_df[['Berri 1']].copy()
berri_bikes[:5]

>>

            Berri 1
Date
2012-01-01       35
2012-01-02       83
2012-01-03      135
2012-01-04      144
2012-01-05      197
```

Далі додамо стовпець "день тижня". Зараз в якості індексів рядків використовується дата, це не дуже зручно для нашої мети.

```
berri_bikes.index

>>

DatetimeIndex(['2012-01-01', '2012-01-02', '2012-01-03', '2012-01-04',
               '2012-01-05', '2012-01-06', '2012-01-07', '2012-01-08',
               '2012-01-09', '2012-01-10',
               ...
               '2012-10-27', '2012-10-28', '2012-10-29', '2012-10-30',
               '2012-10-31', '2012-11-01', '2012-11-02', '2012-11-03',
               '2012-11-04', '2012-11-05'],
              dtype='datetime64[ns]', name='Date', length=310, freq=None)
```

Pandas має набір функціоналу для роботи з часовими проміжками. Тому, якщо ми хочемо отримати день місяця для кожного рядка, то можна написати:

```
berri_bikes.index.day

>>

Int64Index([ 1,  2,  3,  4,  5,  6,  7,  8,  9, 10,
            ...
            27, 28, 29, 30, 31,  1,  2,  3,  4,  5],
           dtype='int64', name='Date', length=310)
```

Але ми хочемо бачити день тижня, тому доповнюємо:

```
berri_bikes.index.weekday

>>

Int64Index([6, 0, 1, 2, 3, 4, 5, 6, 0, 1,
            ...
            5, 6, 0, 1, 2, 3, 4, 5, 6, 0],
           dtype='int64', name='Date', length=310)
```

Це дні тижня, 0 - понеділок. Тепер, коли ми знаємо, як отримати день тижня, ми можемо додати його як стовпець в DataFrame.

```
berri_bikes['weekday'] = berri_bikes.index.weekday
berri_bikes[:7]

>>
```

```
            Berri 1  weekday
Date
2012-01-01       35        6
2012-01-02       83        0
2012-01-03      135        1
2012-01-04      144        2
2012-01-05      197        3
2012-01-06      146        4
2012-01-07       98        5
```

Оскільки дні тижня будуть циклічно повторюватись, записи в таблиці необхідно згрупувати. Для цього структура DataFrame має метод *groupby()*, який групує по одному або кількох стовпцях.

У нашому випадку, *berri_bikes.groupby('weekday').sum()* означає "Згрупувати рядки за днями тижня і потім скласти всі значення з однаковим днем тижня".

```
weekday_counts = berri_bikes.groupby('weekday').sum()
weekday_counts

>>

         Berri 1
weekday
0         134298
1         135305
2         152972
3         160131
4         141771
5         101578
6          99310
```

Тепер перейменуємо 0, 1, 2, 3, 4, 5, 6, щоб розуміти, що вони означають.

```
weekday_counts.index = ['Понеділок', 'Вівторок', 'Середа', 'Четвер',
"П'ятниця", 'Субота', 'Неділя']
weekday_counts

           Berri 1
Понеділок   134298
Вівторок    135305
Середа      152972
Четвер      160131
П'ятниця    141771
```

```
Субота      101578
Неділя       99310
```

Виведемо графік (рис. 1.3):

```
weekday_counts.plot(kind='bar')

>>
```

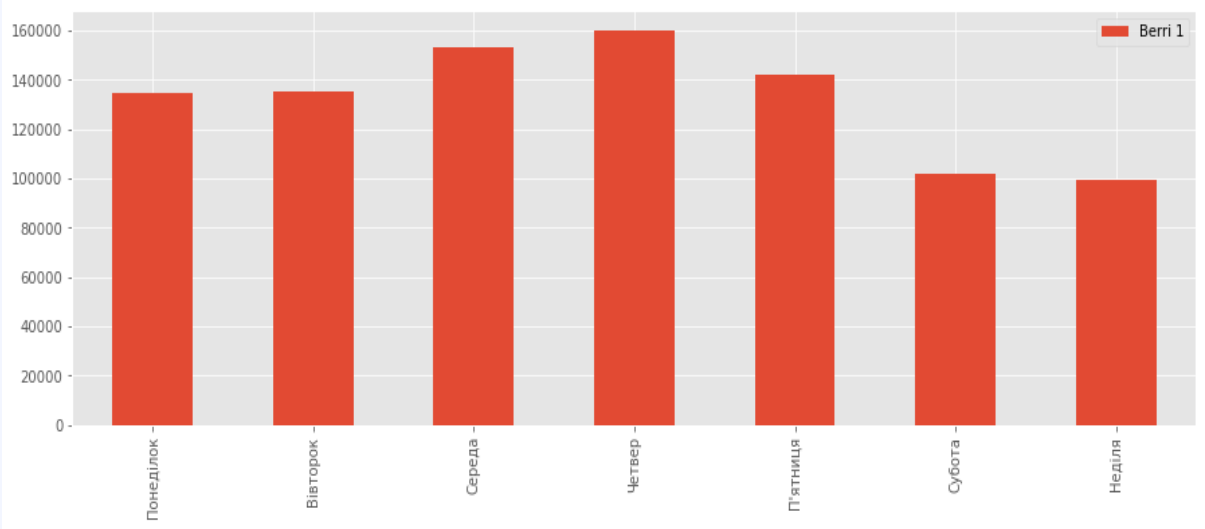

Рис. 1.3. Графік розподілу велосипедистів на велосипедній доріжці Монреаля ‘Berri 1’ в залежності від дня тижня

Як бачимо, в Монреалі частіше їздять на велосипедах по будням.

Аналіз великого обсягу даних

Завантажимо новий набір даних, щоб навчитись працювати з великими обсягами. Це дані про запити (скарги) жителів США до соціальної служби "Сервіс 311" (аналог київської 1551).

- Завантажити набір даних: *https://raw.githubusercontent.com/jvns/pandas-cookbook/master/data/311-service-requests.csv*

```
complaints = pd.read_csv('C:/Drive/IIC/Datasets/311-service-requests.csv
')

>>

C:\Py\Anaconda3\envs\PythonGPU\lib\site-packages\IPython\core\interactiv
eshell.py:3072: DtypeWarning: Columns (8) have mixed types.Specify dtype
```

```
option on import or set low_memory=False.
  interactivity=interactivity, compiler=compiler, result=result)
```

Як ми бачимо, виникло попередження. Це означає, що pandas зіткнувся з проблемою читання даних. У нашому випадку це майже точно означає, що дані мають стовпці, в яких деякі записи є рядками, а деякі являють собою цілі числа. Поки що будемо це ігнорувати, але зазвичай в таких ситуаціях потрібно більш детально розбиратись.

Переглянемо інформацію про завантажений набір даних:

```
complaints.info()

>>

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 111069 entries, 0 to 111068
Data columns (total 52 columns):
 #   Column                          Non-Null Count   Dtype
---  ------                          --------------   -----
 0   Unique Key                      111069 non-null  int64
 1   Created Date                    111069 non-null  object
 2   Closed Date                     60270 non-null   object
 3   Agency                          111069 non-null  object
 4   Agency Name                     111069 non-null  object
 5   Complaint Type                  111069 non-null  object
 6   Descriptor                      110613 non-null  object
 7   Location Type                   79022 non-null   object
 8   Incident Zip                    98807 non-null   object
 9   Incident Address                84441 non-null   object
 10  Street Name                     84432 non-null   object
 11  Cross Street 1                  84728 non-null   object
 12  Cross Street 2                  84005 non-null   object
 13  Intersection Street 1           19364 non-null   object
 14  Intersection Street 2           19366 non-null   object
 15  Address Type                    102247 non-null  object
 16  City                            98854 non-null   object
 17  Landmark                        95 non-null      object
 18  Facility Type                   19104 non-null   object
 19  Status                          111069 non-null  object
 20  Due Date                        39239 non-null   object
 21  Resolution Action Updated Date  96507 non-null   object
 22  Community Board                 111069 non-null  object
 23  Borough                         111069 non-null  object
 24  X Coordinate (State Plane)      98143 non-null   float64
```

```
 25  Y Coordinate (State Plane)      98143 non-null   float64
 26  Park Facility Name              111069 non-null  object
 27  Park Borough                    111069 non-null  object
 28  School Name                     111069 non-null  object
 29  School Number                   111048 non-null  object
 30  School Region                   110524 non-null  object
 31  School Code                     110524 non-null  object
 32  School Phone Number             111069 non-null  object
 33  School Address                  111069 non-null  object
 34  School City                     111069 non-null  object
 35  School State                    111069 non-null  object
 36  School Zip                      111069 non-null  object
 37  School Not Found                38984 non-null   object
 38  School or Citywide Complaint    0 non-null       float64
 39  Vehicle Type                    99 non-null      object
 40  Taxi Company Borough            117 non-null     object
 41  Taxi Pick Up Location           1059 non-null    object
 42  Bridge Highway Name             185 non-null     object
 43  Bridge Highway Direction        185 non-null     object
 44  Road Ramp                       180 non-null     object
 45  Bridge Highway Segment          219 non-null     object
 46  Garage Lot Name                 49 non-null      object
 47  Ferry Direction                 24 non-null      object
 48  Ferry Terminal Name             70 non-null      object
 49  Latitude                        98143 non-null   float64
 50  Longitude                       98143 non-null   float64
 51  Location                        98143 non-null   object
dtypes: float64(5), int64(1), object(46)
memory usage: 44.1+ MB
```

Як ми бачимо, дані містять 52 колонки та 111069 записів. Якщо ми хочемо вивести цей DataFrame, то будуть показані тільки декілька перших рядків. Виведемо перші 5 рядків таблиці:

```
complaints[:5]

>>

   Unique Key             Created Date             Closed Date Agency  \
0    26589651  10/31/2013 02:08:41 AM                      NaN   NYPD
1    26593698  10/31/2013 02:01:04 AM                      NaN   NYPD
2    26594139  10/31/2013 02:00:24 AM  10/31/2013 02:40:32 AM   NYPD
3    26595721  10/31/2013 01:56:23 AM  10/31/2013 02:21:48 AM   NYPD
4    26590930  10/31/2013 01:53:44 AM                      NaN  DOHMH

                              Agency Name           Complaint Type  \
0          New York City Police Department  Noise - Street/Sidewalk
1          New York City Police Department          Illegal Parking
```

```
2          New York City Police Department       Noise - Commercial
3          New York City Police Department          Noise - Vehicle
4  Department of Health and Mental Hygiene                   Rodent

                    Descriptor        Location Type Incident Zip  \
0                 Loud Talking      Street/Sidewalk        11432
1  Commercial Overnight Parking      Street/Sidewalk        11378
2             Loud Music/Party  Club/Bar/Restaurant        10032
3               Car/Truck Horn      Street/Sidewalk        10023
4  Condition Attracting Rodents           Vacant Lot        10027

   Incident Address  ... Bridge Highway Name Bridge Highway Direction  \
0  90-03 169 STREET  ...                  NaN                      NaN
1         58 AVENUE  ...                  NaN                      NaN
2     4060 BROADWAY  ...                  NaN                      NaN
3    WEST 72 STREET  ...                  NaN                      NaN
4   WEST 124 STREET  ...                  NaN                      NaN

  Road Ramp Bridge Highway Segment Garage Lot Name Ferry Direction  \
0       NaN                    NaN             NaN              NaN
1       NaN                    NaN             NaN              NaN
2       NaN                    NaN             NaN              NaN
3       NaN                    NaN             NaN              NaN
4       NaN                    NaN             NaN              NaN

  Ferry Terminal Name   Latitude  Longitude  \
0                 NaN  40.708275 -73.791604
1                 NaN  40.721041 -73.909453
2                 NaN  40.843330 -73.939144
3                 NaN  40.778009 -73.980213
4                 NaN  40.807691 -73.947387

                                  Location
0   (40.70827532593202, -73.79160395779721)
1  (40.721040535628305, -73.90945306791765)
2   (40.84332975466513, -73.93914371913482)
3    (40.7780087446372, -73.98021349023975)
4   (40.80769092704951, -73.94738703491433)

[5 rows x 52 columns]
```

Переглянемо записи лише по одному із стовпців (наприклад, 'Complaint Type' - вид скарги):

```
complaints['Complaint Type'][:5]

>>

0    Noise - Street/Sidewalk
1            Illegal Parking
2         Noise - Commercial
3            Noise - Vehicle
4                     Rodent
```

До речі, порядок вказування індексів не важливий:

```
complaints[:5]['Complaint Type']

>>

0    Noise - Street/Sidewalk
1            Illegal Parking
2         Noise - Commercial
3            Noise - Vehicle
4                     Rodent
```

Тепер переглянемо лише тип скарги та район, відкинувши всі інші колонки.

```
complaints[['Complaint Type', 'Borough']]

>>

                 Complaint Type    Borough
0       Noise - Street/Sidewalk     QUEENS
1               Illegal Parking     QUEENS
2            Noise - Commercial  MANHATTAN
3               Noise - Vehicle  MANHATTAN
4                        Rodent  MANHATTAN
...                         ...        ...
111064  Maintenance or Facility   BROOKLYN
111065          Illegal Parking     QUEENS
111066  Noise - Street/Sidewalk  MANHATTAN
111067       Noise - Commercial   BROOKLYN
111068         Blocked Driveway   BROOKLYN

[111069 rows x 2 columns]
```

Як бачимо, виводяться тільки перші і останні 5 записів.

Виведемо натомість перші 10.

```
complaints[['Complaint Type', 'Borough']][:10]

>>

            Complaint Type    Borough
0  Noise - Street/Sidewalk     QUEENS
1           Illegal Parking     QUEENS
2       Noise - Commercial  MANHATTAN
3          Noise - Vehicle  MANHATTAN
4                   Rodent  MANHATTAN
5       Noise - Commercial     QUEENS
6         Blocked Driveway     QUEENS
7       Noise - Commercial     QUEENS
8       Noise - Commercial  MANHATTAN
9       Noise - Commercial   BROOKLYN
```

Тепер визначимо, який тип скарг зустрічається найчастіше. Для цього у *pandas* є вбудований метод *value_counts()*.

```
complaints['Complaint Type'].value_counts()

>>

HEATING                          14200
GENERAL CONSTRUCTION              7471
Street Light Condition            7117
DOF Literature Request            5797
PLUMBING                          5373
                                 ...
Stalled Sites                        1
Ferry Permit                         1
Municipal Parking Facility           1
Trans Fat                            1
Snow                                 1
```

Виведемо 10 найбільш частих типів скарг:

```
complaint_counts = complaints['Complaint Type'].value_counts()
complaint_counts[:10]

>>

HEATING                    14200
GENERAL CONSTRUCTION        7471
Street Light Condition      7117
DOF Literature Request      5797
PLUMBING                    5373
```

```
PAINT - PLASTER            5149
Blocked Driveway           4590
NONCONST                   3998
Street Condition           3473
Illegal Parking            3343
```

І для зручності побудуємо стовпчикову діаграму (рис. 1.4).

```
complaint_counts[:10].plot(kind='bar')

>>
```

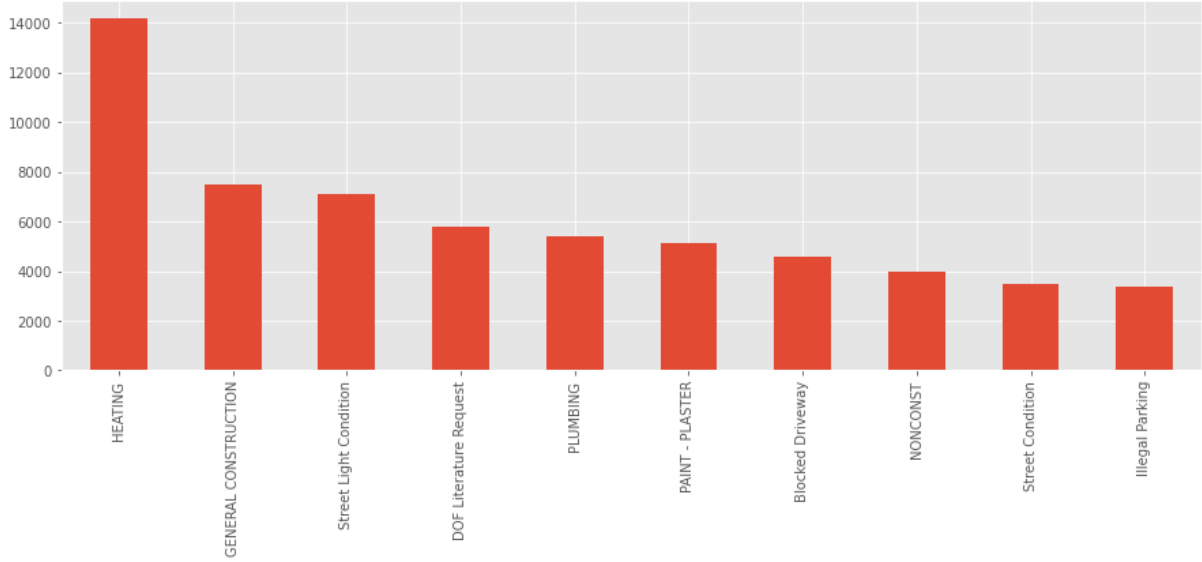

Рис. 1.4. Стовпчикова діаграма кількості скарг жителів США в залежності від типу скарги

Як бачимо, найчастіше жителі США скаржаться на опалення :)

1.4. Аналіз набору даних "Титанік"

Швидкий погляд на дані

Завантажимо набір даних з інформацією про пасажирів "Титаніка".

- Посилання:

  https://github.com/agconti/kaggle-titanic/raw/master/data/train.csv

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns #розширення функціоналу matplotlib
import numpy as np
sns.set_style("ticks")

titanic_full_df = pd.read_csv("https://github.com/agconti/kaggle-titanic/
raw/master/data/train.csv", sep=",")
```

Визначимо розмірність таблиці.

```
titanic_full_df.shape

>>

(891, 12)
```

І переглянемо інформацію.

```
titanic_full_df.info()

>>

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 891 entries, 0 to 890
Data columns (total 12 columns):
 #   Column       Non-Null Count  Dtype
---  ------       --------------  -----
 0   PassengerId  891 non-null    int64
 1   Survived     891 non-null    int64
 2   Pclass       891 non-null    int64
 3   Name         891 non-null    object
 4   Sex          891 non-null    object
 5   Age          714 non-null    float64
 6   SibSp        891 non-null    int64
 7   Parch        891 non-null    int64
 8   Ticket       891 non-null    object
```

```
 9   Fare         891 non-null    float64
 10  Cabin        204 non-null    object
 11  Embarked     889 non-null    object
dtypes: float64(2), int64(5), object(5)
memory usage: 83.7+ KB
```

- PassengerId – ідентифікатор пасажира
    - Survival – поле в якому зазначено врятувалась людина (1) чи ні (0)
- Pclass – містить соціально-економічний статус:
    - високий
    - середній
    - низький
- Name – ім'я пасажира
- Sex – стать пасажира
- Age – вік
- SibSp – містить інформацію про кількість родичів 2-го порядку (чоловік, дружина, брати, сетри)
- Parch – містить інформацію про кількість родичів на борту 1-го порядку (мати, батько, діти)
- Ticket – номер квитка
- Fare – ціна квитка
- Cabin – каюта
- Embarked – порт посадки
    - C – Cherbourg
    - Q – Queenstown
    - S – Southampton

Переглянемо статистичні характеристики набору даних:

```
titanic_full_df.describe()

>>

       PassengerId    Survived      Pclass         Age       SibSp
count   891.000000  891.000000  891.000000  714.000000  891.000000
mean    446.000000    0.383838    2.308642   29.699118    0.523008
std     257.353842    0.486592    0.836071   14.526497    1.102743
min       1.000000    0.000000    1.000000    0.420000    0.000000
25%     223.500000    0.000000    2.000000   20.125000    0.000000
50%     446.000000    0.000000    3.000000   28.000000    0.000000
75%     668.500000    1.000000    3.000000   38.000000    1.000000
max     891.000000    1.000000    3.000000   80.000000    8.000000

            Parch        Fare
count  891.000000  891.000000
mean     0.381594   32.204208
std      0.806057   49.693429
min      0.000000    0.000000
25%      0.000000    7.910400
50%      0.000000   14.454200
75%      0.000000   31.000000
max      6.000000  512.329200
```

А також перші записи в таблиці.

```
titanic_full_df.head()

>>

   PassengerId  Survived  Pclass  \
0            1         0       3
1            2         1       1
2            3         1       3
3            4         1       1
4            5         0       3

                                                Name     Sex   Age  SibSp  \
0                            Braund, Mr. Owen Harris    male  22.0      1
1  Cumings, Mrs. John Bradley (Florence Briggs Th...  female  38.0      1
2                             Heikkinen, Miss. Laina  female  26.0      0
3       Futrelle, Mrs. Jacques Heath (Lily May Peel)  female  35.0      1
4                           Allen, Mr. William Henry    male  35.0      0

   Parch            Ticket     Fare Cabin Embarked
```

```
0      0         A/5 21171   7.2500   NaN        S
1      0          PC 17599  71.2833   C85        C
2      0  STON/O2. 3101282   7.9250   NaN        S
3      0            113803  53.1000  C123        S
4      0            373450   8.0500   NaN        S
```

І останні записи в таблиці.

```
titanic_full_df.tail()

>>

     PassengerId  Survived  Pclass                                          Name
\
886          887         0       2                         Montvila, Rev. Juozas
887          888         1       1                  Graham, Miss. Margaret Edith
888          889         0       3      Johnston, Miss. Catherine Helen "Carrie"
889          890         1       1                          Behr, Mr. Karl Howell
890          891         0       3                            Dooley, Mr. Patrick

        Sex   Age  SibSp  Parch      Ticket   Fare Cabin Embarked
886    male  27.0      0      0      211536  13.00   NaN        S
887  female  19.0      0      0      112053  30.00   B42        S
888  female   NaN      1      2  W./C. 6607  23.45   NaN        S
889    male  26.0      0      0      111369  30.00  C148        C
890    male  32.0      0      0      370376   7.75   NaN        Q
```

Переглянемо список пасажирів, які вижили.

```
titanic_full_df[titanic_full_df['Survived']==True]

>>

     PassengerId  Survived  Pclass  \
1              2         1       1
2              3         1       3
3              4         1       1
8              9         1       3
9             10         1       2
..           ...       ...     ...
875          876         1       3
879          880         1       1
880          881         1       2
887          888         1       1
889          890         1       1

                                                  Name     Sex   Age  SibSp
\
```

```
1    Cumings, Mrs. John Bradley (Florence Briggs Th...  female  38.0      1
2                                Heikkinen, Miss. Laina  female  26.0      0
3         Futrelle, Mrs. Jacques Heath (Lily May Peel)  female  35.0      1
8    Johnson, Mrs. Oscar W (Elisabeth Vilhelmina Berg)  female  27.0      0
9                  Nasser, Mrs. Nicholas (Adele Achem)  female  14.0      1
..                                                   ...     ...   ...    ...
875                    Najib, Miss. Adele Kiamie "Jane"  female  15.0      0
879        Potter, Mrs. Thomas Jr (Lily Alexenia Wilson)  female  56.0      0
880         Shelley, Mrs. William (Imanita Parrish Hall)  female  25.0      0
887                        Graham, Miss. Margaret Edith  female  19.0      0
889                               Behr, Mr. Karl Howell    male  26.0      0

     Parch            Ticket     Fare Cabin Embarked
1        0          PC 17599  71.2833   C85        C
2        0  STON/O2. 3101282   7.9250   NaN        S
3        0            113803  53.1000  C123        S
8        2            347742  11.1333   NaN        S
9        0            237736  30.0708   NaN        C
..     ...               ...      ...   ...      ...
875      0              2667   7.2250   NaN        C
879      1             11767  83.1583   C50        C
880      1            230433  26.0000   NaN        S
887      0            112053  30.0000   B42        S
889      0            111369  30.0000  C148        C

[342 rows x 12 columns]
```

Підрахуємо кількість пасажирів, які вижили та загинули.

```
titanic_full_df["Survived"].value_counts()

>>

0    549
1    342
```

Переглянемо декілька довільних записів.

```
titanic_full_df.loc[442 : 450 : 2, ["Age", "Sex"]]

>>

      Age     Sex
442  25.0    male
444   NaN    male
```

```
446  13.0  female
448   5.0  female
450  36.0    male
```

Виведемо список унікальних значень в стовпці "Embarked".

```
titanic_full_df["Embarked"].unique()

>>

array(['S', 'C', 'Q', nan], dtype=object)
```

А також їх кількість:

```
titanic_full_df["Embarked"].nunique()

>>

3
```

Попередня обробка даних

Додамо ще один стовпець, який назвемо "Relatives" – родичі. Нехай він буде містити загальну кількість родичів пасажира.

```
titanic_full_df["Relatives"] = titanic_full_df["SibSp"] + titanic_full_df["Parch"]
```

Переглянемо результат:

```
titanic_full_df[["SibSp", "Parch", "Relatives"]].head()

>>

   SibSp  Parch  Relatives
0      1      0          1
1      1      0          1
2      0      0          0
3      1      0          1
4      0      0          0
```

Замінимо числові значення в стовпці "Pclass" на рядкові.

```
titanic_full_df["Pclass"].replace({1: "Мажори", 2: "Середній клас", 3:
"Роботяги"}, inplace=True)
titanic_full_df["Pclass"].value_counts()

>>
```

```
Роботяги          491
Мажори            216
Середній клас     184
```

Відсортуємо записи за вартістю квитка.

```
titanic_full_df.sort_values(by="Fare", ascending=False)

>>

     PassengerId  Survived         Pclass                                  Name  \
258          259         1         Мажори                    Ward, Miss. Anna
737          738         1         Мажори               Lesurer, Mr. Gustave J
679          680         1         Мажори  Cardeza, Mr. Thomas Drake Martinez
88            89         1         Мажори          Fortune, Miss. Mabel Helen
27            28         0         Мажори      Fortune, Mr. Charles Alexander
..           ...       ...            ...                                 ...
633          634         0         Мажори       Parr, Mr. William Henry Marsh
413          414         0  Середній клас      Cunningham, Mr. Alfred Fleming
822          823         0         Мажори     Reuchlin, Jonkheer. John George
732          733         0  Середній клас                Knight, Mr. Robert J
674          675         0  Середній клас          Watson, Mr. Ennis Hastings

        Sex   Age  SibSp  Parch    Ticket      Fare        Cabin Embarked  \
258  female  35.0      0      0  PC 17755  512.3292          NaN        C
737    male  35.0      0      0  PC 17755  512.3292         B101        C
679    male  36.0      0      1  PC 17755  512.3292  B51 B53 B55        C
88   female  23.0      3      2     19950  263.0000  C23 C25 C27        S
27     male  19.0      3      2     19950  263.0000  C23 C25 C27        S
..      ...   ...    ...    ...       ...       ...          ...      ...
633    male   NaN      0      0    112052    0.0000          NaN        S
413    male   NaN      0      0    239853    0.0000          NaN        S
822    male  38.0      0      0     19972    0.0000          NaN        S
732    male   NaN      0      0    239855    0.0000          NaN        S
674    male   NaN      0      0    239856    0.0000          NaN        S

     Relatives
258          0
737          0
679          1
88           5
27           5
..         ...
633          0
413          0
822          0
732          0
674          0
```

```
[891 rows x 13 columns]
```

Визначимо кількість пропущених даних.

```
titanic_full_df.isnull().sum()

>>

PassengerId      0
Survived         0
Pclass           0
Name             0
Sex              0
Age            177
SibSp            0
Parch            0
Ticket           0
Fare             0
Cabin          687
Embarked         2
Relatives        0
```

Видалимо пропущені записи із колонок *Age* та *Embarked*

```
titanic_full_df = titanic_full_df.dropna(subset=["Age", "Embarked"])
```

Тепер перевіримо наявність пропусків.

```
titanic_full_df.isnull().any()

>>

PassengerId    False
Survived       False
Pclass         False
Name           False
Sex            False
Age            False
SibSp          False
Parch          False
Ticket         False
Fare           False
Cabin           True
```

```
Embarked       False
Relatives      False
```

Заповнимо пропущені дані.

```
titanic_full_df = titanic_full_df.fillna("Невідомо")
titanic_full_df.head()

>>

   PassengerId  Survived    Pclass  \
0            1         0  Роботяги
1            2         1    Мажори
2            3         1  Роботяги
3            4         1    Мажори
4            5         0  Роботяги

                                                Name     Sex   Age  SibSp  \
0                            Braund, Mr. Owen Harris    male  22.0      1
1  Cumings, Mrs. John Bradley (Florence Briggs Th...  female  38.0      1
2                             Heikkinen, Miss. Laina  female  26.0      0
3       Futrelle, Mrs. Jacques Heath (Lily May Peel)  female  35.0      1
4                           Allen, Mr. William Henry    male  35.0      0

   Parch            Ticket     Fare     Cabin Embarked  Relatives
0      0         A/5 21171   7.2500  Невідомо        S          1
1      0          PC 17599  71.2833       C85        C          1
2      0  STON/O2. 3101282   7.9250  Невідомо        S          0
3      0            113803  53.1000      C123        S          1
4      0            373450   8.0500  Невідомо        S          0
```

Аналіз даних

Визначимо середній вік пасажирів

```
titanic_full_df["Age"].mean()

>>

29.64209269662921
```

Створимо таблицю розподілу за статтю пасажирів, які вижили або загинули.

```
titanic_full_df[["Sex", "Survived"]].pivot_table(index=["Sex"],
```

```
     columns=["Survived"], aggfunc=len)

>>

Survived    0    1
Sex
female     64  195
male      360   93
```

А тепер ще і визначимо їх середній вік.

```
titanic_full_df[["Sex", "Survived", "Age"]].pivot_table(values=["Age"],
index=["Sex"], columns=["Survived"], aggfunc="mean")

>>

                Age
Survived          0          1
Sex
female    25.046875  28.630769
male      31.618056  27.276022
```

Згрупуємо пасажирів за класом та визначимо середній вік у кожному класі.

```
titanic_full_df.groupby("Pclass").mean()["Age"]

>>

Pclass
Мажори           38.105543
Роботяги         25.140620
Середній клас    29.877630
```

Переглянемо усереднені дані за класом "Роботяги"

```
titanic_full_df.groupby("Pclass").mean().loc["Роботяги"]

>>

PassengerId    441.219718
Survived         0.239437
Age             25.140620
SibSp            0.585915
Parch            0.456338
Fare            13.229435
Relatives        1.042254
```

Побудуємо гістограми для всіх колонок, де це можливо (рис. 1.12).

```
titanic_full_df.hist()
>>
```

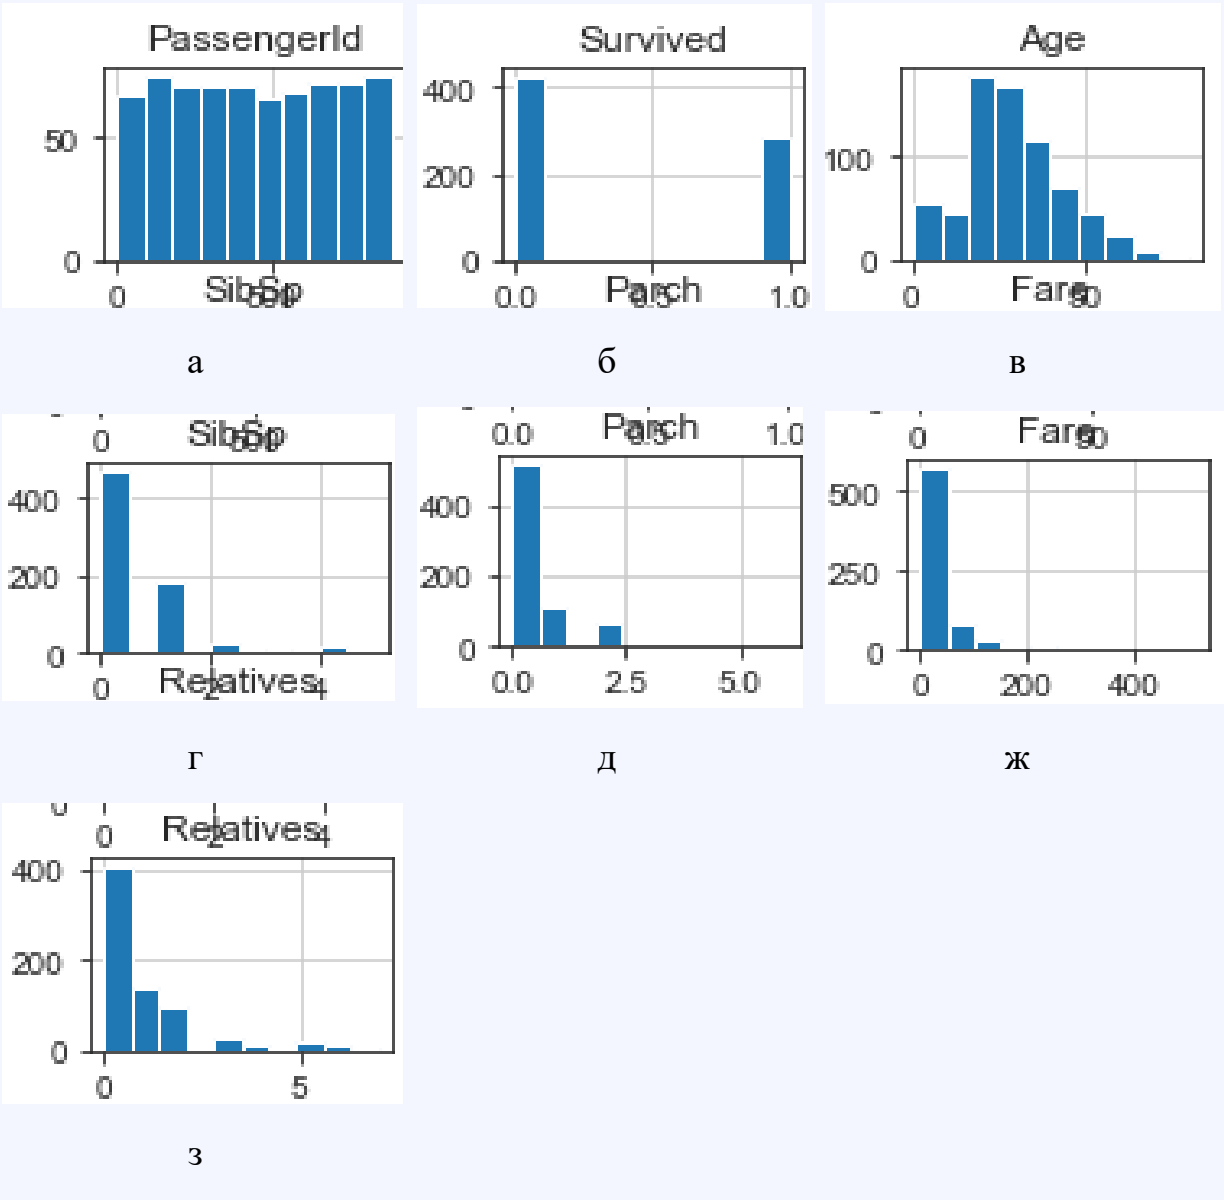

а б в г д ж з

Рис. 1.12. а – ідентифікатор пасажира; б – кількість пасажирів, які вижили та загинули; в – вік пасажирів; г – кількість родичів 2-го порядку; д – кількість родичів 1-го порядку; ж – вартість квитка; з – загальна кількість родичів

Окрема гістограма розподілу за віком (рис. 1.13).

```
titanic_full_df["Age"].hist()
>>
```

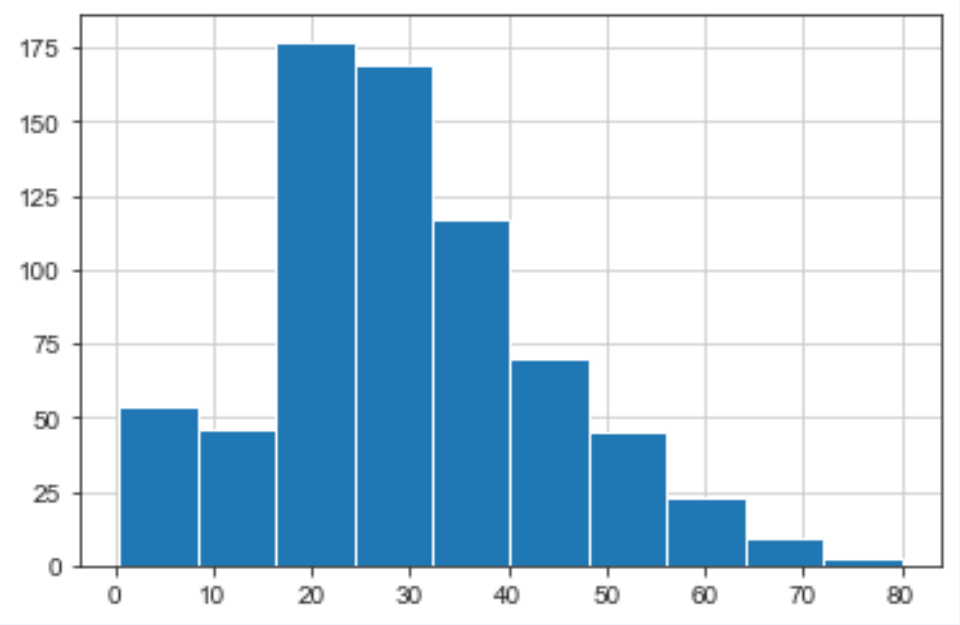

Рис. 1.13. Розподіл пасажирів за віком

Кругова діаграма розподілу за статтю (рис. 1.14):

```
titanic_full_df["Sex"].value_counts().plot(kind="pie", figsize=(5, 5),
fontsize=16);

>>
```

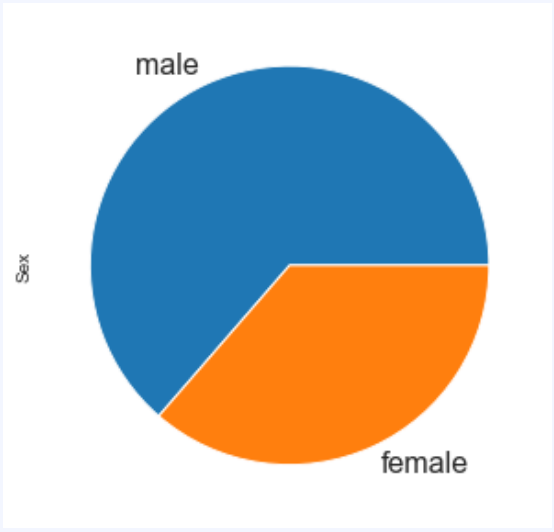

Рис. 1.14. Розподіл пасажирів за статтю

Те саме для класів (рис. 1.15):

```
titanic_full_df["Pclass"].value_counts().plot(kind="pie", figsize=(5, 5),
fontsize=16);

>>
```

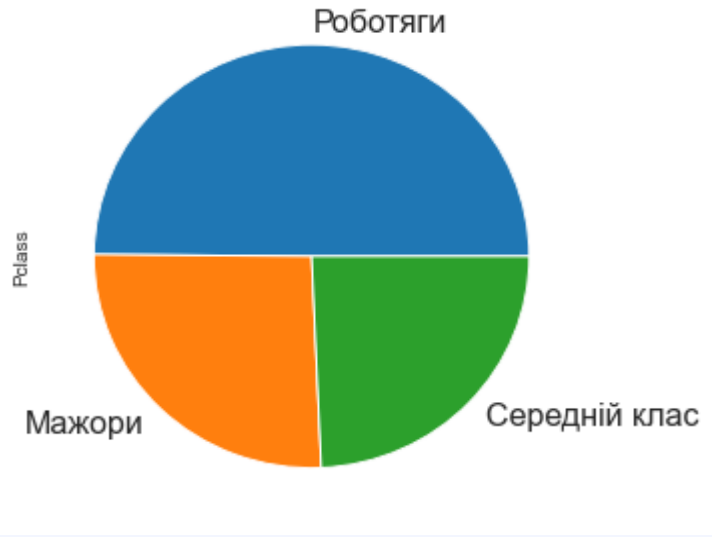

Рис. 1.15. Розподіл пасажирів за класами

Стовпчикова діаграма за кількістю вижившних та їх статтю (рис. 1.16):

```
titanic_full_df[["Sex", "Survived"]].pivot_table(index=["Sex"],
columns=["Survived"], aggfunc=len).plot(kind="bar");

>>
```

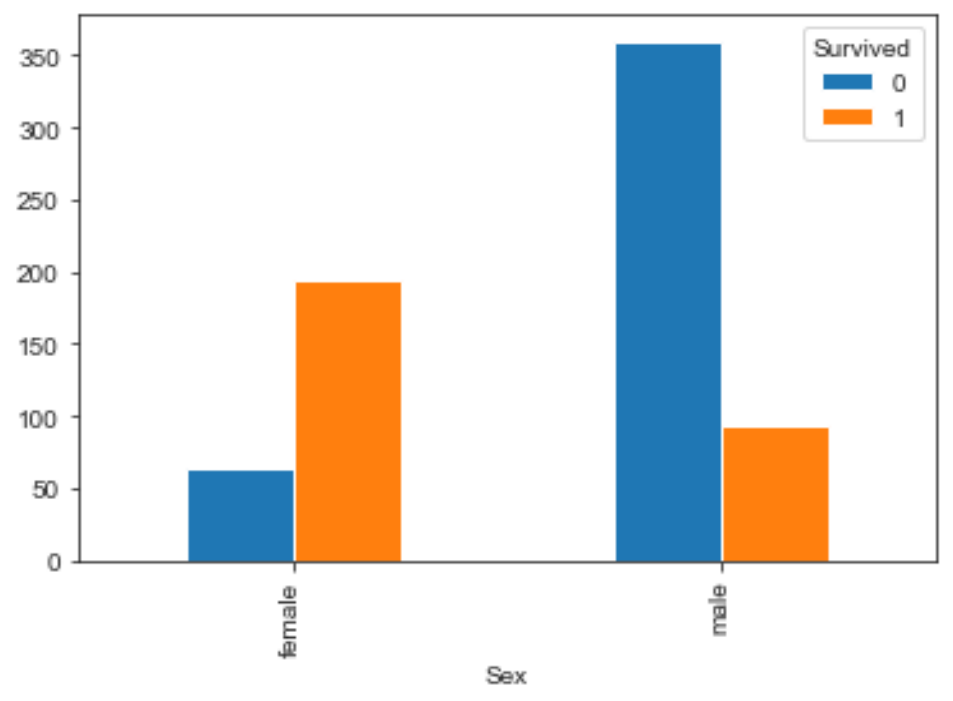

Рис. 1.16. Кількість пасажирів, що вижили та загинули з врахуванням статі

Графік летальності за віком та статтю (рис. 1.17):

```
titanic_full_df[["Age", "Survived"]].pivot_table(index=["Age"],
columns=["Survived"], aggfunc=len).plot();

>>
```

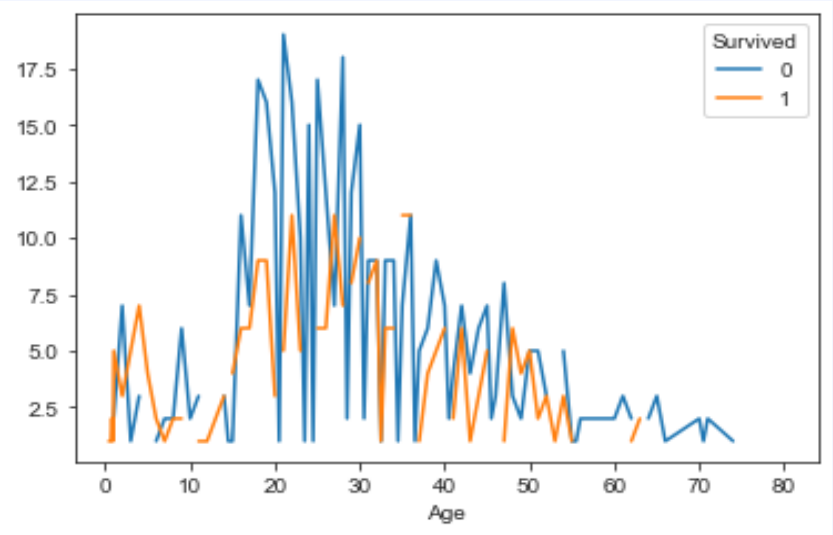

Рис. 1.17. Графік летальності за віком та статтю

1.5 Завдання для самостійного виконання

Загальні завдання для всіх варіантів:

Швидкий погляд на дані:

1. Завантажте набір даних.
2. Виведіть заголовок таблиці (перші 5 записів).
3. Скільки рядків і стовпців в таблиці?
4. Які назви стовпців?
5. Які типи даних у різних стовпців?
6. Скільки в кожному з них унікальних значень?
7. Скільки пропущених значень?

Варіант 1

Набір даних: злочинність в Лос-Анджелесі (la-crime.csv).

Аналіз даних:

1. У наборі даних є інформація про вік, стать, і походження кожної жертви. Люди якого походження найчастіше є жертвами злочинів?
2. Чи вірно, що жінки частіше виявляються жертвами в порівнянні з чоловіками?
3. Вивчіть розподіл кількості злочинів за віком. Яка тенденція? Люди якого віку найчастіше піддаються злочинам? Чи є локальні мінімуми? Використовуйте тип графіків hist.
4. Як відрізняється ймовірність для жінок і чоловіків стати жертвою в залежності від віку? Побудуйте візуалізацію.
5. В якому віковому проміжку чоловіки частіше стають жертвами злочинів?

Походження:

A - Other Asian	H - Hispanic / Latin / Mexican	P - Pacific Islander	Z - Asian Indian
B - Black	I - American Indian / Alaskan Native	S - Samoan	
C - Chinese	J - Japanese	U - Hawaiian	
D - Cambodian	K - Korean	V- Vietnamese	
F - Filipino	L - Laotian	W - White	
G - Guamanian	O - Other	X- Unknown	

Варіант 2

Набір даних: дорож ня поліція Ст енфорда (police_project.csv).

Аналіз даних:

1. З'ясуйте, чоловіки чи жінки частіше перевищують швидкість.
2. Порівняйте, наскільки часто для чоловіків та жінок проводився обшук (search_conducted).
3. Проаналізуйте найбільш часті причини (search_type) для оголошення в розшук. Візуалізуйте дані за допомогою стовпчикової діаграми.
4. Як часто водіїв розшукують для проведення обшуку (Protective Frisk)? Додайте до таблиці новий стовпець 'frisk', який буде містити булеві дані про проведення обшуку (True, якщо обшук проводився).
5. Побудуйте графік кількості зупинок за роками. В якому році було найменше зупинок водіїв?

Варіант 3

Набір даних: злочинніст ь в Лос-Андж елесі (la-crime.csv).

Аналіз даних:

1. Визначте 10 найпоширеніших злочинів в LA. Побудуйте графік.
2. Від яких злочинів частіше потерпають жінки, а від яких чоловіки?
3. Люди якого походження найчастіше піддаються злочинам?
4. Відсортуйте райони по кількості злочинів. Побудуйте графік, що показує найбезпечніші і небезпечні райони.

5. Люди якого походження найчастіше страждають від злочинів в кожному з районів?

Походження:

A - Other Asian	H - Hispanic / Latin / Mexican	P - Pacific Islander	Z - Asian Indian
B - Black	I - American Indian / Alaskan Native	S - Samoan	
C - Chinese	J - Japanese	U - Hawaiian	
D - Cambodian	K - Korean	V- Vietnamese	
F - Filipino	L - Laotian	W - White	
G - Guamanian	O - Other	X- Unknown	

Варіант 4

Набір даних: дорож ня поліція Ст енфорда (police_project.csv).

Аналіз даних:

1. Перевірте, білих чи темношкірих людей частіше зупиняє поліція.
2. З'ясуйте, як частота зупинок через наркотики залежить від часу доби. Побудуйте графік.
3. Чи правда, що більшість зупинок водіїв трапляється вночі? Побудуйте графік типу bar для розподілу кількості зупинок за часом.
4. Виявіть хибні дані в стовпці 'stop_duration' та замініть їх на NaN.
5. Визначте середній час зупинки для кожної з причин зупинки (violation_raw). Побудуйте графік у вигляді стовпчикової діаграми.

Варіант 5

Набір даних: продаж і відеоігор (vgsales.csv).

Аналіз даних:

1. Знайдіть ТОП-10 ігор за кількістю продажів на платформі PC.
2. Побудуйте графік продажів гри Super Mario Bros. в Європі за роками.

3. Визначте, ігри якого жанру найчастіше продавались в Північній Америці у 2010 році. Підрахуйте сумарну кількість проданих ігор цього жанру.
4. Побудуйте кругову діаграму, яка відображає долю проданих ігор 5 найпопулярніших видавництв (Publisher) по відношенню до загальної кількості проданих ігор за останні 2005-2015 роки.
5. Визначте середню кількість всіх проданих ігор у світі за кожні 5 років, починаючи з 1980. Побудуйте графік bar.

Варіант 6

Набір даних: ринок смарт фонів в Україні (phones_data.csv).

Аналіз даних:

1. Побудуйте стовпчикову діаграму розподілу цін (best price) на смартфони.
2. Визначте, як залежить ціна на смартфон від діагоналі екрану.
3. Знайдіть ТОП-5 найдешевших смартфонів з найбільшою ємністю акумулятора.
4. Створіть кругову діаграму розподілу долі виробників смартфонів на ринку (візьміть лише перші 10 найбільших виробників).
5. Який смартфон виробника Samsung є найбільш популярним в ціновій категорії 10-15 тис. грн?

Варіант 7

Набір даних: продаж і відеоігор (vgsales.csv).

Аналіз даних:

1. Знайдіть ТОП-10 видавництв (Publisher) ігор за кількістю продажів у Європі за всі роки (1980-2020).
2. Визначте гру, яка найкраще продавалась у Японії в 2015 році. Підрахуйте долю її продажів у Японії по відношенню до загальної кількості проданих ігор в цьому регіоні та порівняйте з аналогічним показником цієї гри для інших регіонів.
3. Побудуйте суміщений графік (стовпчикову діаграму) кількості проданих ігор на PC та PS4 за 2015-2020 роки. Порівняйте, як змінювалась популярність даних платформ.
4. Побудуйте кругову діаграму, яка показуватиме долю популярності кожного жанру ігор в Європі у 2020 році.
5. Порівняйте рівень світової популярності ігор серії “Call of Duty” та “Battlefield” протягом 2005-2020 років. Побудуйте графік динаміки їх популярності за вказані роки.

Варіант 8

Набір даних: проект и на Netflix (netflix_titles.csv).

Аналіз даних:

1. Побудуйте стовпчикову діаграму розподілу кількості проектів за телевізійним рейтингом (TV-MA, TV-14, TV-PG тощо).
2. Чи правда, що останніми роками Netflix більше фокусується на серіалах (TV Show), ніж на фільмах? Проаналізуйте динаміку за останні 5 років.
3. Визначте, яка країна випустила найбільше проектів на Netflix у 2020 році. А яка найменше?
4. В якому місяці на Netflix зазвичай виходить найбільше серіалів?
5. Визначте 5 найбільш популярних жанрів на Netflix та побудуйте відповідну кругову діаграму їх розподілу.

Варіант 9

Набір даних: ринок смарт фонів в Україні (phones_data.csv).

Аналіз даних:

1. Визначте 10 найбільш дорогих смартфонів на ринку з датою виходу у 2020 році (порівнювати за категорією best price).
2. Чи правда, що найбільш дорогий смартфон виробника Prestigio коштує менше, ніж найдешевший смартфон від Apple?
3. Побудуйте стовпчикову діаграму розподілу кількості смартфонів на ринку в залежності від виробника.
4. Визначте, як змінювалась ємність акумулятора смартфонів від Samsung (з ціною вище 15 тис. грн) за період з 2015 по 2020 рік.
5. Порівняйте середню популярність смартфонів на базі Android та iOS за період з 2015 по 2020 рік.

Варіант 10

Набір даних: проект и на Netflix (netflix_titles.csv).

Аналіз даних:

1. Визначте, проектів якого жанру було найбільше випущено на Netflix у 2020 році.
2. Визначте ТОП-10 країн за кількістю проектів на Netflix. Побудуйте діаграму їх розподілу.
3. Яка країна випустила найбільше старих фільмів (дата прем’єри до 1960 року), доступних на Netflix?
4. Фільми на Netflix частіше виходять весною чи восени? А серіали?
5. В якому році на Netflix було випущено найбільшу кількість фільмів?

Варіант 11

Набір даних: додат ки в Google Play Store (googleplaystore.csv).

Аналіз даних:

1. Визначте 10 категорій, додатки в яких мають найменшу кількість завантажень. Побудуйте стовпчикову діаграму.
2. Чи правда, що безкоштовні додатки з категорії «Ігри» мають більший середній рейтинг, ніж аналогічні платні додатки?
3. Побудуйте кругову діаграму розподілу частки додатків за віковими групами (Content rating).
4. Складіть список додатків, які не оновлювались більш ніж 7 років.
5. Порівняйте середню вагу (в мегабайтах) безкоштовних додатків із довільних 5 категорій.

Варіант 12

Набір даних: додат ки в Google Play Store (googleplaystore.csv).

Аналіз даних:

1. Визначте ТОП-10 категорій, додатки в яких мають найбільшу кількість завантажень. Побудуйте стовпчикову діаграму.
2. Чи правда, що безкоштовні додатки з категорії «Шопінг» мають більшу кількість завантажень, ніж платні додатки з категорії «Освіта»?
3. Проаналізуйте, чи змінюється частка завантажень платних додатків у категорії «Ігри» в залежності від вікової групи?
4. Визначте 5 категорій, в яких платні додатки мають найбільшу кількість відгуків.
5. Знайдіть платні додатки в категорії «Сім’я», які не оновлювались більш ніж 5 років.

ПРАКТИКУМ 2. НЕЙРОННІ МЕРЕЖІ В ЗАДАЧАХ КЛАСИФІКАЦІЇ

2.1 Загальні відомості

Keras — відкрита нейромережева бібліотека, написана мовою Python. Вона здатна працювати поверх TensorFlow, Microsoft Cognitive Toolkit, R, Theano та інших модулів. Keras дозволяє легко проводити експерименти з мережами глибинного навчання. Основними меревагами є зручність в користуванні, модульність та розширюваність.

Автор бібліотеки - François Chollet, Deep learning researcher at Google.

- Повна документація за бібліотекою: *https://keras.io/api/*

Keras працює з усіма відомими архітектурами нейронних мереж.

Список модулів Keras:

- Layers – містить набір прошарків нейронних мереж
- Data preprocessing – для попередньої обробки даних
- Optimizers – набір оптимізаторів
- Metrics – набір метрик
- Losses – набір функцій втрат (критеріїв якості)
- Built-in small datasets – вбудовані набори даних
- та інші...

Послідовність кроків для створення нейронної мережі:

- 1) Описати архітектуру мережі
- 2) Описати вхідні значення
- 3) Описати умови навчання (Compilation)
- 4) Навчити (кілька разів?)
- 5) Оцінити якість моделі
- 6) Застосувати

Приклад створення нейромережі

Розглянемо приклад. Необхідно створити нейронну мережу для класифікації мобільних телефонів за ціновою категорією (всього є 4 класи: 0 – найдешевші моделі, 1 – більш дорогі ... 3 – найбільш дорогі).

Перш за все, потрібно імпортувати необхідні модулі.

```
# Для роботи з даними
import pandas as pd
import matplotlib.pyplot as plt
import numpy as np
from sklearn.model_selection import train_test_split

# Для роботи з Keras
from tensorflow.keras.models import Sequential # модель прямого розповсюдження
from tensorflow.keras.layers import Dense # повнозв'язні прошарки
```

Наступний код для оптимізації відеокарт (щоб працювало без помилок).

```
import tensorflow as tf
physical_devices = tf.config.list_physical_devices('GPU')
tf.config.experimental.set_memory_growth(physical_devices[0], True)
```

Завантажуємо навчальні дані.

```
data = pd.read_csv("../phones_price.csv")
data.head()

>>

   battery_power  blue  clock_speed  dual_sim  fc  four_g  int_memory  m_dep  \
0            842     0          2.2         0   1       0           7    0.6
1           1021     1          0.5         1   0       1          53    0.7
2            563     1          0.5         1   2       1          41    0.9
3            615     1          2.5         0   0       0          10    0.8
4           1821     1          1.2         0  13       1          44    0.6

   mobile_wt  n_cores  ...  px_height  px_width   ram  sc_h  sc_w  talk_time  \
0        188        2  ...         20       756  2549     9     7         19
1        136        3  ...        905      1988  2631    17     3          7
2        145        5  ...       1263      1716  2603    11     2          9
3        131        6  ...       1216      1786  2769    16     8         11
4        141        2  ...       1208      1212  1411     8     2         15

   three_g  touch_screen  wifi  price_range
```

```
0          0             0     1             1
1          1             1     0             2
2          1             1     0             2
3          1             0     0             2
4          1             1     0             1

[5 rows x 21 columns]
```

Перевіряємо, наскільки збалансована кількість зразків кожного класу. В ідеальному випадку, доля зразків кожного класу має бути приблизно однаковою.

```
data['price_range'].value_counts(normalize=True)

0    0.25
1    0.25
2    0.25
3    0.25
```

Як бачимо, у нас 21 стовпець даних. З них перші 20 - змінні X, останній стовпець – клас телефону (цінова категорія), Y.

Запишемо стовпці з характеристиками об'єктів до змінної X.

```
X = data.drop('price_range', axis = 1)
X

>>
```

```
      battery_power  blue  clock_speed  dual_sim  fc  four_g  int_memory  \
0               842     0          2.2         0   1       0           7
1              1021     1          0.5         1   0       1          53
2               563     1          0.5         1   2       1          41
...             ...   ...          ...       ...  ..     ...         ...
1997           1911     0          0.9         1   1       1          36
1998           1512     0          0.9         0   4       1          46
1999            510     1          2.0         1   5       1          45

      m_dep  mobile_wt  n_cores  pc  px_height  px_width   ram  sc_h  sc_w  \
0       0.6        188        2   2         20       756  2549     9     7
1       0.7        136        3   6        905      1988  2631    17     3
2       0.9        145        5   6       1263      1716  2603    11     2
...     ...        ...      ...  ..        ...       ...   ...   ...   ...
1997    0.7        108        8   3        868      1632  3057     9     1
```

```
1998    0.1        145        5   5        336       670   869    18    10
1999    0.9        168        6  16        483       754  3919    19     4

      talk_time  three_g  touch_screen  wifi
0            19        0             0     1
1             7        1             1     0
2             9        1             1     0
...         ...      ...           ...   ...
1997          5        1             1     0
1998         19        1             1     1
1999          2        1             1     1

[2000 rows x 20 columns]
```

А також створимо змінну з правильними відповідям Y. Для цього переведемо стовпець *price_range* з початкової таблиці до формату **one hot encoding**.

```
Y = pd.get_dummies(data.price_range, prefix='Price range')
Y

>>

      Price range_0  Price range_1  Price range_2  Price range_3
0                 0              1              0              0
1                 0              0              1              0
2                 0              0              1              0
3                 0              0              1              0
4                 0              1              0              0
...             ...            ...            ...            ...
1995              1              0              0              0
1996              0              0              1              0
1997              0              0              0              1
1998              1              0              0              0
1999              0              0              0              1

[2000 rows x 4 columns]
```

Розділимо отриманий набір даних на навчальну і тестову множини.

```
X_train, X_test, Y_train, Y_test = train_test_split(X, Y, test_size=0.15)
```

Виконаємо стандартизацію значень змінних X, привівши кожен стовпець до нульового середнього значення та одиничної дисперсії.

```
mean = X_train.mean(axis=0)
std = X_train.std(axis=0)

X_train -= mean
X_train /= std
X_test -= mean
X_test /= std
```

Створюємо послідовну модель:

```
model = Sequential()
```

Додаємо перший прихований прошарок *Dense*. В якості аргументів спочатку вказуємо кількість нейронів в прихованому прошарку, потім розмірність вхідного вектору (скільки характеристик X), а також активаційну функцію. В Keras доступні такі активаційні функції:

- relu
- sigmoid
- softmax
- softplus
- softsign
- tanh
- selu
- elu
- exponential

Використовуємо *relu*.

```
model.add(Dense(10, input_dim=X_train.shape[1], activation="relu"))
```

Додаємо другий прихований прошарок. Вказуємо тільки кількість нейронів у ньому та активаційну функцію *relu*.

```
model.add(Dense(5, activation="relu"))
```

Додаємо вихідний прошарок. Кількість нейронів у ньому має відповідати кількості класів (якщо використовується формат one hot encoding). Активаційна функція для задачі класифікації – *softmax*.

```
model.add(Dense(4, activation="softmax"))
```

Описуємо умови навчання. Обов'язково потрібно задати оптимізатор, критерій якості (функцію помилки, яку будемо мінімізувати) та метрику (показник, за яким зручно оцінювати якість навчання).

В Keras доступні оптимізатори:

- SGD
- RMSprop
- Adam
- Adadelta
- Adagrad
- Adamax
- Nadam
- Ftrl

Зараз найчастіше використовується *Adam*.

В якості функцій втрат в Keras доступні різні варіанти, але для задач класифікації використовуємо такі:

- *binary_crossentropy* - для бінарної класифікації (коли всього два класи, закодовані як 0 та 1)
- *categorical_crossentropy* - для категоріальної класифікації (формат кодування one hot encoding)

Метрики, які найчастіше використовуються для класифікації:

- *Accuracy* (доля правильних відповідей серед всіх зразків)
- *Precision* (як багато з обраних елементів дійсно є правильними?)

- *Recall* (як багато елементів було обрано серед загальної кількості елементів, які потрібно було обрати)

Обираємо метрику *accuracy*.

```
model.compile(optimizer='adam', loss='categorical_crossentropy',
    metrics=['accuracy'])
```

Навчаємо модель. Лог навчання запишемо до змінної *history*. Необхідно обов'язково вказати наступні аргументи: навчальний набір даних (*X_train*), правильні відповіді для цього набору (*Y_train*), кількість епох *epochs*, обсяг вибірки валідації *validation_split* (по відношенню до тестової вибірки). Також вкажемо розмір батчу *batch_size* та режим відображення *verbose=2*, щоб виводити повну інформацію про навчання.

```
history = model.fit(X_train, Y_train, epochs=50,
validation_split=0.15, batch_size=16, verbose=2)

>>

Epoch 1/50
91/91 - 0s - loss: 1.4100 - accuracy: 0.2512 - val_loss: 1.4019 -
val_accuracy: 0.2118
Epoch 2/50
91/91 - 0s - loss: 1.3870 - accuracy: 0.2893 - val_loss: 1.3944 -
val_accuracy: 0.2196
Epoch 3/50
91/91 - 0s - loss: 1.3742 - accuracy: 0.3190 - val_loss: 1.3827 -
val_accuracy: 0.2392

…

Epoch 48/50
91/91 - 0s - loss: 0.0863 - accuracy: 0.9785 - val_loss: 0.1605 -
val_accuracy: 0.9333
Epoch 49/50
91/91 - 0s - loss: 0.0853 - accuracy: 0.9758 - val_loss: 0.1527 -
val_accuracy: 0.9373

Epoch 50/50
91/91 - 0s - loss: 0.0834 - accuracy: 0.9827 - val_loss: 0.1499 -
val_accuracy: 0.9451
```

Оцінюємо якість моделі на тестовій множині. Запишемо результат до змінних *loss* та *accuracy*.

```
loss, accuracy = model.evaluate(X_test, Y_test, verbose=0)
print(loss, accuracy)

>>

0.18817807734012604 0.9200000166893005
```

Виводимо графік з історією навчання (рис. 2.1) для оцінки ефективності навчання.

```
plt.plot(history.history['accuracy'])
plt.plot(history.history['val_accuracy'])
plt.title('Model accuracy')
plt.ylabel('accuracy')
plt.xlabel('Epoch')
plt.legend(['Train', 'Val'], loc='upper left')
plt.show()

>>
```

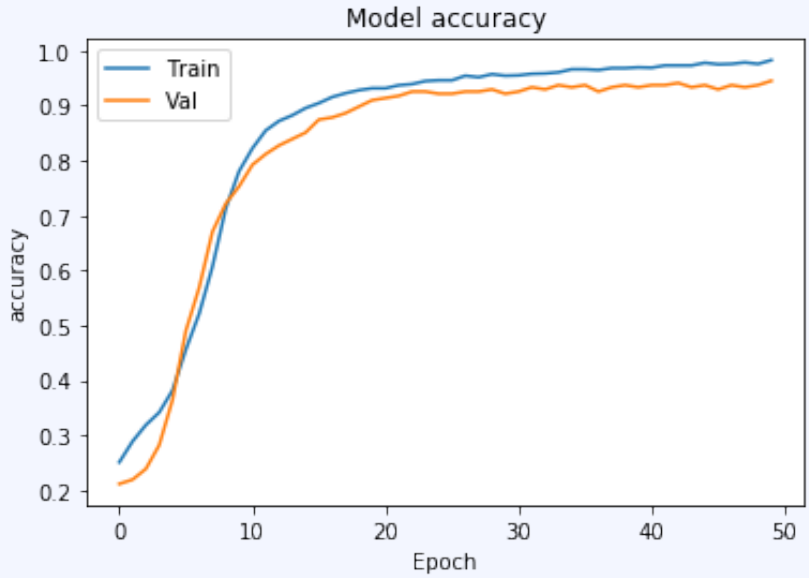

Рис. 2.1. Якість навчання для кожної епохи:
навчальна множина; валідаційна множина

Використовуємо модель для класифікації одного зразка з тестової вибірки.

```
# Зразок треба подати як список, тому робимо зріз
sample = X_test[0:1]
```

```
prediction = model.predict(sample)
print(prediction)

>>

[[4.3346232e-30 3.1874181e-24 1.7326867e-05 9.9998271e-01]]
```

Оформимо красиво:

```
score = np.max(prediction)
prediction = np.argmax(prediction)

print(f'Передбачено: {prediction} з достовірністю {score*100:.2f}%',
f'Повинно бути: {np.argmax(Y_test[0:1])}', sep='\n')

Передбачено: 3 з достовірністю 100.00%
Повинно бути: 3
```

Збережемо модель.

```
model.save('mobile_price.h5')
```

2.2. Оптимізація нейронних мереж

Часто буває необхідно оптимізувати архітектуру та інші параметри створених нейронних мереж. Завдяки вдалому підбору зовнішніх параметрів мережі можна покращити якість її роботи. Серед підходів, які найчастіше використовуються для оптимізації нейромережевих моделей, можна виділити наступні:

- Підготовка навчальної вибірки
- Дострокова зупинка навчання (early stopping)
- Оптимізація архітектури
- Нормалізація вихідних даних окремих прошарків мережі (Batch normalization)
- Регуляризація нейронів (Dropout)
- Регуляризація ваг (weight regularizers)

- Підбір оптимальних критеріїв якості та метрик
- Підбір характеристик оптимізаторів
- Підбір характеристик ініціалізації ваг (weight initializers)

Підготовка навчальної вибірки

Розглянемо приклад підготовки даних. Необхідно створити нейронну мережу для класифікації деяких осіб за рівнем доходу. Класів всього два: дохід більше 50 тис. у.о. (income_>50K == 1) та менше 50 тис. у.о. (income_>50K == 0). Для кожної особи є набір характеристик, за якими пропонується визначити рівень доходів (більше 50 тис. або менше). Всі особливості змінних у даних необхідно врахувати у подальшому аналізі.

Перш за все, імпортуємо необхідні модулі.

```
import pandas as pd
import matplotlib.pyplot as plt
import numpy as np
from sklearn.model_selection import train_test_split
from keras.models import Sequential
from keras.layers import Dense
```

Наступний код для оптимізації відеокарт (щоб працювало без помилок)

```
import tensorflow as tf
physical_devices = tf.config.list_physical_devices('GPU')
tf.config.experimental.set_memory_growth(physical_devices[0], True)
```

Завантажуємо дані та переглянемо заголовок таблиці.

```
data = pd.read_csv("../income.csv")
data.head()

>>

   age  workclass  fnlwgt     education  educational-num      marital-status  \
0   67    Private  366425     Doctorate               16            Divorced
1   17    Private  244602          12th                8       Never-married
2   31    Private  174201     Bachelors               13  Married-civ-spouse
3   58  State-gov  110199       7th-8th                4  Married-civ-spouse
4   25  State-gov  149248  Some-college               10       Never-married
```

```
         occupation   relationship   race gender  capital-gain  capital-loss  \
0   Exec-managerial  Not-in-family  White   Male         99999             0
1     Other-service      Own-child  White   Male             0             0
2   Exec-managerial        Husband  White   Male             0             0
3  Transport-moving        Husband  White   Male             0             0
4     Other-service  Not-in-family  Black   Male             0             0

   hours-per-week native-country  income_>50K
0              60  United-States            1
1              15  United-States            0
2              40  United-States            1
3              40  United-States            0
4              40  United-States            0
```

Як бачимо, характеристики об'єктів в наборі даних можуть бути як числовими (загальний капітал, кількість робочих годин за тиждень, рівень витрат тощо), так і рядковими (професія, сімейний стан, стать тощо).

Переглянемо загальну інформацію про набір даних.

```
data.info()

>>

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 43957 entries, 0 to 43956
Data columns (total 15 columns):
 #   Column           Non-Null Count  Dtype
---  ------           --------------  -----
 0   age              43957 non-null  int64
 1   workclass        41459 non-null  object
 2   fnlwgt           43957 non-null  int64
 3   education        43957 non-null  object
 4   educational-num  43957 non-null  int64
 5   marital-status   43957 non-null  object
 6   occupation       41451 non-null  object
 7   relationship     43957 non-null  object
 8   race             43957 non-null  object
 9   gender           43957 non-null  object
 10  capital-gain     43957 non-null  int64
 11  capital-loss     43957 non-null  int64
 12  hours-per-week   43957 non-null  int64
 13  native-country   43194 non-null  object
 14  income_>50K      43957 non-null  int64
dtypes: int64(7), object(8)
memory usage: 5.0+ MB
```

Бачимо, що всього в наборі є дані про 43957 об'єктів (осіб). Окрім того, якщо подивимось уважно, то деякі об'єкти мають пропущені характеристики (число ненульових записів в стовпці не співпадає з загальною кількістю об'єктів).

Відповідно, дізнаємось кількість пропущених значень для кожної характеристики.

```
data.isnull().sum()

>>

age                  0
workclass         2498
fnlwgt               0
education            0
educational-num      0
marital-status       0
occupation        2506
relationship         0
race                 0
gender               0
capital-gain         0
capital-loss         0
hours-per-week       0
native-country     763
income_>50K          0
```

Як бачимо, пропущені значення є в стопцях *workclass*, *occupation* та *native-country*. Оскільки кожен рядок таблиці являє собою окрему людину, ми не можемо просто взяти і замінити пропущені дані нулями або середніми значеннями. Тому єдиний варіант - прибрати з таблиці записи із пропущеними даними.

```
clear_data = data.dropna(subset=["workclass", "occupation", "native-country"])
clear_data.isnull().sum()

>>

age               0
workclass         0
```

```
fnlwgt             0
education          0
educational-num    0
marital-status     0
occupation         0
relationship       0
race               0
gender             0
capital-gain       0
capital-loss       0
hours-per-week     0
native-country     0
income_>50K        0
dtype: int64
```

Тепер пропущених даних немає - можна продовжувати роботу.

Перевіряємо, наскільки збалансована кількість зразків кожного класу. В ідеальному випадку, доля зразків кожного класу має бути приблизно однаковою.

```
clear_data['income_>50K'].value_counts(normalize=True)

>>

0    0.752204
1    0.247796
```

Як бачимо, кількість об'єктів кожного класу незбалансована. Це може призвести до того, що мережа під час навчання значно більше "уваги" приділятиме об'єктам того класу, зразків якого більше. За такої незбалансованості навіть може виникнути ситуація, коли до навчальної вибірки не потрапить жодного зразка класу, об'єктів якого менше. З цим треба щось робити.

Балансування вибірки

Існують різні підходи до виправлення балансу між класами. Наприклад, можна ввести так звану "вагу класу" - коефіцієнти для кожного класу, які визначатимуть ціну помилки. Ціна помилки для класу, зразків якого в

навчальних даних менше, буде більшою. Відповідно, такі зразки будуть сильніше впливати на критерій якості, що змусить мережу більше уваги приділяти саме цим зразкам. Однак, це призведе до розширення діапазону значень функції помилки. Деякі оптимізатори, величина кроку яких залежить від величини градієнту (наприклад, стандартний SGD), можуть спрацювати некоректно.

Детальніше з використанням зважених класів можна ознайомитись за посиланням:

- *https://www.tensorflow.org/tutorials/structured_data/imbalanced_data#calculate_class_weights*

У подальшому ми будемо використовувати більш прості і очевидні підходи, такі як:

- штучне збільшення кількості зразків (oversampling) класу, об'єктів якого менше у вибірці;
- штучне зменшення (undersampling) кількості зразків класу, об'єктів якого більше у вибірці.

Коли який підхід використовувати?

- Якщо загальна кількість зразків "пригніченого" класу невелика (до 200-300), то використовуємо oversampling - копіюємо існуючі зразки стільки разів, скільки потрібно для зрівняння з "домінуючим" класом.
- Якщо кількість зразків "пригніченого" класу достатня (від 300 і більше), можна видалити потрібну кількість випадкових об'єктів "домінуючого" класу для виправлення балансу.

Подивимось, скільки у нас зразків кожного класу в абсолютній величині.

```
clear_data['income_>50K'].value_counts()
>>
```

```
0    30635
1    10092
```

Зразків класу 1 в три рази менше, ніж класу 0, але достатньо для застосування підходу undersampling. Зробимо це.

Створимо два набори даних (по одному для кожного класу). В перший набір запишемо лише зразки класу 0, в другий - класу 1. Під час формування набору зразків класу 0 вкажемо, що з початкового набору необхідно взяти випадкові 10500 об'єктів, що приблизно буде дорівнювати кількості зразків у класі 1. Потім об'єднаємо ці два набори в один.

```
# Undersampling
class0 = clear_data[clear_data['income_>50K']==0].sample(n=10500)
class1 = clear_data[clear_data['income_>50K']==1]

balanced_data = pd.concat([class0,class1])
balanced_data['income_>50K'].value_counts(normalize=True)

>>

0    0.509907
1    0.490093
```

Тепер кількість зразків в обох класах збалансована.

Якби ми використовували підхід oversampling, потрібно було б виконати аналогічні операції, але копіювати набір зразків класу 1 три рази.

Приклад:

```
# Oversampling
'''
class0 = clear_data[clear_data['income_>50K']==0]
class1 = clear_data[clear_data['income_>50K']==1]
class1 = pd.concat([class1]*3)

balanced_data = pd.concat([class0,class1])
balanced_data['income_>50K'].value_counts(normalize=True)
'''

>>
```

```
0    0.502947
1    0.497053
```

Факторизація

Як ми вже з'ясували, в наборі даних деякі змінні представлені у вигляді рядків. Подивимось знову на заголовок таблиці.

```
balanced_data.head()

>>

       age         workclass  fnlwgt   education  educational-num  \
224     60           Private  167670   Bachelors               13
9419    59           Private  113838   Bachelors               13
36762   43           Private  233851   Bachelors               13
23171   27  Self-emp-not-inc  334132  Assoc-acdm               12
16259   34           Private  299383     HS-grad                9

          marital-status      occupation   relationship   race  gender  \
224    Married-civ-spouse  Prof-specialty        Husband  White    Male
9419             Widowed  Prof-specialty  Not-in-family  White  Female
36762           Divorced    Adm-clerical  Not-in-family  White  Female
23171      Never-married  Prof-specialty  Not-in-family  White  Female
16259      Never-married    Craft-repair  Not-in-family  Black    Male

       capital-gain  capital-loss  hours-per-week native-country  income_>50K
224               0             0              35  United-States            0
9419           4650             0              37  United-States            0
36762             0             0              40  United-States            0
23171             0             0              78  United-States            0
16259             0             0              40  United-States            0
```

Щоб перетворити рядкові дані на числові, використовується операція **факторизації**. Факторизація замінює однакові слова або словосполучення відповідними чисельними значеннями. Таким чином, характеристика об'єкту стає *факт ором*, який може бути врахованим математично.

В Pandas з цією метою використовується функція *factorize()*, яку необхідно застосувати для кожного стовпця з текстовими змінними. В нашому випадку, факторизувати необхідно дані у стовпцях *workclass, education, marital-status, occupation, relationship, race, gender, native-country*. Зробимо це за допомогою наступного коду.

```
to_factor = ['workclass', 'education', 'marital-status', 'occupation',
'relationship', 'race', 'gender', 'native-country']

factor_data = balanced_data.copy()
factor_data[to_factor] = factor_data[to_factor].apply(lambda col:
pd.factorize(col, sort=True)[0])
factor_data.head()

>>
```

	age	workclass	fnlwgt	education	educational-num	marital-status	\
224	60	2	167670	9	13	2	
9419	59	2	113838	9	13	6	
36762	43	2	233851	9	13	0	
23171	27	4	334132	7	12	4	
16259	34	2	299383	11	9	4	

	occupation	relationship	race	gender	capital-gain	capital-loss	\
224	9	0	4	1	0	0	
9419	9	1	4	0	4650	0	
36762	0	1	4	0	0	0	
23171	9	1	4	0	0	0	
16259	2	1	2	1	0	0	

	hours-per-week	native-country	income_>50K
224	35	37	0
9419	37	37	0
36762	40	37	0
23171	78	37	0
16259	40	37	0

Однак, якщо ми подивимось уважніше, в стовпці *educational-num* вже містяться факторизовані дані про освіту особи. Відповідно, стовпець *educational-num* та факторизований нами стовпець *education* по суті дублюють один одного. Іншими словами, вони є **колінеарними**. Тому один із цих стовпців можна взагалі прибрати з даних.

```
final_data = factor_data.drop('education', axis = 1)
final_data.head()

>>
```

	age	workclass	fnlwgt	educational-num	marital-status	occupation	\
224	60	2	167670	13	2	9	
9419	59	2	113838	13	6	9	
36762	43	2	233851	13	0	0	

```
23171   27          4  334132              12               4           9
16259   34          2  299383               9               4           2

       relationship  race  gender  capital-gain  capital-loss  hours-per-week  \
224               0     4       1             0             0              35
9419              1     4       0          4650             0              37
36762             1     4       0             0             0              40
23171             1     4       0             0             0              78
16259             1     2       1             0             0              40

       native-country  income_>50K
224                37            0
9419               37            0
36762              37            0
23171              37            0
16259              37            0
```

Класи збалансовані, текстові змінні факторизовані, пропущені значення та колінеарні змінні видалені. Тепер можна створити і навчити нейронну мережу за стандартною процедурою.

```
Y = pd.get_dummies(final_data['income_>50K'], prefix='Class')
X = final_data.drop(['income_>50K'], axis = 1)

X_train, X_test, Y_train, Y_test = train_test_split(X, Y,
                                                    test_size=0.15)



mean = X_train.mean(axis=0)
std = X_train.std(axis=0)

X_train -= mean
X_train /= std
X_test -= mean
X_test /= std

model = Sequential()
model.add(Dense(10, input_dim=X_train.shape[1], activation="relu"))
model.add(Dense(2, activation="softmax"))
model.compile(optimizer='adam', loss='categorical_crossentropy',
              metrics=['accuracy'])

history = model.fit(X_train, Y_train, epochs=30,
                    validation_split=0.15, batch_size=20)

loss, accuracy = model.evaluate(X_test, Y_test, verbose=0)
print(loss, accuracy)
```

```
>>

Train on 14877 samples, validate on 2626 samples
Epoch 1/30
14877/14877 [==============================] - 3s 182us/step - loss:
0.5293 - accuracy: 0.7364 - val_loss: 0.4578 - val_accuracy: 0.7768
Epoch 2/30
14877/14877 [==============================] - 2s 155us/step - loss:
0.4382 - accuracy: 0.7872 - val_loss: 0.4291 - val_accuracy: 0.8012
Epoch 3/30
14877/14877 [==============================] - 2s 145us/step - loss:
0.4148 - accuracy: 0.8049 - val_loss: 0.4134 - val_accuracy: 0.8111

…

Epoch 28/30
14877/14877 [==============================] - 2s 142us/step - loss:
0.3874 - accuracy: 0.8182 - val_loss: 0.4002 - val_accuracy: 0.8199
Epoch 29/30
14877/14877 [==============================] - 2s 147us/step - loss:
0.3875 - accuracy: 0.8190 - val_loss: 0.3992 - val_accuracy: 0.8161
Epoch 30/30
14877/14877 [==============================] - 2s 146us/step - loss:
0.3876 - accuracy: 0.8182 - val_loss: 0.3986 - val_accuracy: 0.8184
0.3751888842828145 0.827128529548645
```

Регуляризація

Регуляризація – комплекс дій, спрямованих на уникнення перенавчання мережі. У випадку використання регуляризації модель навмисно спрощують під час навчання або обмежують її параметри, накладаючи деякі штрафи за перенавчання. Це дозволяє покращити якість навчання та пришвидшити збіжність оптимізатора. Як наслідок, мережа буде швидше навчатись та більш якісно апроксимувати дані. Особливо помітним вплив регуляризації є у навчанні глибинний мереж з десятками і сотнями прошарків, тоді як більш поверхневі моделі самі по собі є достатньо простими для уникнення перенавчання. Однак, іноді все ж вдається на декілька відсотків підвищити показники якості роботи нейромережі.

Для розгляду різноманітних підходів до регуляризації, повернемось до набору даних з класифікацією мобільних телефонів за ціновими діапазонами.

```
data = pd.read_csv("../phones_price.csv")
data.head()

>>

   battery_power  blue  clock_speed  dual_sim  fc  four_g  int_memory  m_dep  \
0            842     0          2.2         0   1       0           7    0.6
1           1021     1          0.5         1   0       1          53    0.7
2            563     1          0.5         1   2       1          41    0.9
3            615     1          2.5         0   0       0          10    0.8
4           1821     1          1.2         0  13       1          44    0.6

   mobile_wt  n_cores  ...  px_height  px_width   ram  sc_h  sc_w  talk_time  \
0        188        2  ...         20       756  2549     9     7         19
1        136        3  ...        905      1988  2631    17     3          7
2        145        5  ...       1263      1716  2603    11     2          9
3        131        6  ...       1216      1786  2769    16     8         11
4        141        2  ...       1208      1212  1411     8     2         15

   three_g  touch_screen  wifi  price_range
0        0             0     1            1
1        1             1     0            2
2        1             1     0            2
3        1             0     0            2
4        1             1     0            1

[5 rows x 21 columns]
```

```
X = data.drop('price_range', axis = 1)
Y = pd.get_dummies(data.price_range, prefix='Price range')

X_train, X_test, Y_train, Y_test = train_test_split(X, Y,
                                                    test_size=0.15)


mean = X_train.mean(axis=0)
std = X_train.std(axis=0)

X_train -= mean
X_train /= std
X_test -= mean
X_test /= std
```

```
model = Sequential()
model.add(Dense(10, input_dim=X_train.shape[1], activation="relu"))
model.add(Dense(5, activation="relu"))
model.add(Dense(4, activation="softmax"))

model.compile(optimizer='adam', loss='categorical_crossentropy',
              metrics=['accuracy'])

history = model.fit(X_train, Y_train, epochs=50,
                    validation_split=0.15, batch_size=16)
loss, accuracy = model.evaluate(X_test, Y_test, verbose=0)
print(loss, accuracy)

>>


Train on 1445 samples, validate on 255 samples
Epoch 1/50
1445/1445 [==============================] - 0s 257us/step - loss:
1.3842 - accuracy: 0.2803 - val_loss: 1.3206 - val_accuracy: 0.3529
Epoch 2/50
1445/1445 [==============================] - 0s 185us/step - loss:
1.3162 - accuracy: 0.3315 - val_loss: 1.2721 - val_accuracy: 0.3882
Epoch 3/50
1445/1445 [==============================] - 0s 185us/step - loss:
1.2525 - accuracy: 0.4249 - val_loss: 1.2161 - val_accuracy: 0.4627
...

Epoch 48/50
1445/1445 [==============================] - 0s 183us/step - loss:
0.0749 - accuracy: 0.9827 - val_loss: 0.1879 - val_accuracy: 0.9176
Epoch 49/50
1445/1445 [==============================] - 0s 184us/step - loss:
0.0721 - accuracy: 0.9841 - val_loss: 0.1836 - val_accuracy: 0.9216
Epoch 50/50
1445/1445 [==============================] - 0s 183us/step - loss:
0.0702 - accuracy: 0.9862 - val_loss: 0.1820 - val_accuracy: 0.9137


0.22537615448236464 0.8866666555404663
```

Виводимо графік з історією навчання (рис. 2.2) для оцінки ефективності нав чання.

```
plt.plot(history.history['accuracy'])
plt.plot(history.history['val_accuracy'])
plt.title('Model accuracy')
plt.ylabel('accuracy')
plt.xlabel('Epoch')
```

```
plt.legend(['Train', 'Val'], loc='upper left')
plt.show()

>>
```

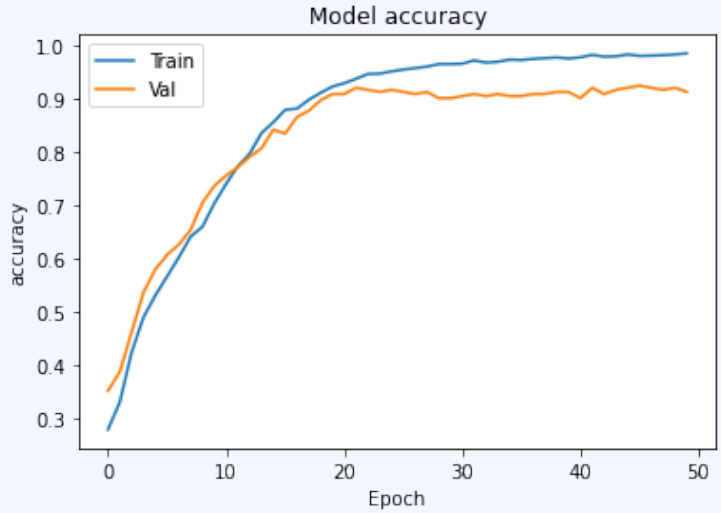

Рис. 2.2. Якість навчання для кожної епохи:
навчальна множина; валідаційна множина

Як бачимо, приблизно після 20 епохи почалося перенавчення мережі: accuracy на валідаційній множині почала знижуватись (хоча потім і відновила своє середнє значення). Accuracy на тестовій множині склала 88,6%. Відповідно, спробуємо застосувати різні підходи до регуляризації для виправлення даної ситуації і покращення якості роботи мережі.

Дострокова зупинка навчання (early stopping)

Keras дозволяє відслідковувати величину зміни критерію якості або метрики під час навчання. Якщо критерій якості не буде покращуватись декілька епох поспіль, існує можливість автоматично зупинити навчання. Це не дозволить мережі продовжувати підлаштовуватись під особливості навчальної вибірки, коли потрібна якість уже досягнута.

- Детальніше: *https://keras.io/api/callbacks/early_stopping/*

Як видно з документації, для реалізації цього методу використовується клас *EarlyStopping*. Ми повинні створити його екземпляр та вказати посилання

на цей об'єкт в якості функції зворотного виклику для метода *model.fit()*. Основні параметри *EarlyStopping*, які нам знадобляться:

- *monitor* - критерій якості або метрика, яку потрібно відслідковувати
- *patience* - кількість епох без покращення результату, після яких навчання буде зупинено.

Використаємо цей підхід. Відслідковувати будемо метрику Accuracy на валідаційній множині.

```
import tensorflow as tf
early = tf.keras.callbacks.EarlyStopping(monitor='val_accuracy',
                                         patience=5)

model2 = Sequential()
model2.add(Dense(10,input_dim=X_train.shape[1], activation="relu"))
model2.add(Dense(5, activation="relu"))
model2.add(Dense(4, activation="softmax"))

model2.compile(optimizer='adam', loss='categorical_crossentropy',
               metrics=['accuracy'])

# Використовуємо callbacks=[early]
history2 = model2.fit(X_train, Y_train, epochs=50,
           validation_split=0.15, batch_size=16, callbacks=[early])

loss, accuracy = model2.evaluate(X_test, Y_test, verbose=0)
print(loss, accuracy)

>>

Train on 1445 samples, validate on 255 samples
Epoch 1/50
1445/1445 [==============================] - 0s 255us/step - loss:
1.4545 - accuracy: 0.2740 - val_loss: 1.3515 - val_accuracy: 0.3294
Epoch 2/50
1445/1445 [==============================] - 0s 187us/step - loss:
1.3664 - accuracy: 0.3370 - val_loss: 1.3036 - val_accuracy: 0.3490
Epoch 3/50
1445/1445 [==============================] - 0s 180us/step - loss:
1.3032 - accuracy: 0.3882 - val_loss: 1.2536 - val_accuracy: 0.3647
Epoch 4/50
...
```

```
Epoch 27/50
1445/1445 [==============================] - 0s 180us/step - loss:
0.1442 - accuracy: 0.9599 - val_loss: 0.2200 - val_accuracy: 0.9059
Epoch 28/50
1445/1445 [==============================] - 0s 181us/step - loss:
0.1379 - accuracy: 0.9640 - val_loss: 0.2132 - val_accuracy: 0.9059
Epoch 29/50
1445/1445 [==============================] - 0s 177us/step - loss:
0.1307 - accuracy: 0.9654 - val_loss: 0.2069 - val_accuracy: 0.9098


0.21375454366207122 0.9133333563804626
```

Як бачимо, спрацював механізм early stopping, і навчання автоматично перервалось на 29 епосі. На тестовій множині ми отримали долю правильних відповідей 91,3%. Подивимось на графік навчання (рис. 2.3). Перенавчання немає.

```
plt.plot(history2.history['accuracy'])
plt.plot(history2.history['val_accuracy'])
plt.title('Model accuracy')
plt.ylabel('accuracy')
plt.xlabel('Epoch')
plt.legend(['Train', 'Val'], loc='upper left')
plt.show()
>>
```

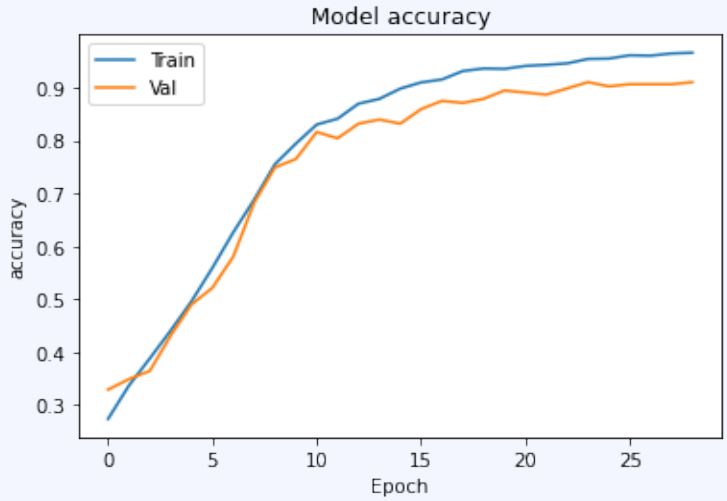

Рис. 2.3. Якість навчання для кожної епохи при застосуванні механізму дострокової зупинки навчання:

навчальна множина; валідаційна множина

Оптимізація архітектури

Іноді початково обрана архітектура мережі є занадто складною, що також може призводити до перенавчання. В такому випадку, доцільно зменшити складність мережі, відповідним чином змінивши кількість прошарків або нейронів у них.

Видалимо другий прихований прошарок з нашої мережі, а також зменшимо кількість нейронів у першому до 6. Цього буде достатньо для вирішення поставленого завдання.

```
model3 = Sequential()
model3.add(Dense(6, input_dim=X_train.shape[1], activation="relu"))
model3.add(Dense(4, activation="softmax"))

model3.compile(optimizer='adam', loss='categorical_crossentropy',
               metrics=['accuracy'])

history3 = model3.fit(X_train, Y_train, epochs=50,
                      validation_split=0.15, batch_size=16)

loss, accuracy = model3.evaluate(X_test, Y_test, verbose=0)
print(loss, accuracy)

>>

Train on 1445 samples, validate on 255 samples
Epoch 1/50
1445/1445 [==============================] - 0s 237us/step - loss:
1.5003 - accuracy: 0.2948 - val_loss: 1.5053 - val_accuracy: 0.2667
Epoch 2/50
1445/1445 [==============================] - 0s 178us/step - loss:
1.4122 - accuracy: 0.3260 - val_loss: 1.4386 - val_accuracy: 0.3020
Epoch 3/50
1445/1445 [==============================] - 0s 165us/step - loss:
1.3521 - accuracy: 0.3488 - val_loss: 1.3864 - val_accuracy: 0.3412
...

Epoch 48/50
1445/1445 [==============================] - 0s 156us/step - loss:
0.1550 - accuracy: 0.9744 - val_loss: 0.1934 - val_accuracy: 0.9647
Epoch 49/50
1445/1445 [==============================] - 0s 156us/step - loss:
0.1515 - accuracy: 0.9723 - val_loss: 0.1897 - val_accuracy: 0.9647
```

```
Epoch 50/50
1445/1445 [==============================] - 0s 157us/step - loss:
0.1475 - accuracy: 0.9730 - val_loss: 0.1868 - val_accuracy: 0.9569
0.17638297021389007 0.949999988079071
```

Виводимо графік з історією навчання (рис. 2.4) для оцінки ефективності навчання.

```
plt.plot(history3.history['accuracy'])
plt.plot(history3.history['val_accuracy'])
plt.title('Model accuracy')
plt.ylabel('accuracy')
plt.xlabel('Epoch')
plt.legend(['Train', 'Val'], loc='upper left')
plt.show()

>>
```

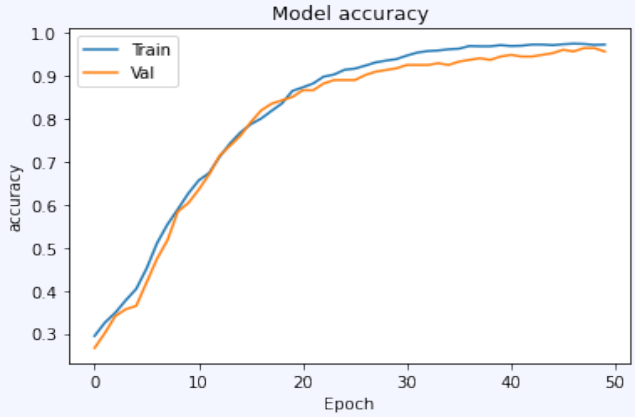

Рис. 2.4. Якість навчання для кожної епохи при оптимізації архітектури:

навчальна множина; валідаційна множина

Як бачимо, для навчання мережі знадобилося більше ітерацій, але водночас якість суттєво зросла до значення accuracy майже 94,5% на тестовій множині. Перенавчання немає.

Batch normalization

Використання прошарку Batch normalization дозволяє пришвидшити навчання та полегшити мережі пошук необхідних ознак. Математичне обґрунтування необхідності використання такого прошарку існує, але його

ефективність на практиці часто ставиться під сумнів. Втім, Batch normalization все одно застосовують.

- Документація в Keras:

https://keras.io/api/layers/normalization_layers/batch_normalization/

Прошарок Batch normalization нормалізує вхідні дані для наступного прошарку. Для цього значення по кожному із входів прошарку стандартизуються методом приведення їх до нульового середнього та одиничної дисперсії. Для обчислення необхідних величин використовуються дані за один батч (або міні-батч).

Використаємо Batch normalization у комбінації зі спрощеною архітектурою.

```
from keras.layers import BatchNormalization

model4 = Sequential()
model4.add(Dense(6, input_dim=X_train.shape[1], activation="relu"))
model4.add(BatchNormalization())
model4.add(Dense(4, activation="softmax"))

model4.compile(optimizer='adam', loss='categorical_crossentropy',
               metrics=['accuracy'])

history4 = model4.fit(X_train, Y_train, epochs=50,
                      validation_split=0.15, batch_size=16)

loss, accuracy = model4.evaluate(X_test, Y_test, verbose=0)
print(loss, accuracy)



>>



Train on 1445 samples, validate on 255 samples
Epoch 1/50
1445/1445 [==============================] - 1s 370us/step - loss:
1.6787 - accuracy: 0.2325 - val_loss: 1.4582 - val_accuracy: 0.2980
Epoch 2/50
1445/1445 [==============================] - 0s 231us/step - loss:
1.4983 - accuracy: 0.2865 - val_loss: 1.3770 - val_accuracy: 0.3765
Epoch 3/50
```

```
1445/1445 [==============================] - 0s 228us/step - loss:
1.3761 - accuracy: 0.3315 - val_loss: 1.2973 - val_accuracy: 0.4000
...

Epoch 48/50
1445/1445 [==============================] - 0s 227us/step - loss:
0.3119 - accuracy: 0.8803 - val_loss: 0.2209 - val_accuracy: 0.9333
Epoch 49/50
1445/1445 [==============================] - 0s 232us/step - loss:
0.2911 - accuracy: 0.8858 - val_loss: 0.2117 - val_accuracy: 0.9451
Epoch 50/50
1445/1445 [==============================] - 0s 227us/step - loss:
0.3167 - accuracy: 0.8775 - val_loss: 0.2071 - val_accuracy: 0.9490
0.19396755476792654 0.9566666483879089
```

Виводимо графік з історією навчання (рис. 2.5) для оцінки ефективності навчання.

```
plt.plot(history4.history['accuracy'])
plt.plot(history4.history['val_accuracy'])
plt.title('Model accuracy')
plt.ylabel('accuracy')
plt.xlabel('Epoch')
plt.legend(['Train', 'Val'], loc='upper left')
plt.show()

>>
```

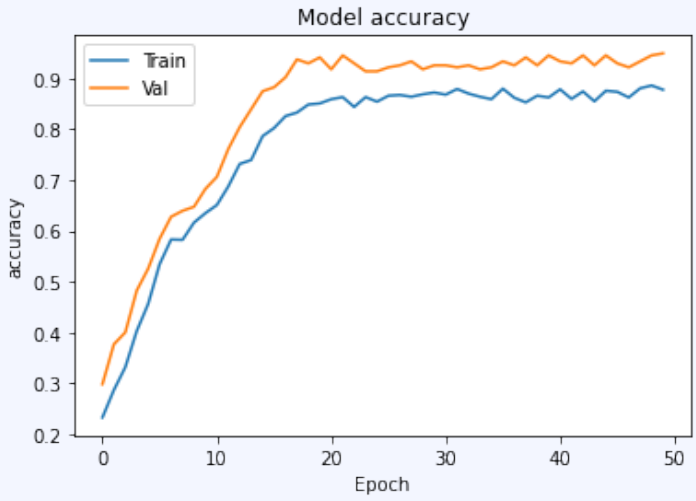

Рис. 2.5. Якість навчання для кожної епохи при застосуванні Batch normalization: навчальна множина; валідаційна множина

Значення accuracy склало 95,6% на тестовій множині. Перенавчання немає.

На графіку можна помітити цікавий ефект - точність на валідаційній множині вище, ніж на навчальній. Це нормально, і вказує на те, що під час навчання використовувалась регуляризація.

Dropout

Прошарок Dropout дозволяє уникнути перенавчання шляхом відключення певної кількості випадкових нейронів попереднього прошарку. Під "відключенням" мається на увазі заміна їх вихідних значень на 0. Таким чином, під час навчанння мережа гірше запам'ятовує конкретні навчальні зразки та краще їх узагальнює, виявляючи найбільш значущі взаємозв'язки у даних.

- Документація:
  https://keras.io/api/layers/regularization_layers/dropout/

Головним параметром прошарку Dropout є *rate* - доля нейронів, які необхідно відключити.

Dropout зазвичай застосовується у випадках, коли прошарок містить декілька десятків і більше нейронів. Однак, з навчальною метою, використаємо його для нашої моделі.

```
from keras.layers import Dropout

model5 = Sequential()
model5.add(Dense(6, input_dim=X_train.shape[1], activation="relu"))
model5.add(Dropout(0.2))
model5.add(Dense(4, activation="softmax"))

model5.compile(optimizer='adam', loss='categorical_crossentropy',
               metrics=['accuracy'])

history5 = model5.fit(X_train, Y_train, epochs=50,
                      validation_split=0.15, batch_size=16)
```

```
loss, accuracy = model5.evaluate(X_test, Y_test, verbose=0)
print(loss, accuracy)

>>


Train on 1445 samples, validate on 255 samples
Epoch 1/50
1445/1445 [==============================] - 0s 287us/step - loss:
1.6374 - accuracy: 0.2360 - val_loss: 1.5357 - val_accuracy: 0.2471
Epoch 2/50
1445/1445 [==============================] - 0s 203us/step - loss:
1.4873 - accuracy: 0.2879 - val_loss: 1.4358 - val_accuracy: 0.2706
Epoch 3/50
1445/1445 [==============================] - 0s 171us/step - loss:
1.3809 - accuracy: 0.3384 - val_loss: 1.3656 - val_accuracy: 0.3373
...

Epoch 48/50
1445/1445 [==============================] - 0s 167us/step - loss:
0.3666 - accuracy: 0.8526 - val_loss: 0.2306 - val_accuracy: 0.9490
Epoch 49/50
1445/1445 [==============================] - 0s 167us/step - loss:
0.3395 - accuracy: 0.8713 - val_loss: 0.2231 - val_accuracy: 0.9569


Epoch 50/50
1445/1445 [==============================] - 0s 167us/step - loss:
0.3757 - accuracy: 0.8457 - val_loss: 0.2222 - val_accuracy: 0.9608
0.240070184469223 0.9466666579246521
```

Виводимо графік з історією навчання (рис. 2.6) для оцінки ефективності навчання.

```
plt.plot(history5.history['accuracy'])
plt.plot(history5.history['val_accuracy'])
plt.title('Model accuracy')
plt.ylabel('accuracy')
plt.xlabel('Epoch')
plt.legend(['Train', 'Val'], loc='upper left')
plt.show()

>>
```

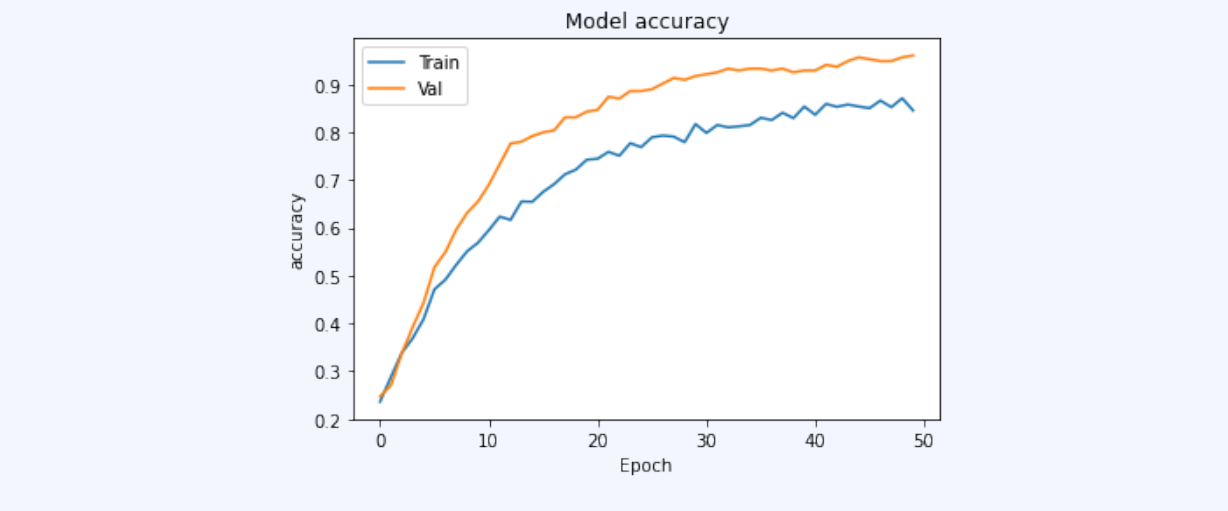

Рис. 2.6. Якість навчання для кожної епохи при застосуванні прошарку Dropout: навчальна множина; валідаційна множина

Значення accuracy склало 94,6% на тестовій множині. Перенавчання немає. На графіку знову видно ефект регуляризації - точність на валідаційній множині вище, ніж на навчальній. У випадку Dropout це легко пояснити - під час навчання деякі нейрони вимикаються, і модель працює у спрощеному вигляді. Але під час валідаціїї прошарок Dropout не використовується, тому нейронна мережа виконує задачу зі своєю повною потужністю, що призводить до зменшення помилки.

Регуляризація ваг (weight regularizers)

Встановлено, що великі значення ваг призводять до перенавчання. Це пояснюється тим, що такі значення "перетягують на себе увагу" мережі, водночас інші ознаки потенційно важливі ознаки будуть ігноруватись. Чим більші значення ваг, тим більш нелінійною буде розділяюча функція (правило), яку шукає мережа під час навчання. Тут можна провести аналогію з апроксимацією поліномом - чим вище степінь полінома, тим біль нелінійною є апроксимуюча функція.

Щоб уникнути перенавчання внаслідок завеликих значень деяких ваг, використовуються так звані регуляризаційні доданки до значення критерію якості. Основні їх види такі:

- L1-регуляризація - під час розрахунку функції втрат до її значення додається зважена сума модулів синаптичних ваг мережі.
- L2-регуляризація - те саме, але додається зважена сума квадратів ваг мережі (використовується частіше).
- L1_L2-регуляризація - комбінація перших двох.

Додавання регуляризаційного доданку до значення функції втрат грає роль штрафу. Чим більше значення цього доданку (чим вище сума ваг), тим вищим буде значення функції втрат. Відповідно, щоб це значення зменшити, оптимізатор буде зменшувати ваги.

Регуляризація може застосовуватись як до основних ваг (kernel regularizer), так і для ваг зміщень (вільних членів) мережі (bias regularizer).

- Детальніше в документації: *https://keras.io/api/layers/regularizers/*

Застосуємо L2-регуляризацію для нашої моделі. Для цього необхідний вид регуляризації вказується як аргумент під час створення прошарку.

```
model6 = Sequential()
model6.add(Dense(6, input_dim=X_train.shape[1], activation="relu",
kernel_regularizer='l2'))
model6.add(Dense(4, activation="softmax", kernel_regularizer='l2'))

model6.compile(optimizer='adam', loss='categorical_crossentropy',
               metrics=['accuracy'])

history6 = model6.fit(X_train, Y_train, epochs=50,
                      validation_split=0.15, batch_size=16)

loss, accuracy = model6.evaluate(X_test, Y_test, verbose=0)
print(loss, accuracy)

>>
```

```
Train on 1445 samples, validate on 255 samples
Epoch 1/50
1445/1445 [==============================] - 0s 243us/step - loss:
1.7506 - accuracy: 0.2201 - val_loss: 1.6760 - val_accuracy: 0.2549
Epoch 2/50
1445/1445 [==============================] - 0s 169us/step - loss:
1.6007 - accuracy: 0.2464 - val_loss: 1.5548 - val_accuracy: 0.2902
Epoch 3/50
1445/1445 [==============================] - 0s 158us/step - loss:
1.5076 - accuracy: 0.2830 - val_loss: 1.4683 - val_accuracy: 0.3333
...

Epoch 49/50
1445/1445 [==============================] - 0s 157us/step - loss:
0.5211 - accuracy: 0.9696 - val_loss: 0.5286 - val_accuracy: 0.9569
Epoch 50/50
1445/1445 [==============================] - 0s 157us/step - loss:
0.5205 - accuracy: 0.9702 - val_loss: 0.5283 - val_accuracy: 0.9608
0.5368138917287191 0.949999988079071
```

Виводимо графік з історією навчання (рис. 2.7) для оцінки ефективності навчання.

```
plt.plot(history6.history['accuracy'])
plt.plot(history6.history['val_accuracy'])
plt.title('Model accuracy')
plt.ylabel('accuracy')
plt.xlabel('Epoch')
plt.legend(['Train', 'Val'], loc='upper left')
plt.show()

>>
```

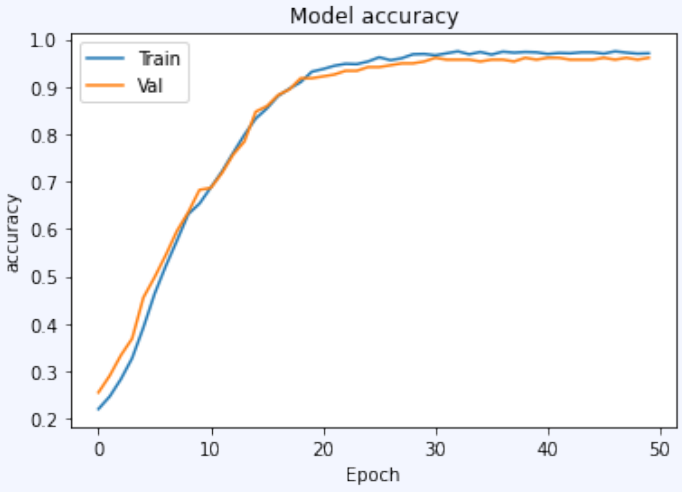

Рис. 2.7. Якість навчання для кожної епохи при застосуванні регуляризації ваг: — навчальна множина; — валідаційна множина

Значення accuracy склало 94,9% на тестовій множині. Перенавчання немає.

Підбір оптимальних критеріїв якості та метрик

Обраний критерій якості напряму впливає на якість роботи нейронної мережі. Адже саме критерій якості оптимізується в ході виконання алгоритму зворотношо поширення помилки. Деякі критерії якості призначені для вирішення лише спеціалізованих задач, деякі є універсальними. Важливо розуміти, який критерій якості потрібно використати в конкретній ситуації.

- Доступні критерії якості в Keras: *https://keras.io/api/losses/*

Всього критерії якості в Keras діляться на три великі групи:

- Probabilistic losses – функції втрат для вирішення задач класифікації.
- Regression losses – функції втрат для вирішення задач регресії.
- Hinge losses for "maximum-margin" classification – функції втрат для розділових (маржевих) класифікаторів (застосовується рідко).

Якщо вирішується задача класифікації, використовують наступні критерії якості:

- **Binary Crossentropy** – якщо в задачі два класи, закодовані як 0 та 1.
- **Categorical Crossentropy** – якщо класи закодовані у категоріальному форматі one hot encoding.

- **Sparse Categorical Crossentropy** – якщо мітки класів представлені звичайними числами (факторами), а не в категоріальному форматі One hot encoding (такий варіант не рекомендується).

Якщо вирішується задача регресії (прогнозування), то зазвичай використовують такі критерії якості:

- **Mean Squared Error** – середня сума квадратів помилок. Нестійка до рідкісних великий за модулем помилок - викидів.
- **Mean Absolute Error** – середня сума модулів помилок. Стійка до викидів, але повільніше збіжність.
- **Mean Absolute Percentage Error** – середня сума модулів помилок у відсотках (відносна помилка). Зручна для інтерпретації.
- **Mean Squared Logarithmic Error** – середня сума логарифмів квадратів помилок. Зручна якщо величина змінюється в широкому діапазоні.

На практиці людині важко інтерпретувати значення критеріїв якості. Наприклад, важко зрозуміти, що означає "значення категоріальної крос-ентропії на тестовій множині складає 0,036". Набагато більш легким для сприйняття буде "доля правильних відповідей на тестовій множині складає 98%". Саме тому разом з критеріями якості в Keras застосовуються метрики - показники ефективності нейронної мережі, які людині легше сприйняти і осмислити.

- Доступні метрики в Keras: *https://keras.io/api/metrics/*

Для задач класифікації найчастіше використовуються:

- **Accuracy** (іноді ще **BinaryAccuracy, CategoricalAccuracy**) – доля правильних відповідей. Застосовується практично завжди.

- **Precision, Recall** – метрики, засновані на підрахунку кількості помилок I та II роду. Застосовуються у випадку несбалансованих класів.
- **MeanIoU** – застосовується для визначення якості сегментації зображень.

Для задач регресії метриками можуть виступати самі критерії якості. Найчастіше використовуються:

- **Mean Absolute Error** – середня сума модулів помилок. Цю метрику легко інтерпретувати, адже одиниці її вимірювання співпадають з одиницями цілі.
- **Mean Absolute Percentage Error** – середня сума модулів помилок у відсотках.
- **RootMeanSquaredError** – аналог суми квадратів помилок, але додатково береться квадратний корінь. Знову ж таки, щоб узгодити одиниці вимірювання відповіді.

Спробуємо замінити метрику Accuracy на Categorical Accuracy у нашому прикладі. Ця метрика відрізняється від звичайної Accuracy тим, що можна додатково налаштувати деякі її параметри (але ми цього робити не будемо).

```
model7 = Sequential()
model7.add(Dense(6, input_dim=X_train.shape[1], activation="relu"))
model7.add(Dense(4, activation="softmax"))

model7.compile(optimizer='adam', loss='categorical_crossentropy',
               metrics=['categorical_accuracy'])

history7 = model7.fit(X_train, Y_train, epochs=50,
                      validation_split=0.15, batch_size=16)
loss, categ_accuracy = model7.evaluate(X_test, Y_test, verbose=0)
print(loss, categ_accuracy)

>>

Train on 1445 samples, validate on 255 samples
Epoch 1/50
```

```
1445/1445 [==============================] - 0s 226us/step - loss: 1.5554 -
categorical_accuracy: 0.2429 - val_loss: 1.3968 - val_categorical_accuracy:
0.2824
Epoch 2/50
1445/1445 [==============================] - 0s 156us/step - loss: 1.3957 -
categorical_accuracy: 0.2962 - val_loss: 1.2931 - val_categorical_accuracy:
0.3647
Epoch 3/50
1445/1445 [==============================] - 0s 152us/step - loss: 1.2891 -
categorical_accuracy: 0.3779 - val_loss: 1.2167 - val_categorical_accuracy:
0.4078
...

Epoch 48/50
1445/1445 [==============================] - 0s 151us/step - loss: 0.1697 -
categorical_accuracy: 0.9737 - val_loss: 0.2034 - val_categorical_accuracy:
0.9412
Epoch 49/50
1445/1445 [==============================] - 0s 157us/step - loss: 0.1649 -
categorical_accuracy: 0.9709 - val_loss: 0.1992 - val_categorical_accuracy:
0.9451
Epoch 50/50
1445/1445 [==============================] - 0s 151us/step - loss: 0.1607 -
categorical_accuracy: 0.9723 - val_loss: 0.1933 - val_categorical_accuracy:
0.9529
0.18950493037700653 0.95333331823349
```

Виводимо графік з історією навчання (рис. 2.8) для оцінки ефективності навчання.

```
plt.plot(history7.history['categorical_accuracy'])
plt.plot(history7.history['val_categorical_accuracy'])
plt.title('Model categorical_accuracy')
plt.ylabel('categorical_accuracy')
plt.xlabel('Epoch')
plt.legend(['Train', 'Val'], loc='upper left')
plt.show()

>>
```

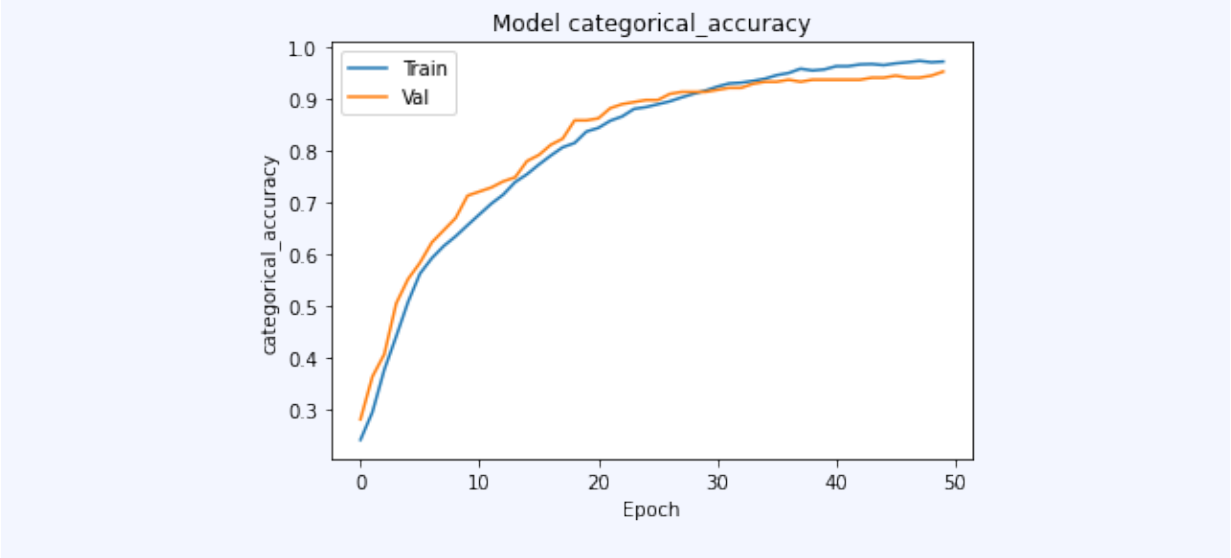

Рис. 2.8. Якість навчання для кожної епохи з метрикою Categorical Accuracy:

навчальна множина; валідаційна множина

Значення категоріальної долі правильних відповідей склало 95,3% на тестовій множині.

Підбір характеристик оптимізаторів

Не дивлячись на те, що на даний момент найбільш популярним оптимізатором є Adam, іноду буває необхідність замінити його або підлаштувати деякі параметри (наприклад, швидкість навчання learning rate). Для цього можна створити новий екземпляр класу потрібного оптимізатора, і вказати бажані атрибути замість стандартних. Можна навіть створити власний оптимізатор.

- Доступні оптимізатори в Keras: *https://keras.io/api/optimizers/*

Для того, щоб створити оптимізатор з власними налаштуваннями, необхідно в документації знайти опис відповідного класу оптимізатора та переглянути список доступних атрибутів.

- Наприклад, опис класу Adam: *https://keras.io/api/optimizers/adam/*

Використовуючи такий підхід, створимо оптимізатор Adam з нестандартними параметрами (змінимо learning rate) і застосуємо його в нашій моделі.

```
from keras import optimizers

my_adam = optimizers.Adam(learning_rate=0.01)

model8 = Sequential()
model8.add(Dense(6, input_dim=X_train.shape[1], activation="relu"))
model8.add(Dense(4, activation="softmax"))

model8.compile(optimizer=my_adam, loss='categorical_crossentropy',
               metrics=['accuracy'])

history8 = model8.fit(X_train, Y_train, epochs=50,
                      validation_split=0.15, batch_size=16)

loss, accuracy = model8.evaluate(X_test, Y_test, verbose=0)
print(loss, accuracy)
```

```
Train on 1445 samples, validate on 255 samples
Epoch 1/50
1445/1445 [==============================] - 0s 211us/step - loss:
1.2799 - accuracy: 0.4014 - val_loss: 0.8947 - val_accuracy: 0.5922
Epoch 2/50
1445/1445 [==============================] - 0s 153us/step - loss:
0.6723 - accuracy: 0.7322 - val_loss: 0.5069 - val_accuracy: 0.7961
Epoch 3/50
1445/1445 [==============================] - 0s 149us/step - loss:
0.4253 - accuracy: 0.8671 - val_loss: 0.3715 - val_accuracy: 0.8706
...

Epoch 48/50
1445/1445 [==============================] - 0s 168us/step - loss:
0.0614 - accuracy: 0.9730 - val_loss: 0.1665 - val_accuracy: 0.9333


Epoch 49/50
1445/1445 [==============================] - 0s 158us/step - loss:
0.0614 - accuracy: 0.9730 - val_loss: 0.1895 - val_accuracy: 0.9333
Epoch 50/50
1445/1445 [==============================] - 0s 163us/step - loss:
0.0753 - accuracy: 0.9696 - val_loss: 0.1548 - val_accuracy: 0.9412
0.22023165668050448 0.9266666769981384
```

Виводимо графік з історією навчання (рис. 2.9) для оцінки ефективності навчання.

```
plt.plot(history8.history['accuracy'])
plt.plot(history8.history['val_accuracy'])
plt.title('Model accuracy')
plt.ylabel('accuracy')
```

```
plt.xlabel('Epoch')
plt.legend(['Train', 'Val'], loc='upper left')
plt.show()

>>
```

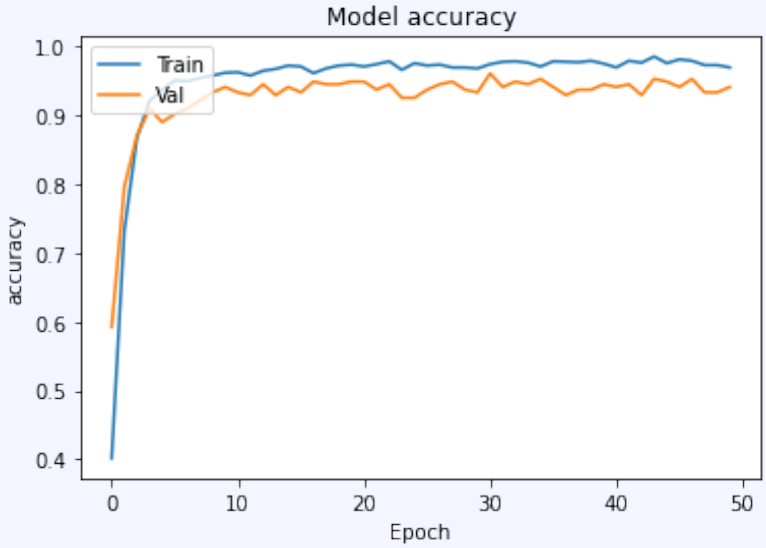

Рис. 2.9. Якість навчання для кожної епохи з модифікованим оптимізатором Adam (*learning_rate=0.01)*: навчальна множина; валідаційна множина

Як бачимо, збільшивши швидкість навчання, оптимізатор швидше знайшов мінімум. Але при цьому є ризик пропустити інший мінімум, до чого може призвести завеликий крок навчання - оптимізатор просто "перестрибне" необхідну область.

Окрім модифікацій параметрів оптимізатора Adam, можна для порівняння створити інший оптимізатор з використанням класичного методу градієнтного спуску з поправкою (моментом) Нестерова.

```
from keras import optimizers

my_SGD = optimizers.SGD(learning_rate=0.001, momentum=0.8,
                        nesterov=True)

model9 = Sequential()
model9.add(Dense(6, input_dim=X_train.shape[1], activation="relu"))
model9.add(Dense(4, activation="softmax"))

model9.compile(optimizer=my_SGD, loss='categorical_crossentropy',
```

```
                metrics=['accuracy'])

history9 = model9.fit(X_train, Y_train, epochs=100,
                      validation_split=0.15, batch_size=16)

loss, accuracy = model9.evaluate(X_test, Y_test, verbose=0)
print(loss, accuracy)

>>

Train on 1445 samples, validate on 255 samples
Epoch 1/100
1445/1445 [==============================] - 0s 176us/step - loss:
1.5448 - accuracy: 0.3149 - val_loss: 1.4357 - val_accuracy: 0.3725
Epoch 2/100
1445/1445 [==============================] - 0s 129us/step - loss:
1.4731 - accuracy: 0.3280 - val_loss: 1.3876 - val_accuracy: 0.3961
Epoch 3/100
1445/1445 [==============================] - 0s 130us/step - loss:
1.4253 - accuracy: 0.3433 - val_loss: 1.3520 - val_accuracy: 0.4078
...

Epoch 98/100
1445/1445 [==============================] - 0s 134us/step - loss:
0.2531 - accuracy: 0.9606 - val_loss: 0.2769 - val_accuracy: 0.9176
Epoch 99/100
1445/1445 [==============================] - 0s 135us/step - loss:
0.2509 - accuracy: 0.9599 - val_loss: 0.2749 - val_accuracy: 0.9216
Epoch 100/100
1445/1445 [==============================] - 0s 149us/step - loss:
0.2488 - accuracy: 0.9585 - val_loss: 0.2729 - val_accuracy: 0.9216
0.28417868455251055 0.9399999976158142
```

Виводимо графік з історією навчання (рис. 2.10) для оцінки ефективності навчання.

```
plt.plot(history9.history['accuracy'])
plt.plot(history9.history['val_accuracy'])
plt.title('Model accuracy')
plt.ylabel('accuracy')
plt.xlabel('Epoch')
plt.legend(['Train', 'Val'], loc='upper left')
plt.show()

>>
```

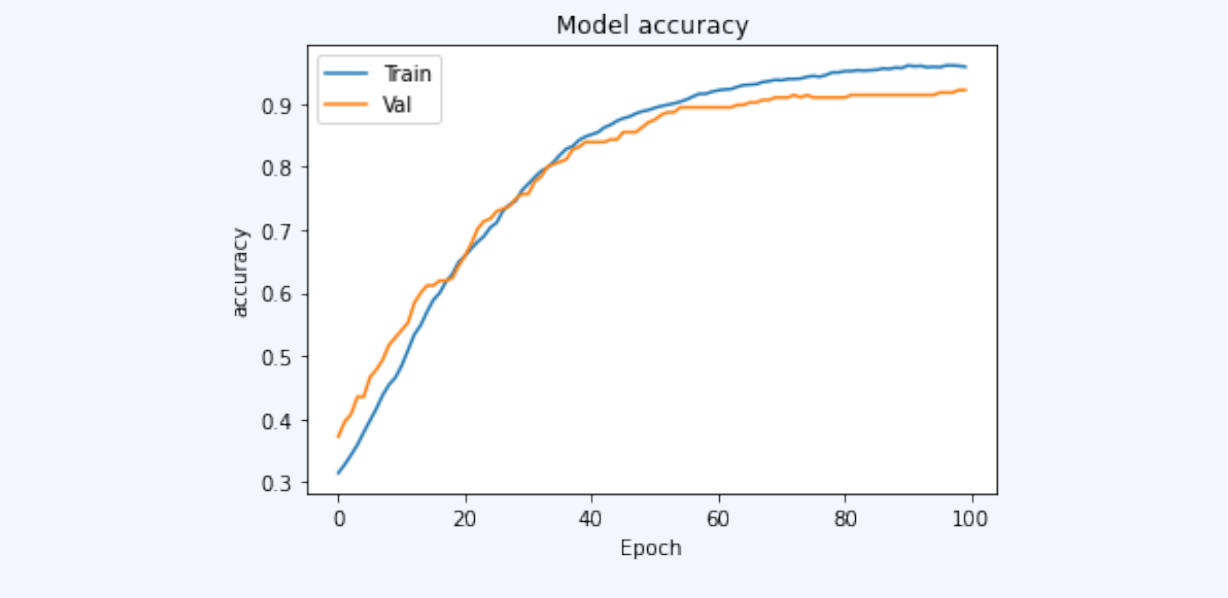

Рис. 2.10. Якість навчання для кожної епохи при застосуванні в якості оптимізатора методу градієнтного спуску з поправкою Нестерова (*learning_rate=0.01)*:

навчальна множина; валідаційна множина

Як можна побачити, оптимізатору SGD знадобилось більше ітерацій навчання, щоб знайти мінімум. Водночас, показники якості роботи мережі суттєво не покращились. Accuracy на тестовій множині склала майже 94%. Висновок - змінюємо параметри оптимізатора або використовуємо Adam.

Підбір характеристик ініціалізації ваг (weight initializers)

Ми вже знаємо, що перед початком навчання мережі необхідно задати початкові значення ваг - ініціалізувати їх. Але яким чином провести цю ініціалізацію? Варіантів багато.

- Документація: *https://keras.io/api/layers/initializers/*

Найчастіше ваги ініціалізуються випадковими маленькими числами. Ми можемо задати закон розподілу цих чисел або взагалі провести ініціалізацію константами (тільки для ваг зміщень bias!). Keras пропонує нам наступні варіанти:

- Random Normal – ініціалізація за нормальним законом розподілу. Використовується за замовчуванням.
- Random Uniform – ініціалізація за рівномірним законом розподілу.
- Truncated Normal – ініціалізація за нормальним законом розподілу, для якого введені граничні значення величин (усічений нормальний закон).
- Zeros – встановити всі початкові ваги в 0. Не сильно зрозуміло, навіщо.
- Ones – встановити всі початкові ваги в 1. Іноді застосовується в мережах LSTM.
- Constant – ініціалізувати константою. Можна використовувати для ініціалізації ваг зміщень. Має бути маленьким дійсним числом!

Але найчастіше нестандартна ініціалізація ваг використовується з метою доступу до параметру *seed* – зерна датчику випадкових чисел. Встановивши цей параметр, при кожній реініціалізації (повторному встановленню) початкових значень ваг їх величини будуть однаковими. Таким чином, запам'ятавши значення початкових ваг, можна в будь-який перенавчити мережу для отримання тих самих характеристик її якості (якщо і інші параметри навчання не змінюються). Оскільки початкові значення ваг залишаються однаковими, оптимізатор завжди починає роботу алгоритму з тієї самої початкової точки.

Застосуємо алгоритм ініціалізації ваг нейронів (kernel) Truncated Normal, а ваги зміщень (bias) ініціалізуємо константами. Також задамо параметр *seed* для відтворюваності результатів навчання у разі перезапуску. Ініціалізатори ваг вказуються як атрибути прошарку під час його створення.

```
from keras import initializers

init = initializers.TruncatedNormal(mean=0., stddev=0.05,
                                    seed=12345)
init_b = initializers.Constant(1e-3)

model10 = Sequential()
model10.add(Dense(6, input_dim=X_train.shape[1], activation="relu",
kernel_initializer=init, bias_initializer=init_b))
model10.add(Dense(4, activation="softmax", kernel_initializer=init,
                  bias_initializer=init_b))

model10.compile(optimizer='adam', loss='categorical_crossentropy',
                metrics=['accuracy'])

history10 = model10.fit(X_train, Y_train, epochs=50,
                        validation_split=0.15, batch_size=16)

loss, accuracy = model10.evaluate(X_test, Y_test, verbose=0)
print(loss, accuracy)

>>

Train on 1445 samples, validate on 255 samples
Epoch 1/50
1445/1445 [==============================] - 0s 211us/step - loss:
1.3841 - accuracy: 0.3176 - val_loss: 1.3755 - val_accuracy: 0.4667
Epoch 2/50
1445/1445 [==============================] - 0s 153us/step - loss:
1.3379 - accuracy: 0.5315 - val_loss: 1.2712 - val_accuracy: 0.5020
Epoch 3/50
1445/1445 [==============================] - 0s 154us/step - loss:
1.1840 - accuracy: 0.4997 - val_loss: 1.0916 - val_accuracy: 0.5098
...

Epoch 48/50
1445/1445 [==============================] - 0s 155us/step - loss:
0.1212 - accuracy: 0.9785 - val_loss: 0.1349 - val_accuracy: 0.9647
Epoch 49/50
1445/1445 [==============================] - 0s 163us/step - loss:
0.1192 - accuracy: 0.9813 - val_loss: 0.1319 - val_accuracy: 0.9725
Epoch 50/50
1445/1445 [==============================] - 0s 176us/step - loss:
0.1178 - accuracy: 0.9820 - val_loss: 0.1307 - val_accuracy: 0.9608
0.141209290822347 0.95333331823349
```

Виводимо графік з історією навчання (рис. 2.11) для оцінки ефективності навчання.

```
plt.plot(history10.history['accuracy'])
plt.plot(history10.history['val_accuracy'])
plt.title('Model accuracy')
plt.ylabel('accuracy')
plt.xlabel('Epoch')
plt.legend(['Train', 'Val'], loc='upper left')
plt.show()

>>
```

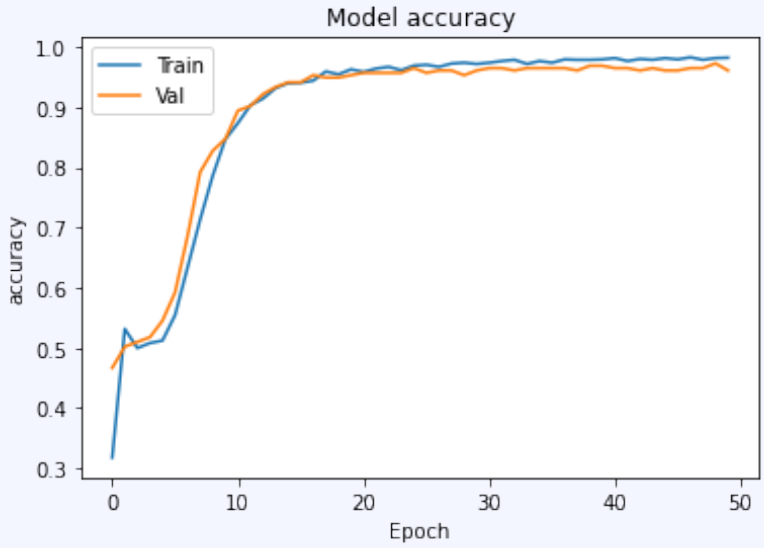

Рис. 2.11. Якість навчання для кожної епохи при застосуванні власної ініціалізації: навчальна множина; валідаційна множина

Отримали Accuracy на тестовій множині 95,3%. За графіком навчання видно, що на початкових ітераціях оптимізатор знаходився далеко від мінімуму, але зрештою вийшов з цієї ситуації. Це трапилось тому що ініціалізовані значення ваг були підібрані не зовсім вдало.

Підсумок

Коли який із розглянутих підходів застосовувати - питання без відповіді. Метод проб і помилок. Лише підбором і комбінацією описаних методів можна досягти оптимального результату.

Зазвичай, найбільший вплив на ефективність роботи мережі мають збалансована вибірка, правильно підібрана архітектура, регуляризація ваг та Batch normalization. Часто корисним є Dropout – якщо в мережі багато нейронів

і вона має складну архітектуру. Також не потрібно забувати і про early stopping. Спробуємо створити мережу із використанням цих підходів.

```
import tensorflow as tf
from keras.models import Sequential
from keras.layers import Dense, Dropout, BatchNormalization
from keras import optimizers
from keras import initializers

early = tf.keras.callbacks.EarlyStopping(monitor='val_accuracy',
                                         patience=5)

init = initializers.TruncatedNormal(mean=0., stddev=0.05,
                                    seed=98765)
init_b = initializers.Constant(1e-3)

model11 = Sequential()
model11.add(Dense(6, input_dim=X_train.shape[1], activation="relu",
                  kernel_initializer=init, bias_initializer=init_b,
                  kernel_regularizer='l2'))
model11.add(BatchNormalization())
model11.add(Dropout(0.2))
model11.add(Dense(4, activation="softmax", kernel_initializer=init,
                 bias_initializer=init_b, kernel_regularizer='l2'))
model11.compile(optimizer='adam', loss='categorical_crossentropy',
                metrics=['accuracy'])


history11 = model11.fit(X_train, Y_train, epochs=50,
                        validation_split=0.15, batch_size=16,
                        callbacks=[early])
loss, accuracy = model11.evaluate(X_test, Y_test, verbose=0)
print(loss, accuracy)

>>

Train on 1445 samples, validate on 255 samples
Epoch 1/50
1445/1445 [==============================] - 1s 404us/step - loss:
1.3525 - accuracy: 0.3889 - val_loss: 1.3643 - val_accuracy: 0.5765
Epoch 2/50
1445/1445 [==============================] - 0s 230us/step - loss:
1.1678 - accuracy: 0.5737 - val_loss: 1.2343 - val_accuracy: 0.5961
Epoch 3/50
1445/1445 [==============================] - 0s 232us/step - loss:
0.9482 - accuracy: 0.6415 - val_loss: 1.0163 - val_accuracy: 0.7294
...
```

```
Epoch 17/50
1445/1445 [==============================] - 0s 271us/step - loss:
0.4256 - accuracy: 0.8533 - val_loss: 0.2953 - val_accuracy: 0.9373
Epoch 18/50
1445/1445 [==============================] - 0s 250us/step - loss:
0.4208 - accuracy: 0.8484 - val_loss: 0.2891 - val_accuracy: 0.9333
Epoch 19/50
1445/1445 [==============================] - 0s 257us/step - loss:
0.3980 - accuracy: 0.8526 - val_loss: 0.2799 - val_accuracy: 0.9216
0.2740660031636556 0.9633333086967468
```

Виводимо графік з історією навчання (рис. 2.12) для оцінки ефективності навчання.

```
plt.plot(history11.history['accuracy'])
plt.plot(history11.history['val_accuracy'])
plt.title('Model accuracy')
plt.ylabel('accuracy')
plt.xlabel('Epoch')
plt.legend(['Train', 'Val'], loc='upper left')
plt.show()

>>
```

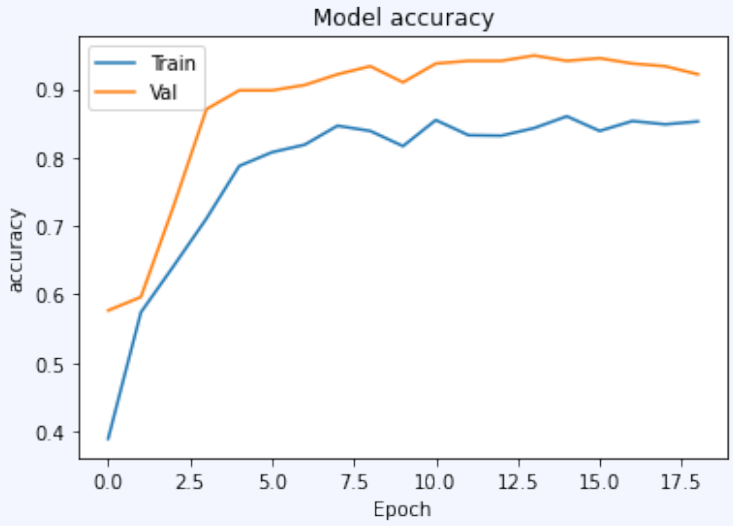

Рис. 2.13. Якість навчання для кожної епохи при одночасному застосуванні декількох методів оптимізації :

навчальна множина; валідаційна множина

Отже, в результаті ми отримали показник долі правильних відповідей на тестовій множині у розмірі 96,3%, що є набагато кращим у порівнянні з початковою моделлю (88,6%). Ось так "тюнінгують" нейронні мережі:)

2.3. Завдання для самостійного виконання

Загальні завдання для всіх варіантів:

1. Завантажте набір даних.
2. Виведіть заголовок таблиці (перші 5 записів).
3. В якому вигляді мітки класів?
4. В якому форматі характеристики об’єктів? Чи є характеристики у вигляді тексту? Якщо так, факторизувати (перетворити на числа) дані в таких стовпцях.
5. Наскільки збалансовані класи?
6. Створити навчальний набір предикторів X та цілей Y. Перетворити мітки класів до формату One hot encoding.
7. Розбити набір даних на навчальну та тестову множини.
8. Стандартизувати предиктори X.
9. Створити модель нейронної мережі прямого розповсюдження. Обрати архітектуру, активаційні функції, оптимізатор, критерії якості та метрики. Якщо даних мало, не використовувати валідаційну множину.
10. Навчити нейронну мережу (кілька разів?).
11. Оцінити якість роботи навченої мережі на тестовій множині.
12. Побудувати графік залежності критерію якості (або метрики) від номеру ітерації навчання. Проаналізувати графік і, за потреби, перенавчити мережу, врахувавши отриману інформацію.
13. Подати на вхід навченої мережі довільний зразок із тестової вибірки. За результатами вивести наступне повідомлення: «Передбачено клас {мітка класу} з достовірністю {P}%».
14. Використовуючи мінімум 3 різних підходи до оптимізації нейронних мереж, спробувати покращити початковий результат навчання.

Варіант 1

Набір даних: цит руси (citrus.csv).

Опис даних: В наборі містяться дані про розміри та колір цитрусових фруктів. За цими характеристиками потрібно розпізнати, апельсин це чи грейпфрут. Мітки класів наведені у стовпці «name».

Кількіст ь класів: 2 (апельсин/грейпфрут).

Варіант 2

Набір даних: відмови від мобільного операт ора (churn_b.csv).

Опис даних: В наборі містяться дані про користувачів французького оператора Orange Telecom. За цими даними потрібно визначити, чи існує ризик відмови користувача від послуг даного оператора. Мітки класів наведені у стовпці «Churn». Стовпець «State» необхідно видалити із набору даних перед аналізом. Дані в деяких інших стовпцях треба факторизувати.

Кількіст ь класів: 2 (Є ризик (true) / немає ризику (false)).

Варіант 3

Набір даних: клієнт и кредит ного агент ст ва (clients_b.csv).

Опис даних: В наборі містяться дані про потенційних клієнтів кредитного агенства. За цими даними потрібно визначити, чи існує ризик того, що клієнт не поверне кредит. Мітки класів наведені у стовпці «bad_client_target». Дані в деяких інших стовпцях треба факторизувати.

Кількіст ь класів: 2 (Клієнт надійний (0) / клієнт ненадійний (1)).

Варіант 4

Набір даних: маркет ингова кампанія банку (bank_b.csv).

Опис даних: В наборі містяться дані про потенційних вкладників банку. За цими даними потрібно визначити, чи існує ймовірність, що клієнт зробить депозит. Мітки класів наведені у стовпці «y». Дані в деяких інших стовпцях треба факторизувати.

Кількіст ь класів: 2 (Зробить внесок (yes) / не зробить внесок (no)).

Варіант 5

Набір даних: здоров'я ембріону (fetal_health_b.csv).

Опис даних: В наборі містяться дані про біологічні показники ембріонів. За цими даними потрібно визначити стан здоров'я плоду. Мітки класів наведені у стовпці «fetal_health».

Кількіст ь класів: 3 (Нормальне (1) / тривожне (2) / патологічне (3)).

Варіант 6

Набір даних: погода на Різдво в Чикаго (ChicagoWeatherChristmas_new.csv).

Опис даних: В наборі містяться дані про історію погоди в Чикаго на Різдво. За цими даними потрібно визначити, яка ймовірність зустріти сніжне Різдво в залежності від характеристик погоди. Мітки класів наведені у стовпці «White Christmas». Стовпець «Year» необхідно видалити із набору даних перед аналізом

Кількість класів: 3 (Без снігу (FALSE) / Невідомо (Not Defined) / зі снігом (TRUE)).

Варіант 7

Набір даних: махінації з кредит ними карт ками (creditcard_b.csv).

Опис даних: В наборі містяться зашифровані дані про операції з кредитними картками. За цими даними потрібно навчитись виявляти підозрілі транзакції. Мітки класів наведені у стовпці «Class».

Кількіст ь класів: 2 (Безпечна транзакція (0) / небезпечна транзакція (1)).

Варіант 8

Набір даних: доходи населення (income_b.csv).

Опис даних: В наборі містяться дані про різних жителів США. За цими даними потрібно визначити клас, до якого належить людина – багата вона чи ні. Мітки класів наведені у стовпці «income_>50K». Дані в деяких інших стовпцях треба факторизувати.

Кількіст ь класів: 2 (Дохід менше 50К (0) / Дохід більше 50К (1)).

Варіант 9

Набір даних: покупці авт омобілів (autocustomer.csv).

Опис даних: В наборі містяться дані про потенційних покупців автомобілів в одному із автосалонів. За цими даними потрібно визначити сгемент, до якого належить покупець. Мітки класів наведені у стовпці «Segmentation». Дані в деяких інших стовпцях треба факторизувати. Стовпець «ID» необхідно видалити із набору даних перед аналізом.

Кількіст ь класів: 4 (A / B / C / D).

Варіант 10

Набір даних: хлопчики т а дівчат а (gender_classification.csv).

Опис даних: В наборі містяться дані про біометричні показники людей різної статі. За цими даними потрібно визначити стать людини. Мітки класів наведені у стовпці «gender».

Кількіст ь класів: 2 (Чоловік (Male) / Жінка (Female)).

Варіант 11

Набір даних: покемони (pokedex_b.csv).

Опис даних: В наборі містяться дані про покемонів. За цими даними потрібно навчитись визначати, чи є покемон легендарним. Мітки класів наведені у стовпці «is_legendary». Дані в деяких інших стовпцях треба факторизувати. Стовпці «pokedex_number» та «name» необхідно видалити із набору даних перед аналізом

Кількіст ь класів: 2 (Легендарний (1) / Звичайний (0)).

Варіант 12

Набір даних: музика (music.csv).

Опис даних: В наборі містяться дані про музичні композиції. За цими даними потрібно навчитись визначати, до якого жанру належить композиція. Мітки класів наведені у стовпці «label». Стовпець «filename» необхідно видалити із набору даних перед аналізом

*Кількіст ь класів:*10 (hiphop/blues/metal/jazz/rock/country/disco/pop/reggae/classical).

ПРАКТИКУМ 3. НЕЙРОННІ МЕРЕЖІ В ЗАДАЧАХ ПРОГНОЗУВАННЯ (РЕГРЕСІЇ)

3.1. Загальні відомості

Задачі прогнозування відрізняються від задач класифікації тим, що цілі Y є не номерами класів, а мають кількісну шкалу (грн, $, кг, В тощо). Відповідно, у вихідному прошарку мережі завжди буде лише один нейрон. Окрім того, до вихідного прошарку не застосовується жодна активаційна функція (або використовується лінійна). Прикладами регресії є прогнозування прибутку, прогноз погоди, прогнозування обсягів продажів або цін на товари. З технічної точки зору, нейронні мережі прямого розповсюдження для прогнозування нічим не відрізняються від аналогічних мереж для класифікації. Важливо лише правильно подібрати метрики та критерії якості і підготувати дані для аналізу.

- Критерії якості для задач регресії в Keras:

  https://keras.io/api/losses/regression_losses/

- Метрики для задач регресії в Keras:

  https://keras.io/api/metrics/regression_metrics/

Одним із прикладів задач регресії є прогнозування часових послідовностей (часових рядів).

Часовий ряд (англ. time series) – це ряд точок даних, проіндексованих (або перелічених, або відкладених на графіку) в хронологічному порядку. Найчастіше часовий ряд є послідовністю, взятою на рівновіддалених точках в часі, які йдуть одна за одною. Таким чином, він є послідовністю даних дискретного часу. Прикладами часових рядів є висоти океанських припливів, кількості сонячних плям, та щоденне значення вартості акцій на момент закриття торгів. (Wikipedia)

Найкраще в цих задачах себе проявляють мережі довгої короткострокової пам'яті (Long Short-Term Memory, LSTM). Але зараз ми навчимось вирішувати цю задачу із використанням вже знайомих нам Feedforward мереж.

Підготовка даних

Розглянемо набір даних про обсяг пасажирських перевезень у США за 1949 - 1960 роки. Цей приклад є класичним і найбільш демонстративним щоб гарно розібратись з усіма особливостями прогнозування рядів.

Задача: необхідно зробити прогноз обсягів пасажирських перевезень на 12 місяців вперед.

Для початку імпортуємо необхідні бібліотеки.

```
import numpy
import pandas as pd

import matplotlib
import matplotlib.pyplot as plt
matplotlib.style.use('ggplot')
# Розмір графіків
plt.rcParams['figure.figsize'] = (15, 5)
```

Завантажимо навчальну вибірку - часовий ряд, на основі якого будемо робити прогноз.

```
ser_g = pd.read_csv('../series_g.csv', sep=';', header=0)
```

Переглянемо заголовок і кінець таблиці:

```
ser_g.head()

>>

       date  series_g
0  JAN 1949       112
1  FEB 1949       118
2  MAR 1949       132
3  APR 1949       129
4  MAY 1949       121

ser_g.tail()
```

```
         date  series_g
139  AUG 1960       606
140  SEP 1960       508
141  OCT 1960       461
142  NOV 1960       390
143  DEC 1960       432
```

Як бачимо, дані організовані по місяцям. В стовпці *date* – місяць і рік, в стовпці *sreies_g* – обсяг пасажирських перевезень за відповідний час.

Переглянемо, скільки всього записів є в наборі даних.

```
ser_g.shape
>>
(144, 2)
```

Отже, маємо дані за 144 місяці.

Тепер побудуємо графік (рис. 4.1), щоб відповісти на 4 питання:

- Чи є тренд? Тренд - це загальна тенденція в поведінці ряду. Тренд описує, як змінюються середні значення ряду із часом. Якщо тренд є, потрібно оцінити його характер: зростаючий/спадаючий, лінійний/експоненціальний/затухаючий тощо.
- Чи є сезонність? Сезонність - періодичні зміни значень ряду з часом. Якщо є сезонність, то яка вона? Який період сезону? Сезонність адитивна (значення сезонних поправок мають постійну амплітуду відносно лінії тренду) чи мультиплікативна (значення сезонних поправок збільшуються/зменшуються пропорційно зростанню/спаданню тренду)? Якщо сезонність мультиплікативна, її потрібно привести до адитивної (наприклад, прологарифмувавши значення ряду).
- Чи змінює ряд свій характер? Зміну характеру можна виявити за різкою зміною тренду. Якщо ряд змінює свій характер, для

прогнозування необхідно використовувати лише останню його ділянку, на якій характер ряду незмінний.

- Чи є викиди або пропущені значення? Викиди - аномально великі або маленькі значення в ряді. Якщо вони є, їх потрібно замінити більш "розумними" значеннями (найчастіше – середнім або медіаною між сусідніми відносно викиду спостереженнями).

```
#  Графік щоб відповісти на 4 питання
ser_g.iloc[:,1].plot()

>>
```

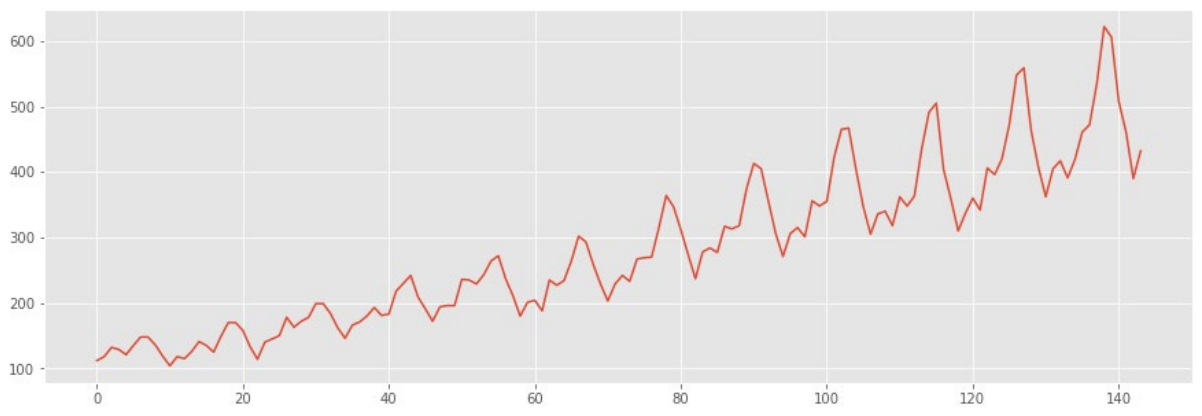

Рис. 3.1. Обсяг пасажирських перевезень у США за 1949 - 1960 роки (за 144 місяці)

Аналізуємо графік:

- Ряд має зростаючий лінійний тренд
- Ряд має мультиплікативну сезонність
- Ряд не змінює свій характер
- Викидів або пропущених значень немає

Оскільки сезонність мультиплікативна, її потрібно привести до адитивної, використавши логарифмування (рис. 3.2). Таким чином, модель буде вчитись робити прогноз для логарифму ряду, а не самого ряду.

```
#  Потрібно прогнозувати логарифм
ser_g['log_y'] = numpy.log10(ser_g['series_g'])
```

```
fig = plt.figure(figsize=(12, 4))
ax1 = fig.add_subplot(121)
ser_g['series_g'].plot(ax=ax1)
ax1.set_title(u'Обсяг перевезень пасажирів')
ax1.set_ylabel(u'Тисяч осіб')

ax2 = fig.add_subplot(122)
pd.Series(ser_g['log_y']).plot(ax=ax2)
ax2.set_title(u'log10 від обсягу перевезень пасажирів')
ax2.set_ylabel(u'log10 від тисяч осіб')

Text(0, 0.5, 'log10 від тисяч осіб')

>>
```

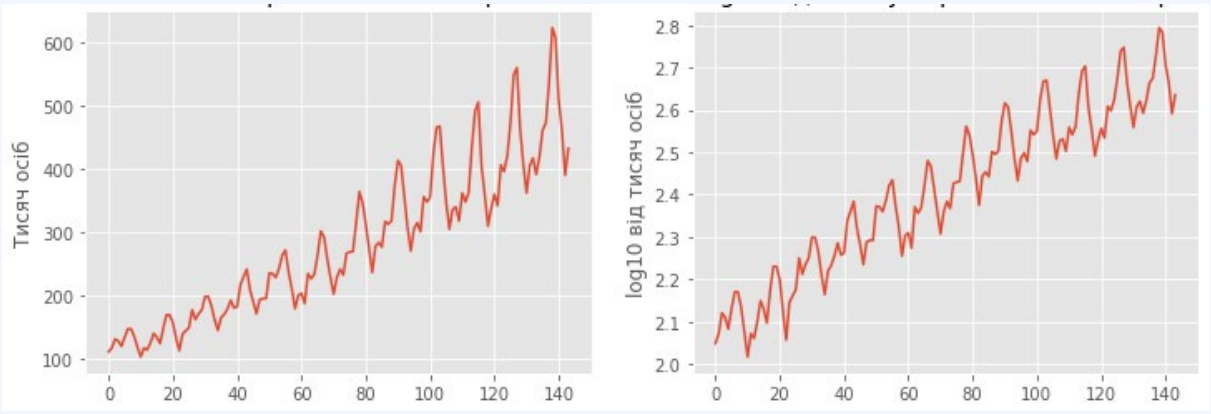

а б

Рис. 3.2. Обсяг пасажирських перевезень у США за 144 місяці:
а – обсяг перевезень пасажирів; б – log10 від обсягу перевезень пасажирів

Тепер необхідно перетворити дані так, щоб отримати таблицю предикторів X та цілей Y. Оскільки тривалість сезону в нашому випадку складає 12 місяців (1 рік), то логічно буде за дванадцятьма попередніми місяцями робити прогноз на один наступний місяць. Тобто для одного рядка навчальних даних буде 12 стовпців X та один стовпець Y.

Під час навчання:

- За значеннями спостережень №1-№12 прогнозуємо спостереження №13 - це буде перша ітерація навчання (перший

рядок навчальних даних). Предиктори X - спостереження №1-№12, ціль Y - спостереження №13.

- Зсуваємось на 1 місяць вперед. За значеннями спостережень №2-№13 прогнозуємо спостереження №14 (це буде другий рядок навчальних даних).
- Зсуваємось на 1 місяць вперед. За значеннями спостережень №3-№14 прогнозуємо спостереження № 15.
- Крок за кроком проходимо по всіх навчальних даних.

Виконаємо необхідні перетворення даних.

```
ser_g_2 = pd.DataFrame()

for i in range(12,0,-1):
    ser_g_2['t-'+str(i)] = ser_g.iloc[:,2].shift(i)

ser_g_2['t'] = ser_g.iloc[:,2].values

print(ser_g_2.head(13))

>>

        t-12      t-11      t-10      t-9       t-8       t-7       t-6  \
0        NaN       NaN       NaN       NaN       NaN       NaN       NaN
1        NaN       NaN       NaN       NaN       NaN       NaN       NaN
2        NaN       NaN       NaN       NaN       NaN       NaN       NaN
3        NaN       NaN       NaN       NaN       NaN       NaN       NaN
4        NaN       NaN       NaN       NaN       NaN       NaN       NaN
5        NaN       NaN       NaN       NaN       NaN       NaN       NaN
6        NaN       NaN       NaN       NaN       NaN       NaN  2.049218
7        NaN       NaN       NaN       NaN       NaN  2.049218  2.071882
8        NaN       NaN       NaN       NaN  2.049218  2.071882  2.120574
9        NaN       NaN       NaN  2.049218  2.071882  2.120574  2.110590
10       NaN       NaN  2.049218  2.071882  2.120574  2.110590  2.082785
11       NaN  2.049218  2.071882  2.120574  2.110590  2.082785  2.130334
12  2.049218  2.071882  2.120574  2.110590  2.082785  2.130334  2.170262

         t-5       t-4       t-3       t-2       t-1         t
0        NaN       NaN       NaN       NaN       NaN  2.049218
1        NaN       NaN       NaN       NaN  2.049218  2.071882
```

```
2        NaN       NaN       NaN  2.049218  2.071882  2.120574
3        NaN       NaN  2.049218  2.071882  2.120574  2.110590
4        NaN  2.049218  2.071882  2.120574  2.110590  2.082785
5   2.049218  2.071882  2.120574  2.110590  2.082785  2.130334
6   2.071882  2.120574  2.110590  2.082785  2.130334  2.170262
7   2.120574  2.110590  2.082785  2.130334  2.170262  2.170262
8   2.110590  2.082785  2.130334  2.170262  2.170262  2.133539
9   2.082785  2.130334  2.170262  2.170262  2.133539  2.075547
10  2.130334  2.170262  2.170262  2.133539  2.075547  2.017033
11  2.170262  2.170262  2.133539  2.075547  2.017033  2.071882
12  2.170262  2.133539  2.075547  2.017033  2.071882  2.060698
```

Відрізаємо перші 12 рядків.

```
ser_g_4 = ser_g_2[12:]

ser_g_4.head()

>>

        t-12      t-11      t-10       t-9       t-8       t-7       t-6  \
12  2.049218  2.071882  2.120574  2.110590  2.082785  2.130334  2.170262
13  2.071882  2.120574  2.110590  2.082785  2.130334  2.170262  2.170262
14  2.120574  2.110590  2.082785  2.130334  2.170262  2.170262  2.133539
15  2.110590  2.082785  2.130334  2.170262  2.170262  2.133539  2.075547
16  2.082785  2.130334  2.170262  2.170262  2.133539  2.075547  2.017033

         t-5       t-4       t-3       t-2       t-1         t
12  2.170262  2.133539  2.075547  2.017033  2.071882  2.060698
13  2.133539  2.075547  2.017033  2.071882  2.060698  2.100371
14  2.075547  2.017033  2.071882  2.060698  2.100371  2.149219
15  2.017033  2.071882  2.060698  2.100371  2.149219  2.130334
16  2.071882  2.060698  2.100371  2.149219  2.130334  2.096910
```

Навчальна таблиця даних готова. Тепер розділяємо предиктори та цілі.

```
# Цілі -  вектор y
y = ser_g_4['t']
# Предиктори - таблиця X
X = ser_g_4.drop('t', axis=1)
```

Розділяємо дані на навчальну і тестову множини. Тестова множина у випадку прогнозування часових рядів - останні спостереження. Оскільки нам важливо отримати точний прогноз саме для останнього періоду часу.

```
# Знадаємо, скільки рядків в навчальній таблиці
ser_g_4.shape

(132, 13)

#  Візьмемо останні 12 спостережень в якості тестової вибірки
X_train = X[:120]
y_train = y[:120]
X_test  = X[120:]
y_test  = y[120:]

#  Все добре?
print(ser_g_4.shape)
print(X_train.shape)
print(y_train.shape)
print(X_test.shape)
print(y_test.shape)

>>

(132, 13)
(120, 12)
(120,)
(12, 12)
(12,)
```

```
#  Все добре?
X_train.head()

        t-12      t-11      t-10       t-9       t-8       t-7       t-6  \
12  2.049218  2.071882  2.120574  2.110590  2.082785  2.130334  2.170262
13  2.071882  2.120574  2.110590  2.082785  2.130334  2.170262  2.170262
14  2.120574  2.110590  2.082785  2.130334  2.170262  2.170262  2.133539
15  2.110590  2.082785  2.130334  2.170262  2.170262  2.133539  2.075547
16  2.082785  2.130334  2.170262  2.170262  2.133539  2.075547  2.017033

         t-5       t-4       t-3       t-2       t-1
12  2.170262  2.133539  2.075547  2.017033  2.071882
13  2.133539  2.075547  2.017033  2.071882  2.060698
14  2.075547  2.017033  2.071882  2.060698  2.100371
15  2.017033  2.071882  2.060698  2.100371  2.149219
16  2.071882  2.060698  2.100371  2.149219  2.130334
```

Навчальні дані готові. Можемо створити і навчити нейронну мережу. В якості критерію якості використаємо *mean_squared_error*, метрика - *mean_absolute_percentage_error*. Активаційна функція вихідного нейрону -

лінійна *activation='linear'*. Розділяти вибірку на батчі не будемо (даних і так мало) - *batch_size=None*.

```
from keras.models import Sequential
from keras.layers import Dense

Using TensorFlow backend.

# Створюємо модель
model = Sequential()
model.add(Dense(8, input_dim=12, activation='relu'))
model.add(Dense(1, activation='linear'))

# Компілюємо модель
model.compile(loss='mean_squared_error', optimizer='adam',
              metrics=['mean_absolute_percentage_error'])

# Навчаємо модель
model.fit(X_train, y_train, epochs=300, batch_size=None)

>>

Epoch 1/300
120/120 [==============================] - 0s 708us/step - loss: 4.6182
- mean_absolute_percentage_error: 88.9544
Epoch 2/300
120/120 [==============================] - 0s 108us/step - loss: 3.7469
- mean_absolute_percentage_error: 80.0813
Epoch 3/300
120/120 [==============================] - 0s 117us/step - loss: 2.9702
- mean_absolute_percentage_error: 71.2797

...
Epoch 298/300
120/120 [==============================] - 0s 92us/step - loss: 0.0019
- mean_absolute_percentage_error: 1.4825
Epoch 299/300
120/120 [==============================] - 0s 108us/step - loss: 0.0019
- mean_absolute_percentage_error: 1.4824
Epoch 300/300
120/120 [==============================] - 0s 100us/step - loss: 0.0019
- mean_absolute_percentage_error: 1.4823
```

Виконаємо грубу оцінку якості моделі на тестових даних. Грубу - тому що таким способом ми уникаємо "накопичення помилки", оскільки використовуємо заздалегідь відомі значення всіх предикторів.

```
scores = model.evaluate(X_test, y_test)
print("\n rude MAPE: %.2f%%" % (scores[1]))

>>

12/12 [==============================] - 0s 1ms/step

 rude MAPE: 0.96%
```

Обчислюємо грубий прогноз на тестових даних.

```
false_predictions = model.predict(X_test)
```

Для правильної оцінки якості роботи мережі на тесових даних необхідно реалізувати наступний алгоритм:

- Взяти перший набір предикторів із тестових даних. В нашому випадку, це спостереження №109-№120. За їх значеннями спрогнозувати спостереження №121.
- Взяти спостереження №110-№121 (спрогнозоване на попередньому кроці). За ними спрогнозувати спостереження №122.
- Взяти спостереження №110-№122 (два останні - спрогнозовані на попередніх кроках). За ними спрогнозувати спостереження №123.
- Повторювати ці дії стільки разів, скільки значень потрібно спрогнозувати. В нашому випадку - 12.
- Лише після цього оцінити значення метрики, порахувавши помилки як різницю між реальними цілями *y* та спрогнозованими значеннями. Це треба зробити за власною формулою, а не стандартним методом *evaluate()*!

Напишемо власну функцію для прогнозування за описаним алгоритмом.

```
def make_prediction(X_predict, nb_of_predictions):
```

```
    predictions = numpy.array([])

    for i in range (nb_of_predictions):

        y_predicted = model.predict(X_predict)
        predictions = numpy.append(predictions, y_predicted)

        X_predict = numpy.roll(X_predict, -1)
        X_predict[0][-1] = y_predicted

    return predictions
```

Проведемо оцінку якості моделі за метрикою MAPE.

```
# Перетворимо перший зразок із тестової вибірки на масив Numpy
X_predict = numpy.array(X_test[:1])

# Використаємо написану функцію для отримання правильного прогнозу
predictions = make_prediction(X_predict, len(X_test))
```

Отримаємо значення MAPE на тестових даних.

```
y_test = numpy.array(y_test)

MAPE = 100*sum(numpy.abs(y_test - predictions) / numpy.maximum(y_tes
t, 1e-20))/len(y_test)
print(f"\n MAPE: {MAPE:.2f} %")


 MAPE: 1.13 %
```

Обчислюємо допасування ("підгонку") моделі. Підгонка показує, наскільки якісно модель робить прогнози на навчальній множині. Порівнявши результати роботи мережі з правильними значеннями Y, можна візуально (на графіку) оцінити, наскільки близькими є прогнози моделі до реальних даних, на яких вона навчалась.

```
predictions_train = model.predict(X_train)
```

Згадуємо розміри таблиць і будуємо графіки (рис. 4.3).

```
print(X_train.shape)
print(y_train.shape)
```

```
print(X_test.shape)
print(y_test.shape)

>>

(120, 12)
(120,)
(12, 12)
(12,)
```

- Було 144 спостереження
- Відкинули 12, стало 132
- train 120
- test 12

```
# Графік з результатами

plt.rcParams['figure.figsize'] = (15, 5)

#   numpy.arange([start, ]stop, [step, ]dtype=None)

x2 = numpy.arange(0, 120, 1)

x3 = numpy.arange(120, 132, 1)

# реальні дані (початковий ряд без відкинутих і тестових значень)
plt.plot(x2, y_train, color='blue')

# підгонка
plt.plot(x2, predictions_train, color='green')

# реальні дані на тестовій множині
plt.plot(x3, y_test, color='blue')


# грубий прогноз на тестовій множині
plt.plot(x3, false_predictions, color='purple')

# правильний прогноз на тестовій множині
plt.plot(x3, predictions, color='red')


>>
```

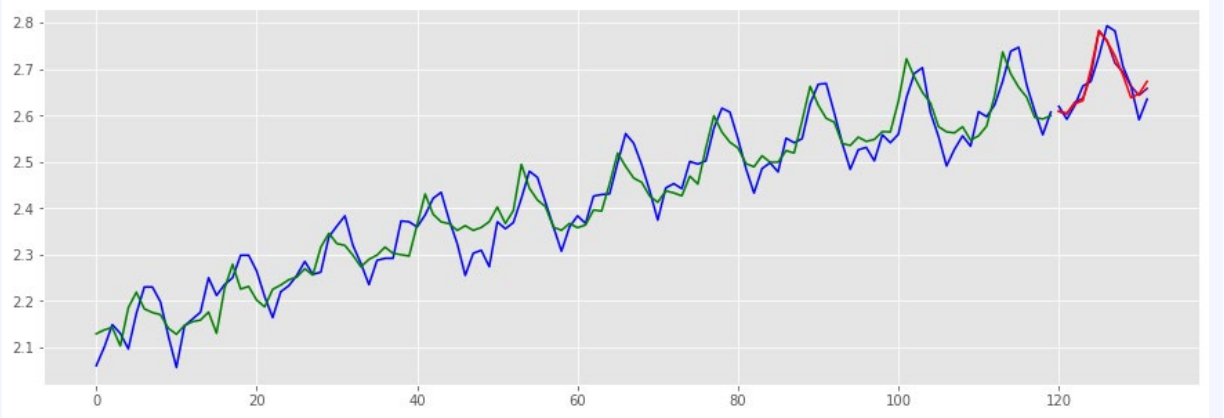

Рис. 3.3. Обсяг пасажирських перевезень у США за 144 місяці:
blue – початкові дані; *green* – апроксимація моделлю; *purple* – грубий прогноз; *red* – правильний прогноз

Якщо результати роботи мережі нас задовольняють, можна використати навчену модель для створення реального прогнозу. Якщо ні - перенавчаємо. Реальний прогноз є продовженням початкового ряду на певну кількість спостережень. В нашому випадку - на 12 місяців вперед. Для створення прогнозу використаємо раніше написану нами функцію *make_prediction()*. Кількість предикторів X має відповідати кількості стовпців X в таблиці даних, на якій навчалась мережа. В нашому випадку, в якості першого набору предикторів X необхідно подати дані за останні 12 місяців з початкового ряду.

```
# Прогнозуємо на 12 місяців вперед
nb_of_predictions = 12

# Перетворюємо дані за останні 12 місяців в масиви Numpy
X_real_prediction = numpy.array(ser_g_4.iloc[-12:,1])
X_real_prediction = numpy.expand_dims(X_real_prediction, axis = 1)
X_real_prediction = numpy.transpose(X_real_prediction)

# Робимо прогноз
real_predictions = make_prediction(X_real_prediction,
                                   nb_of_predictions)
```

Побудуємо суміщений графік (рис. 3.4), на якому покажемо початковий ряд та прогноз на наступні 12 місяців.

```
# Дані з початкового ряду
x_past = numpy.arange(0, len(ser_g_4))
y_past = ser_g_4.iloc[:,1]

# Додаємо координати X для прогнозу
x_pred = numpy.arange(len(ser_g_4), len(ser_g_4) + nb_of_predictions)

# Початковий ряд
plt.plot(x_past, y_past, color='blue')

# Прогноз
plt.plot(x_pred, real_predictions, color='red')

>>
```

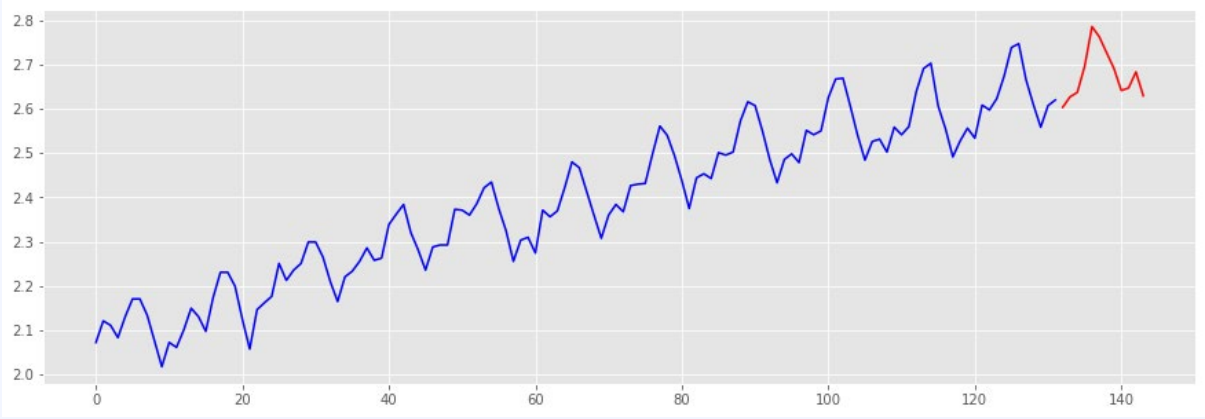

Рис. 3.4. Обсяг пасажирських перевезень у США з прогнозом на наступні 12 місяців: *blue* – початкові дані; *red* – прогноз

Оскільки ми навчили мережу прогнозувати логарифми даних, а не самі дані, необхідно виконати зворотне перетворення – піднесення до степеню. Логарифм був десятковим, тому для отримання реальних результатів (кількості осіб, а не її логарифмів) необхідно піднести 10 до відповідного ступеню. Побудуємо графік (рис. 3.5).

```
# Перетворюємо з логарифмів до реальної величини
non_log_predictions = 10**real_predictions

# Тепер побудуємо фінальний графік.
```

```
x_past = numpy.arange(0, len(ser_g))
y_past = ser_g.iloc[:,1]

x_pred = numpy.arange(len(ser_g), len(ser_g) + nb_of_predictions)

plt.plot(x_past, y_past, color='blue')
plt.plot(x_pred, non_log_predictions, color='red')

>>
```

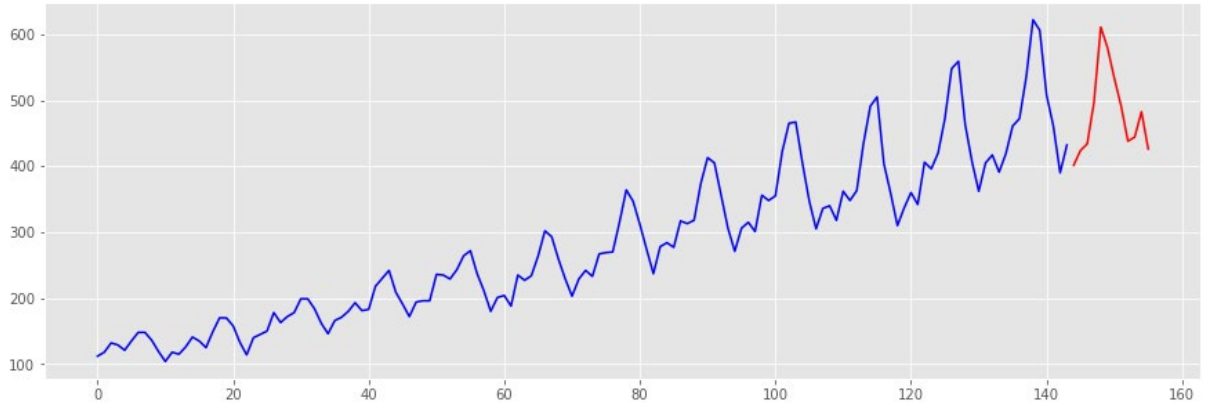

Рис. 3.5. Обсяг пасажирських перевезень у США з прогнозом на наступні 12 місяців: *blue* – початкові дані; *red* – прогноз (без логарифмування)

4.2. Завдання для самостійного виконання

Загальні завдання для всіх варіантів:

1. Завантажте набір даних. Скільки всього записів у ряді?
2. Виведіть заголовок та останні 5 записів таблиці.
3. Побудуйте графік часового ряду.
4. Проаналізуйте ряд, відповівши на 4 питання:
    a. Чи є тренд?
    b. Чи є сезонність?
    c. Чи змінює ряд свій характер?
    d. Чи є викиди або пропущені дані?
5. Виконайте перетворення даних для формування навчальної таблиці. Врахуйте сезонність (якщо вона є) для вибору кількості стовпців.
6. Розділіть дані на предиктори X та цілі Y.
7. Сформуйте навчальну та тестову множини.
8. Створіть та навчіть нейронну мережу для прогнозування.
9. Отримайте грубу оцінку роботи мережі на тестових даних.
10. Отримайте реальну оцінку роботи мережі на тестових даних.
11. Побудуйте суміщений графік, на якому має бути відображено:
    a. відрізок ряду з навчальних (початкових) даних;
    b. відрізок ряду, отриманий за допомогою опрацювання навчальних даних нейронною мережею;
    c. відрізок ряду, який відповідає реальним (початковим) даним на тестовій множині;
    d. відрізок ряду, який відповідає грубому прогнозу мережі на тестовій множині;

e. відрізок ряду, який відповідає реальному прогнозу мережі на тестовій множині.

12. Використайте навчену мережу для отримання прогнозу на вказаний термін часу.
13. Побудуйте суміщений графік початкового ряду та прогнозу.

Варіант 1

Набір даних: ДТП в Великобрит анії (accident_UK_by_month.csv).

Опис даних: В наборі містяться дані про середньомісячну кількість ДТП в Великобританії за 2014-2017 роки. Зробити прогноз кількості ДТП на найближчі місяці.

Термін прогнозу: 5 місяців.

Варіант 2

Набір даних: т рафік на дорогах міст а (IOT_by_days.csv).

Опис даних: В наборі містяться дані про кількість транспортних засобів на одній із вулиць міста за кожен день протягом одного року (2015-2016). Необхідно зробити прогноз трафіку на наступні тижні.

Термін прогнозу: 3 тижні.

Варіант 3

Набір даних: кількіст ь продаж ів продукт у (Month_Value.csv).

Опис даних: В наборі містяться дані про кількість продажів деякого продукту по місяцях за 2015-2020 роки. Необхідно зробити прогноз продаж на наступні місяці.

Термін прогнозу: 5 місяців.

Варіант 4

Набір даних: клімат в Делі (DailyDelhiClimate.csv).

Опис даних: В наборі містяться дані про середню температуру в Делі за кожен день 2013-2017 років. Необхідно зробити прогноз температури на наступні тижні.

Термін прогнозу: 3 тижні.

Варіант 5

Набір даних: акції Yahoo (yahoo_stock2.csv).

Опис даних: В наборі містяться дані про вартість акцій компанії Yahoo за 2015-2020 роки. Необхідно зробити прогноз вартості акцій на наступні місяці.

Термін прогнозу: 3 місяці.

Варіант 6

Набір даних: варт іст ь золот а (gold_price_data.csv).

Опис даних: В наборі містяться дані про вартість золота за 1970-2020 роки. Необхідно зробити прогноз вартості золота на наступні тижні. Для покращення якості прогнозу рекомендується взяти дані лише за останній рік. Врахувати, що біржа працює лише по робочих днях.

Термін прогнозу: 2 тижні.

Варіант 7

Набір даних: акції Apple (Apple_stock.csv).

Опис даних: В наборі містяться дані про вартість акцій компанії Apple за 2010-2020 роки. Необхідно зробити прогноз вартості акцій на наступний місяць.

Термін прогнозу: 1 місяць.

Варіант 8

Набір даних: продаж і супермаркет у Walmart (Grocery_Sales.csv).

Опис даних: В наборі містяться дані про щоденний обсяг продажів в одному із супермаркетів мережі Walmart. Необхідно зробити прогноз обсягів продажів.

Термін прогнозу: 2 місяці.

Варіант 9

Набір даних: варт іст ь зерна в США (corn_price_US.csv).

Опис даних: В наборі містяться дані про середню за тиждень вартість зерна в США за 2013-2017 роки. Необхідно зробити прогноз вартості зерна на найближчі тижні.

Термін прогнозу: 10 тижнів.

Варіант 10

Набір даних: між народні авіаперевезення в США (US_airlines.csv).

Опис даних: В наборі містяться дані про щоденний обсяг перевезень пасажирів компанією авіакомпанією ASM. Необхідно зробити прогноз обсягів перевезень на наступні місяці.

Термін прогнозу: 5 місяців.

Варіант 11

Набір даних: продаж і алкогольних напоїв в США (Alcohol_sales.csv).

Опис даних: В наборі містяться дані про щомісячний обсяг продажів алкоголю в США. Необхідно зробити прогноз обсягів продажів на наступні місяці.

Термін прогнозу: 6 місяців.

Варіант 12

Набір даних: продаж і пива в США (Beer.csv).

Опис даних: В наборі містяться дані про щомісячний обсяг продажів пива в США. Необхідно зробити прогноз обсягів продажів на наступні місяці.

Термін прогнозу: 6 місяців.

ПРАКТИКУМ 4. ЗГОРТКОВІ НЕЙРОННІ МЕРЕЖІ

4.1. Загальні відомості

Згорткові нейронні мережі – це окремий клас глибинних штучних НМ прямого розповсюдження, створений спеціально для аналізу візуальної інформації. Зазвичай, архітектура такої НМ складається з декількох багатовимірних прошарків штучних нейронів, оптимізованих для виявлення закономірностей у візуальних зображеннях. Особливістю моделі згорткової НМ є у доповнення архітектури повнозв’язної мережі прямого розповсюдження окремими згортковими прошарками, в яких кожен нейрон пов'язаний тільки з невеликою групою нейронів попереднього прошарку. Така організація мережі дозволяє виділяти на початковому зображенні лише примітивні діагностичні ознаки, такі як ребра або грані, а на наступних прошарках мережі об’єднувати виділені ознаки для отримання все більш складних елементів. Завдяки цьому з’являється можливість ефективно розпізнавати приховані закономірності та виділяти комплексні образи на зображеннях.

У згорткових НМ використовуються прошарки згортки та підвибірки. Стандартна архітектура виглядає так:

- Згортка у відповідних прошарках застосовується для формування мережею набору діагностичних ознак.
- За допомогою прошарків підвибірки реалізується вибір найбільш значущих ознак попереднього прошарку і скорочення розмірності наступних прошарків.
- Далі виконується операція перетворення отриманих карт ознак в одновимірний масив та класифікація термограми за допомогою одного або двох повнозв’язних прошарків.

– Детальніше про згорткові нейронні мережі:

https://habr.com/ru/post/348000/

– Згорткові прошарки в Keras:

https://keras.io/api/layers/convolution_layers/

– Прошарки підвибірки (пулінгу) в Keras:

https://keras.io/api/layers/pooling_layers/

Розпочнемо знайомство зі згортковими нейронними мережами на прикладі вирішення задачі бінарної класифікації зображень. Наша мета - автоматично розпізнати, яку тварину показано на зорбраженні - кота чи собаку.

Для початку імпортуємо всі необхідні модулі та функції.

```
import numpy as np
import tensorflow as tf
from tensorflow.keras import Sequential
from tensorflow.keras.layers import Conv2D, Flatten, Dense,MaxPooling2D,
Dropout
from keras.regularizers import l2
from keras import utils
from keras.preprocessing import image
from tensorflow.keras.preprocessing import image_dataset_from_directory
from tensorflow.keras.layers.experimental.preprocessing import Rescaling

import matplotlib.pyplot as plt
```

Встановимо необхідний розмір батчу та розміри вхідного зображення. Всі зображення, які подаються на вхід згорткової нейронної мережі, повинні приводитись до однакового розміру.

```
BATCH_SIZE = 64
IMAGE_SIZE = (180, 180)
```

Сформуємо множину навчальних зображень, використовуючи функцію *image_dataset_from_directory()*. Ця функція зчитує зображення, які знаходяться у вказаній директорії. Набори зображеннь, які відповідають кожному класу, повинні знаходитись в окремих папках. За замовчуванням,

назви класів будуть відповідати назвам папок, в яких розміщені зображення, що відповідають цим класам. В якості обов'язкового першого аргументу до функції *image_dataset_from_directory()* передається адреса головної папки, у якій розміщені папки з зображеннями класів.

Параметр *subset* (підмножина) вказує на те, яка підмножина формується - навчальна чи тестова.

- ВАЖЛИВО! У разі використання функції *image_dataset_from_directory()*, навчальні зображення всіх класів мають знаходитись в папках, які в свою чергу розміщені в одній головній папці з навчальними даними. Функція автоматично розділить набори зображень на навчальну та валідаційну множину - не потрібно окремо створювати папки *train* та *validation*. Достатньо просто задати відповідне значення параметру *subset*!

Використовуючи такий підхід, обов'язково потрібно встановити параметр *seed* - значення зерна датчика випадкових чисел. Під час формування навчального та валідаційного наборів зображень це значення має бути однаковим для обох підмножин даних.

Після цього необхадно вказати параметр *validation_split* - доля зображень, які будуть віднесені до валідаційної підмножини.

Далі задається розмур батчу *batch_size* та розмір зображення *image_size* - під час формування набору даних всі зображення будуть автоматично масштабовані до вказаного розміру (в пікселях).

```
# Навчальний набір зображень
train_dataset = image_dataset_from_directory('../training_set',
                                             subset='training',
                                             seed=42,
```

```
                                                validation_split=0.15,
                                                batch_size=BATCH_SIZE,
                                                image_size=IMAGE_SIZE)

>>

Found 8000 files belonging to 2 classes.
Using 6800 files for training.
```

```
# Валідаційний набір зображень
validation_dataset = image_dataset_from_directory('../training_set',
                                                subset='validation',
                                                seed=42,
                                                validation_split=0.15,
                                                batch_size=BATCH_SIZE,
                                                image_size=IMAGE_SIZE)

>>

Found 8000 files belonging to 2 classes.
Using 1200 files for validation.
```

Створимо змінну, в якій збережемо список з імен класів. Цей список міститься в атрибуті *class_names*, який формується автоматично під час роботи функції *image_dataset_from_directory()*.

```
class_names = train_dataset.class_names
class_names

>>

['cats', 'dogs']
```

Переглянемо перші дев'ять зображень з навчального набору даних (рис. 4.1).

```
plt.figure(figsize=(8, 8))

for images, labels in train_dataset.take(1):
    for i in range(9):
        ax = plt.subplot(3, 3, i + 1)
        plt.imshow(images[i].numpy().astype("uint8"))
        plt.title(class_names[labels[i]])
        plt.axis("off")
```

```
>>
```

Рис. 4.1. Перші дев’ять зображень з навчального набору даних

Аналогічним чином створимо тестовий набір даних. Вкажемо лише адресу папки з тестовими зображеннями (як і для навчальних даних, зображення кожного класу повинні розміщуватись в окремій папці), а також розмір батчу та зображення.

```
test_dataset = image_dataset_from_directory('../test_set',
                                            batch_size=BATCH_SIZE,
                                            image_size=IMAGE_SIZE)

>>
```

```
Found 2000 files belonging to 2 classes.
```

Перевіримо, чи правильно зчитались імена класів.

```
test_dataset.class_names

>>

['cats', 'dogs']
```

Все добре. Далі необхідно написати службовий код, який оптимізує процедуру роботи з відеокартою.

```
AUTOTUNE = tf.data.experimental.AUTOTUNE

train_dataset = train_dataset.prefetch(buffer_size=AUTOTUNE)
validation_dataset = validation_dataset.prefetch(buffer_size=AUTOTUNE)
test_dataset = test_dataset.prefetch(buffer_size=AUTOTUNE)
```

Створюємо модель згорткової нейронної мережі. Оберемо наступну архітектуру:

- Службовий прошарок для стандартизації значень в пікселях зображення (переведення з діапазону 0-255 до діапазону 0-1).
- Вхідний згортковий прошарок (кількість фільтрів - 32, розмір фільтру - 5x5, padding - однаковий з усіх країв, розмірність вхідного зображення - 180x180x3 [палітра RGB має три кольорових канали], активаційна функція - ReLU).
- Прошарок підвибірки (розмір фільтру - 2x2).
- Прошарок дропауту для регуляризації (випадково вимикаємо 20% нейронів попереднього прошарку)
- Другий згортковий прошарок (кількість фільтрів - 64, розмір фільтру - 3x3, padding – однаковий, активаційна функція – ReLU).
- Прошарок підвибірки (розмір фільтру – 2x2).
- Прошарок дропауту.

- Третій згортковий прошарок (кількість фільтрів – 128, розмір фільтру – 3x3, padding – однаковий, активаційна функція – ReLU).
- Прошарок підвибірки (розмір фільтру – 2x2).
- Прошарок дропауту.
- Четвертий згортковий прошарок (кількість фільтрів – 256, розмір фільтру – 3x3, padding – однаковий, активаційна функція – ReLU).
- Прошарок підвибірки (розмір фільтру – 2x2).
- Прошарок дропауту.
- Службовий прошарок для перетворення набору ознак у одновимірний вектор.
- Повнозв'язний прошарок для класифікації (512 нейронів, активаційна функція – ReLU, регуляризація ваг – L2).
- Прошарок дропауту.
- Вихідний прошарок з одним нейроном, значення якого може бути 0 (коти) або 1 (собаки) (активаційна функція – сигмоїдальна).

```
# Створюємо послідовну модель
model = Sequential()

# Додаємо прошарок стандартизації значень пікселів
model.add(Rescaling(scale=1./255))

# Згортковий прошарок
model.add(Conv2D(32, (5, 5), padding='same',
                 input_shape=(180, 180, 3), activation='relu'))
# Прошарок підвибірки
model.add(MaxPooling2D(pool_size=(2, 2)))
model.add(Dropout(0.2))

# Згортковий прошарок
model.add(Conv2D(64, (3, 3), activation='relu', padding='same'))
# Прошарок підвибірки
model.add(MaxPooling2D(pool_size=(2, 2)))
model.add(Dropout(0.2))

# Згортковий прошарок
```

```
model.add(Conv2D(128, (3, 3), activation='relu', padding='same'))
# Прошарок підвибірки
model.add(MaxPooling2D(pool_size=(2, 2)))
model.add(Dropout(0.2))

# Згортковий прошарок
model.add(Conv2D(256, (3, 3), activation='relu', padding='same'))
# Прошарок підвибірки
model.add(MaxPooling2D(pool_size=(2, 2)))
model.add(Dropout(0.2))


# Повнозв'язна частина нейронної мережі для класифікації
model.add(Flatten())
model.add(Dense(512, activation='relu', kernel_regularizer='l2'))
model.add(Dropout(0.2))

# Вихідний прошарок, 1 нейрон
model.add(Dense(1, activation='sigmoid'))
```

Компілюємо модель. Критерій якості – бінарна крос-ентропія (оскільки в задачі рівно 2 класи), оптимізатор – Adam, метрика – Accuracy.

```
model.compile(loss='binary_crossentropy',
              optimizer="adam",
              metrics=['accuracy'])
```

Переглянемо зведену інформацію щодо архітектури моделі. Як бачимо, задана мережа має 16 250 689 внутрішніх параметрів.

```
model.build((1, 180, 180,3))
model.summary()

>>

Model: "sequential_3"
_________________________________________________________________
Layer (type)                 Output Shape              Param #
=================================================================
rescaling_3 (Rescaling)      (1, 180, 180, 3)          0
_________________________________________________________________
conv2d_12 (Conv2D)           (1, 180, 180, 32)         2432
_________________________________________________________________
max_pooling2d_12 (MaxPooling (1, 90, 90, 32)           0
```

```
_________________________________________________________________
dropout_15 (Dropout)         (1, 90, 90, 32)           0
_________________________________________________________________
conv2d_13 (Conv2D)           (1, 90, 90, 64)           18496
_________________________________________________________________
max_pooling2d_13 (MaxPooling (1, 45, 45, 64)           0
_________________________________________________________________
dropout_16 (Dropout)         (1, 45, 45, 64)           0
_________________________________________________________________
conv2d_14 (Conv2D)           (1, 45, 45, 128)          73856
_________________________________________________________________
max_pooling2d_14 (MaxPooling (1, 22, 22, 128)          0
_________________________________________________________________
dropout_17 (Dropout)         (1, 22, 22, 128)          0
_________________________________________________________________
conv2d_15 (Conv2D)           (1, 22, 22, 256)          295168
_________________________________________________________________
max_pooling2d_15 (MaxPooling (1, 11, 11, 256)          0
_________________________________________________________________
dropout_18 (Dropout)         (1, 11, 11, 256)          0
_________________________________________________________________
flatten_3 (Flatten)          (1, 30976)                0
_________________________________________________________________
dense_6 (Dense)              (1, 512)                  15860224
_________________________________________________________________
dropout_19 (Dropout)         (1, 512)                  0
_________________________________________________________________
dense_7 (Dense)              (1, 1)                    513
=================================================================
Total params: 16,250,689
Trainable params: 16,250,689
Non-trainable params: 0
_________________________________________________________________
```

Навчаємо нейронну мережу. Вказуємо навчальний набір даних, набір даних для валідації та кількість епох.

```
history = model.fit(train_dataset,
                    validation_data=validation_dataset,
                    epochs=40)

Epoch 1/40
107/107 [==============================] - 18s 170ms/step - loss:
1.7990 - accuracy: 0.4946 - val_loss: 0.7111 - val_accuracy: 0.492
5
Epoch 2/40
107/107 [==============================] - 18s 169ms/step - loss:
```

```
0.6970 - accuracy: 0.5000 - val_loss: 0.6935 - val_accuracy: 0.492
5
Epoch 3/40
107/107 [==============================] - 18s 169ms/step - loss:
0.6933 - accuracy: 0.4985 - val_loss: 0.6933 - val_accuracy: 0.492
5
...
Epoch 38/40
107/107 [==============================] - 18s 169ms/step - loss:
0.4487 - accuracy: 0.8156 - val_loss: 0.4714 - val_accuracy: 0.802
5
Epoch 39/40
107/107 [==============================] - 18s 170ms/step - loss:
0.4483 - accuracy: 0.8196 - val_loss: 0.4874 - val_accuracy: 0.805
0
Epoch 40/40
107/107 [==============================] - 18s 170ms/step - loss:
0.4362 - accuracy: 0.8204 - val_loss: 0.4878 - val_accuracy: 0.800
0
```

Побудуємо графіки навчання (рис. 4.2).

```
plt.plot(history.history['accuracy'])
plt.plot(history.history['val_accuracy'])
plt.title('Model accuracy')
plt.ylabel('accuracy')
plt.xlabel('Epoch')
plt.legend(['Train', 'Val'], loc='upper left')
plt.show()

>>
```

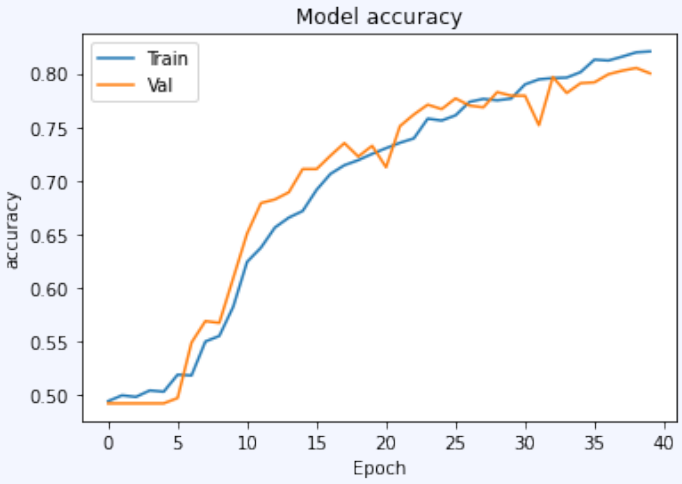

Рис. 4.2. Якість навчання для кожної епохи:

— навчальна множина; — валідаційна множина

Перенавчання немає.

Виконаємо оцінку якості роботи мережі на тестових даних.

```
scores = model.evaluate(test_dataset)

32/32 [==============================] - 9s 295ms/step - loss: 0.4963
- accuracy: 0.7945

print("Доля вірних відповідей на тестових даних, у відсотках:",
      round(scores[1] * 100, 4))

>>

Доля вірних відповідей на тестових даних, у відсотках: 79.45
```

Застосуємо створену модель для класифікації довільного зображення. Імпортуємо функції для завантаження зображення в програму.

```
from IPython.display import Image
from tkinter.filedialog import askopenfilename
```

Виконаємо попередню обробку (масштабування та перетворення зображення в масив Numpy) та подамо його на вхід мережі для отримання відповіді. Виведемо результат (рис. 4.3).

```
# Викликаємо віконце для вибору файлу
img_path = askopenfilename()
# Імпортуємо зображення та масштабуємо його (img_path, ширина=180,
висота=180)
img = image.load_img(img_path, target_size=(180, 180))

# Перетворюємо зображення в масив
x = image.img_to_array(img)
x = x.reshape(-1,180, 180, 3)

# Подаємо зображення на вхід мережі для класифікації
prediction = model.predict(x)

# Визначаємо код класу
prediction = int(np.round(prediction))

# Показуємо результат
```

```
plt.figure(figsize=(4, 4))
plt.imshow(img)
plt.title(f"Назва класу: {class_names[prediction]}" )
plt.axis("off")

(-0.5, 179.5, 179.5, -0.5)
```

Рис. 4.3. Результат роботи мережі

4.2. Завдання для самостійного виконання

Загальні завдання для всіх варіантів:

1. Завантажте навчальний набір даних. Сформуйте навчальну та тестову підмножини зображень. Самостійно визначте оптимальний розмір зображень та розмір батчу.
2. Виведіть перші 9 зображень із сформованої навчальної підмножини.
3. Перевірте, чи правильно сформовано імена класів.
4. Сформуйте множину тестових даних. Перевірте правильність імен класів на тестовій множині.
5. Створіть та навчіть згорткову нейронну мережу для розпізнавання двох класів об’єктів на зображеннях. Побудуйте графік навчання.
6. Проведіть оцінку якості роботи навченої мережі на тестових даних.
7. Застосуйте навчену мережу для класифікації довільних зображень, які імпортуються в програму з жорсткого диску ПК.

Варіант 1

Набір даних: мавпочки (monkeys.zip).

Опис даних: В наборі містяться зображення двох різних видів мавп. Необхідно навчити нейронну мережу визначати, до якого виду належить мавпа на зображенні.

Варіант 2

Набір даних: чуж ий/хиж ак (alien.zip).

Опис даних: В наборі містяться зображення Чужих та Хижаків. Необхідно навчити нейронну мережу визначати, яка істота зображена на рисунку.

Варіант 3

Набір даних: кот и і панди (animals.zip).

Опис даних: В наборі містяться зображення котів та панд. Необхідно навчити нейронну мережу визначати, яка істота зображена на фотографії.

Варіант 4

Набір даних: Сімпсони (simpsons.zip).

Опис даних: В наборі містяться зображення персонажів з мультфільму «Сімпсони». Необхідно навчити нейронну мережу визначати, хто зображений на рисунку – Гомер чи Барт Сімпсон.

Варіант 5

Набір даних: види спорт у (sports.zip).

Опис даних: В наборі містяться зображення з футбольних та баскетбольних матчів. Необхідно навчити нейронну мережу визначати, який вид спорту показано на фотографії.

Варіант 6

Набір даних: породи собак (dogs.zip).

Опис даних: В наборі містяться зображення двох різних порід собак. Необхідно навчити нейронну мережу визначати, до якої породи належить собака на зображенні.

Варіант 7

Набір даних: сорт ування сміт т я (garbage.zip).

Опис даних: В наборі містяться зображення двох різних типів сміття. Необхідно навчити нейронну мережу визначати, до якого типу належить об’єкт на зображенні – скло чи метал.

Варіант 8

Набір даних: погода (weather.zip).

Опис даних: В наборі містяться зображення різних типів погоди. Необхідно навчити нейронну мережу визначати, яка погода показана на зображенні – дощова чи сонячна.

Варіант 9

Набір даних: човни (boats.zip).

Опис даних: В наборі містяться зображення різних типів човнів. Необхідно навчити нейронну мережу визначати, який човен показано на зображенні – вітрильник чи круїзний лайнер.

Варіант 10

Набір даних: рентгенографія COVID-19 (covid.zip).

Опис даних: В наборі містяться рентгенівські знімки легень здорових людей та хворих на COVID-19. Необхідно навчити нейронну мережу визначати, знімок якої людини показано на зображенні – хворої чи здорової.

Варіант 11

Набір даних: дика природа Орегону (wildlife.zip).

Опис даних: В наборі містяться зображення різних тварин, які водяться в штаті Орегон, США. Необхідно навчити нейронну мережу визначати, яку тварину показано на зображенні – ведмедя чи єнота.

Варіант 12

Набір даних: літаки (planes.zip).

Опис даних: В наборі містяться зображення різних типів літаків. Необхідно навчити нейронну мережу визначати, який літак показано на зображенні – пасажирський чи винищувач.

ПРАКТИКУМ 5. АУГМЕНТАЦІЯ ДАНИХ ТА ПЕРЕНЕСЕННЯ НАВЧАННЯ

5.1. Загальні відомості

Для роботи з глибинними згортковими нейронними мережами необхідно мати набори зображень, які містять сотні та тисячі зразків кожного класу. В реальності буває досить складно знайти такий обсяг інформації. Тому для штучного збільшення обсягу навчальної вибірки використовують підхід, який називається аугментацією (доповненням) даних. Доповнення відбувається завдяки виконанню різних операцій над початковими зображеннями - їх масштабують, повертають на деякий кут, віддзеркалюють тощо. Таким чином, на основі одного зображення можна створити декілька його видозмінених копій. Аугментація не дозволить суттєво покращити ефективність мережі, але якість її навчання стане відчутно кращою у порівнянні із навчанням на початковій (не доповненій) вибірці.

Зазвичай аугментація застосовується у випадках, коли у початковому наборі даних не більше 200-300 зображень кожного класу. Але потрібно пам'ятати, що такий метод не завжди можна застосувати. Наприклад, якщо розпізнаються номери автомобілів, то віддзеркалення зображень з метою аугментації навпаки погіршить якість навчання. Оскільки цифри номеру, як і будь-яка інша текстова інформація, втрачають весь свій зміст та характерні ознаки у випадку віддзеркалення.

- В Keras аугментація здійснюється за допомогою генератора зображень ImageDataGenerator:
  https://keras.io/api/preprocessing/image/#imagedatagenerator-class

Розглянемо приклад роботи з генератором даних в завданні класифікації героїв коміксів Marvel.

Проведемо імпорт необхідних модулів та функцій, включно з генератором зображень ImageDataGenerator.

```
import numpy as np
import tensorflow as tf
from tensorflow.keras import Sequential
from tensorflow.python.keras.preprocessing.image import ImageDataGen
erator
from tensorflow.keras.layers import Conv2D, Flatten, Dense, MaxPooli
ng2D, Dropout
from tensorflow.keras.regularizers import l2
from tensorflow.keras.optimizers import Adam
from keras import utils
from keras.preprocessing import image

import matplotlib.pyplot as plt
```

Оптимізуємо режим роботи відеокарти.

```
from tensorflow.compat.v1 import ConfigProto
from tensorflow.compat.v1 import InteractiveSession

config = ConfigProto()
config.gpu_options.per_process_gpu_memory_fraction = 0.9
session = InteractiveSession(config=config)

physical_devices = tf.config.list_physical_devices('GPU')
tf.config.experimental.set_memory_growth(physical_devices[0], True)
```

Задамо початкові параметри, такі як адреси папок із зображеннями та розміри зображень. Зверніть увагу, що на відміну від використання функції *image_dataset_from_directory()*, у випадку застосування генератора зображень потрібно попередньо розмістити навчальні зразки у трьох різних каталогах: дані для навчання, дані для валідації та дані для тестування. Також на цьому етапі задамо розмір батчу.

```
# Каталог з даними для навчання
train_dir = '../marvel/train'
# Каталог з даними для валідації
val_dir = '../marvel/valid'
# Каталог з даними для тестування
test_dir = '../marvel/test'
# Розміри зображення
img_width, img_height = 256, 256
# Розмірність тензору на основі зображення для подання на вхід
```

```
нейронної мережі
# backend Tensorflow, channels_last (три канали, тому що зображення
кольорове)
input_shape = (img_width, img_height, 3)
# Розмір міні-вибірки
batch_size = 32

#Назви класів
classes = ['black widow', 'captain america', 'doctor strange',
           'hulk', 'ironman', 'loki', 'spider-man', 'thanos']
```

Створюємо об'єкт-генератор зображень *ImageDataGenerator()* для навчальної вибірки. Даний об'єкт дозволить одразу під час зчитування зображень з каталогу здійснити над ними деякі перетворення. Наприклад, опція *rescale=1. / 255* виконає стандартизацію значень пікселів зображення. Інші параметри даного генератора використовуються для аугментації даних. Наприклад, задамо наступні налаштування:

- *rotation_range=15* - обертання зображення на максимум 15% від початкового положення;
- *width_shift_range=0.2* - зсув зображення по вертикалі на максимум 20% від початкового положення;
- *height_shift_range=0.2* - зсув зображення по горизонталі на максимум 20% від початкового положення;
- *zoom_range=0.2* - збільшення зображення на максимум 20%;
- *horizontal_flip=True* - віддзеркалення зображення за горизонталлю;
- *fill_mode='nearest* - режим заповнення пустих пікселів, що утворились внаслідок зсуву або обертання зображення. Значення *nearest* вказує на те, що пустіл ділянки будуть заповнені значеннями граничних пікселів початкового зображення.

```
train_datagen = ImageDataGenerator(rescale=1. / 255,
                                   rotation_range=15,
```

```
                                    width_shift_range=0.2,
                                    height_shift_range=0.2,
                                    zoom_range=0.2,
                                    horizontal_flip=True,
                                    fill_mode='nearest')
```

Аналогічним чином створимо генератор, який буде використовуватись для валідаційної та тестової множини. Однак, під час валідації або тестування аугментація не застосовується. Тому єдиним параметром генератора буде *rescale=* для стандартизації вхідних значень.

```
test_datagen = ImageDataGenerator(rescale=1. / 255)
```

Тепер створимо необхідні набори даних за допомогою методу *flow_from_directory()* генератора. В якості параметрів вказуємо адресу каталога з зображеннями, розмір зображення для його автоматичного масштабування (має відповідати формі входу нейронної мережі), розмір батчу та режим міток класів (в нашому випадку *categorical*, оскільки в завданні більше 2 класів).

```
# Генератор для зображень із папки для навчання
train_generator = train_datagen.flow_from_directory(
    train_dir,
    target_size=(img_width, img_height),
    batch_size=batch_size,
    class_mode='categorical')

# Генератори для тестової та валідаційної вибірки
val_generator = test_datagen.flow_from_directory(
    val_dir,
    target_size=(img_width, img_height),
    batch_size=batch_size,
    class_mode='categorical')


test_generator = test_datagen.flow_from_directory(
    test_dir,
    target_size=(img_width, img_height),
    batch_size=batch_size,
    class_mode='categorical')
```

```
>>

Found 1660 images belonging to 8 classes.
Found 305 images belonging to 8 classes.
Found 197 images belonging to 8 classes.
```

Створимо список із назвами класів. Для цього звернемось до параметру `class_indices`, який є словником. Ключами даного словника є назви класів, а значеннями - числові індекси (номери) класів. Оскільки нам потрібні лише назви, отримаємо перелік ключів словника та перетворимо його на список.

```
classes = list(train_generator.class_indices.keys())

print(classes)

>>

['black widow', 'captain america', 'doctor strange', 'hulk',

'ironman', 'loki', 'spider-man', 'thanos']
```

Тепер перевіримо роботу генератора навчальних зображень. Завантажимо довільне зображення із навчального каталогу (рис. 5.1).

```
image_file_name = train_dir + '/ironman/pic_001.jpg'
img = image.load_img(image_file_name, target_size=(256, 256))
plt.imshow(img)

>>
```

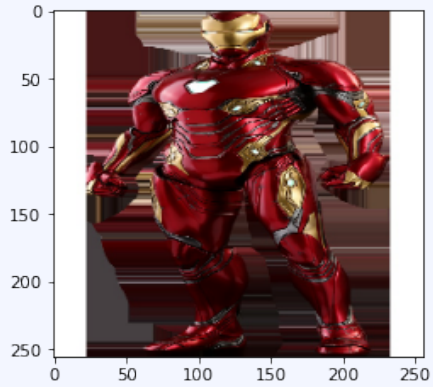

Рис. 5.1. Зображення із навчального каталогу

Тестуємо генератор. Виведемо перші 4 зображення із згенерованого батчу (рис. 5.2).

```
x = image.img_to_array(img)
x = x.reshape((1,) + x.shape)
i = 0
for batch in train_datagen.flow(x, batch_size=1):
    plt.figure(i)
    imgplot = plt.imshow(image.array_to_img(batch[0]))
    i += 1
    if i % 4 == 0:
        break
plt.show()

>>
```

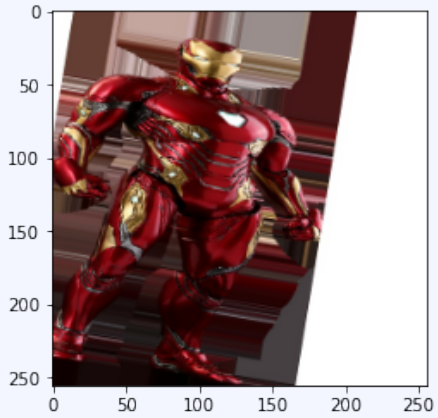

а

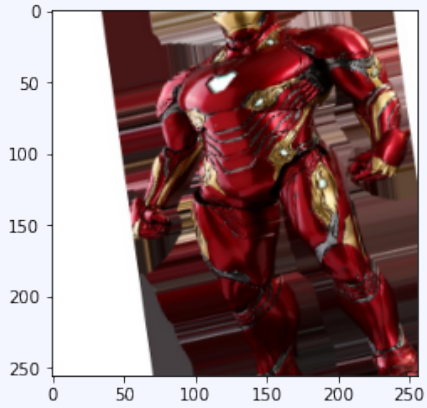

б

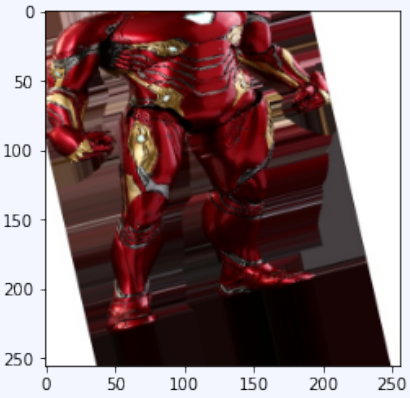

в

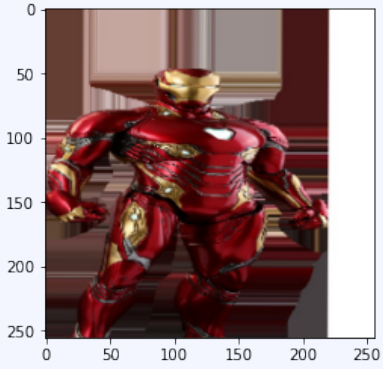

г

Рис. 5.2. Результат аугментації вхідних даних:

а – поворот зображення; б – поворот + віддзеркалювання;

в,г – поворот + зсув+zoom

Після того, як навчальні дані підготовлені, можна створити модель нейронної мережі.

```
# Створюємо послідовну модель
model = Sequential()

# Згортковий прошарок
model.add(Conv2D(32, (5, 5), padding='same',
                 input_shape=input_shape, activation='relu'))
# Прошарок підвибірки
model.add(MaxPooling2D(pool_size=(2, 2)))
model.add(Dropout(0.2))

# Згортковий прошарок
model.add(Conv2D(64, (3, 3), activation='relu', padding='same'))
# Згортковий прошарок
# Прошарок підвибірки
model.add(MaxPooling2D(pool_size=(2, 2)))
model.add(Dropout(0.2))

# Згортковий прошарок
model.add(Conv2D(128, (3, 3), activation='relu', padding='same'))
# Згортковий прошарок
# Прошарок підвибірки
model.add(MaxPooling2D(pool_size=(2, 2)))
model.add(Dropout(0.2))

# Згортковий прошарок
model.add(Conv2D(256, (3, 3), activation='relu', padding='same'))
# Прошарок підвибірки
model.add(MaxPooling2D(pool_size=(2, 2)))
model.add(Dropout(0.2))

# Повнозв'язна частина нейронної мережі для класифікації
model.add(Flatten())
model.add(Dense(512, activation='relu', kernel_regularizer='l2'))
model.add(Dropout(0.5))

# Вихідний прошарок, 8 нейронів (за кількістю класів)
model.add(Dense(8, activation="softmax"))

# Компілюємо модель. В якості оптимізатора вказуємо Adam з
модифікованим значенням швидкості навчання
model.compile(loss="categorical_crossentropy", optimizer=Adam(learni
ng_rate=1e-5), metrics=["accuracy"])
```

Навчаємо описану нейронну мережу. У методі *fit()* вказуємо наступні атрибути:

- *train_generator* - посилання на об'єкт-генератор навчальних даних;
- *steps_per_epoch = 40* - кількість батчів за одну епоху. Для обчислення необхідно кількість картинок в навчальному каталозі поділити на розмір батчу та округлити до цілого значення;
- *epochs=150* - кількість епох, визначається емпірично;
- *validation_data=val_generator* - посилання на об'єкт-генератор даних для валідації;
- *validation_steps= 10* - кількість батчів за одну валідаційну епоху. Для обчислення необхідно кількість картинок в валідайіному каталозі поділити на розмір батчу та округлити до цілого значення.

```
history = model.fit(
            train_generator,
            steps_per_epoch = 40,
            epochs=150,
            validation_data=val_generator,
            validation_steps= 10)
>>

Epoch 1/150
40/40 [==============================] - 34s 857ms/step - loss: 12.2887
- accuracy: 0.1719 - val_loss: 11.3672 - val_accuracy: 0.1705
40/40 [==============================] - 53s 1s/step - loss: 12.0474 -
accuracy: 0.1450 - val_loss: 11.8009 - val_accuracy: 0.1672
Epoch 2/150
40/40 [==============================] - 34s 857ms/step - loss: 11.6173
- accuracy: 0.1442 - val_loss: 11.3672 - val_accuracy: 0.1705
Epoch 3/150
40/40 [==============================] - 30s 750ms/step - loss: 11.1889
- accuracy: 0.1293 - val_loss: 10.9583 - val_accuracy: 0.1344
...
Epoch 148/150
40/40 [==============================] - 29s 730ms/step - loss: 1.8596
- accuracy: 0.4538 - val_loss: 1.8551 - val_accuracy: 0.4820
Epoch 149/150
40/40 [==============================] - 30s 756ms/step - loss: 1.8448
- accuracy: 0.4397 - val_loss: 1.8562 - val_accuracy: 0.4820
Epoch 150/150
```

```
40/40 [==============================] - 29s 735ms/step - loss: 1.8542
- accuracy: 0.4569 - val_loss: 1.8553 - val_accuracy: 0.4623
```

Побудуємо графік навчання (рис. 6.3).

```
plt.plot(history.history['accuracy'])
plt.plot(history.history['val_accuracy'])
plt.title('Model accuracy')
plt.ylabel('accuracy')
plt.xlabel('Epoch')
plt.legend(['Train', 'Val'], loc='upper left')
plt.show()
```

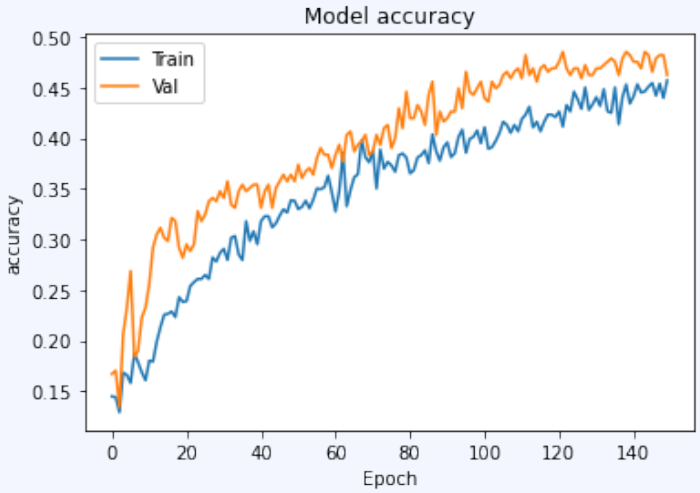

Рис. 5.3. Якість навчання для кожної епохи:

навчальна множина; валідаційна множина

Перенавчання немає. Проведемо оцінку якості роботи мережі на тестовій множині, вказавши у методі *evaluate()* посилання на генератор даних для тестування.

```
scores = model.evaluate(test_generator)
print(f"Доля правильних відповідей на тестових даних:
      {(scores[1]*100):.2f}")
>>

7/7 [==============================] - 3s 430ms/step - loss: 1.9899
- accuracy: 0.3909
Доля правильних відповідей на тестових даних: 39.09
```

Як бачимо, мережа демонструє не найкращі показники на тестовій множині. Для покращення результатів необхідно використовувати більш складну архітектуру мережі.

Застосуємо навчену мережу для розпізнавання довільного зображення. Виведемо результат (рис. 5.4).

```
from IPython.display import Image
from tkinter.filedialog import askopenfilename

# Викликаємо віконце для вибору файлу
img_path = askopenfilename()

# Імпортуємо зображення та масштабуємо його (img_path, ширина=256, в
исота=256)
img = image.load_img(img_path, target_size=(256, 256))

# Перетворюємо зображення в масив
x = image.img_to_array(img)
x = x.reshape(-1, 256, 256, 3)

# Подаємо зображення на вхід мережі для класифікації
prediction = model.predict(x)

# Визначаємо код класу
prediction = np.argmax(prediction)

# Показуємо результат
plt.figure(figsize=(4, 4))
plt.imshow(img)
plt.title(f"Назва класу: {classes[prediction]}" )
plt.axis("off")

>>
```

Рис. 5.4. Результат роботи мережі

5.2. Матриця помилок класифікації

Матриця помилок - це таблиця, яка дозволяє оцінити правльність класифікації об'єктів кожного із класів. Стовпці такої таблиці відображають класи, спрогнозовані нейронною мережею, а рядки - реальні (правильні) класи. В деяких джерелах та бібліотеках використовується обернений зміст - стовпці відображають реальні значення, рядки - відповіді мережі. На суть методу це не впливає.

Матриця помилок може бути класична або нормалізована. У класичному варіанті кожен елемент матриці відображає кількість співпадінь реальних та прогнозованих значень. У випадку нормалізованої матриці відображається доля співпадінь.

Матриця помилок будується за результатами роботи мережі на тестовій множині. В ідеальному випадку, тобто у разі безпомилкової класифікації всіх тестових зразків (accuracy = 100%), нормалізована матриця помилок набуває вигляду одиничної - всі елементи головної діагоналі будуть рівними одиниці.

Для початку створення такої матриці для нашої задачі імпортуємо необхідні бібліотеки, модулі та функції.

```
from sklearn.metrics import confusion_matrix
import pandas as pd
import seaborn as sn
```

Далі отримаємо всі правильні мітки класів для тестової множини. Оскільки в прикладі використовується генератор зображень, який є ітератором, для отримання повного списку міток необхідно пройти по всім елементам тестової множини у циклі. Потрібно пам'ятати, що мітки класів для даного прикладу закодовані в категоріальному форматі one hot encoding. Генератор зображень на кожній ітерації циклу видає батч, з якого ми будемо брати мітки класів та додавати їх до загального списку *y_test*.

```
y_test = []
for i in range( test_generator.__len__() ):
    y_test.extend(test_generator.__getitem__(i)[1])
```

Після цього отримаємо відповіді мережі на тестовій множині та створимо нормалізовану матрицю помилок класифікації.

```
y_prediction = model.predict(test_generator)

result = confusion_matrix(np.argmax(np.array(y_test), axis=1),
                          np.argmax(y_prediction, axis=1),
                          normalize='pred')
```

Щоб відобразити отриману матрицю у зручному для аналізу форматі, перетворимо її у Dataframe та виведемо на графік у вигляді теплової карти.

```
# Заготовка
df_cm = pd.DataFrame(result, classes, classes)

#Розмір картинки та шрифту
plt.figure(figsize=(10,7))
sn.set(font_scale=1.4)

# Створюємо теплову карту матриці та візуалізуємо її
matrix = sn.heatmap(df_cm, annot=True, annot_kws={"size": 16})
matrix.set(xlabel="Прогноз", ylabel="Реально")
plt.show()

>>
```

Рис. 5.5. Матриця помилок мережі

Як видно з отриманої матриці, найкраще мережа розпізнає клас *spider-man*. Водночас, 9,4% зразків даного класу мережа відносить до класу *ironman*. Найгріше розпізнається клас *thanos* - 27% зразків даного класу мережа відносить до класу ironman, в той час як правильно класифікує лише 20% зразків.

5.3. Підготовка власного набору даних

Для роботи зі згортковими нейронними мережами доводиться використовувати навчальні набори даних, які складаються з декількох тисяч зображень. Підготовка навчальних даних в такому випадку є відповідальним та затратним етапом. З метою пришвидшення цього процесу, розбиття початкового набору даних на навчальну, валідаційну та тестову множини можна автоматизувати. Розглянемо приклад, як це зробити за допомогою засобів Python.

Завдання полягає у наступному: необхідно навчити нейронну мережу розпізнавати персонажів фільмів "Зоряні війни". Початковий набір даних представлений у вигляді базового каталогу, що містить папки із зображеннями персонажів, які відносяться до різних класів. Необхідно на базі цього початкового набору сформувати навчальну, валідаційну та тестову підмножини даних. Кожна підмножина повинна складатись з основного каталогу, в якому у різних папках будуть розміщені зображення відповідних класів.

Для початку роботи, імпортуємо модулі для роботи з файловою системою.

```
import shutil
import os
```

Задамо значення необхідних змінних, долю валідаційної та тестової підмножини відносно початкового набору даних, а також імпортуємо імена класів. Пам'ятаємо, що папки в кожному головному каталозі повинні мати назву, яка відповідає конкретному класу, зображення якого розміщені всередині папки.

```
# Каталог з початковим набором даних
data_dir = '../star_wars/images'
```

```
# Каталог з даними для навчання
train_dir = '../star_wars/train'
# Каталог з даними для валідації
val_dir = '../star_wars/valid'
# Каталог з даними для тестування
test_dir = '../star_wars/test'

# Доля набору даних для валідації
val_data_portion = 0.15
# Доля набору даних для тестування
test_data_portion = 0.15

# Імпортуємо назви класів (як назви папок з початкового каталогу)
classes = os.listdir(data_dir)
```

Оголосимо функцію для створення каталогів. Дана функція створить головний каталог підмножини, а також пусті папки для кожного із класів.

```
def create_directory(dir_name):
    if os.path.exists(dir_name):
        shutil.rmtree(dir_name)
    os.makedirs(dir_name)
    for name in classes:
        os.makedirs(os.path.join(dir_name, name))
```

Використаємо написану функцію для створення каталогів для навчальної, валідаційної та тестової підмножин.

```
create_directory(train_dir)
create_directory(val_dir)
create_directory(test_dir)
```

Напишемо функцію для копіювання зображень із початкового набору даних до відповідного каталогу. Функція прийматиме наступні аргументи:

- *start_indexes* - список, який містить номери зображень, починаючи з яких потрібно виконувати копіювання (для кожного класу).
- *end_indexes* - список, який містить номери зображень, якими треба завершити копіювання (для кожного класу);
- *source_dir* - адреса початкового каталогу (з якого копіювати);

- *dest_dir* - адреса каталогу призначення (до якого копіювати).

Наприклад, у деякому початковому каталозі *source* є дві папки (два класи), які містять по 100 зображень. Потрібно сформувати валідаційну підмножину, яка буде розміщена в каталозі *destination*. В якості вибірки валідації обмеремо 15 останніх зображень із початкового набору (для кожного класу). Тоді аргументами створюваної функції *copy_images()* будуть:

copy_images(start_indexes = [74, 74], [99,99], source, destination)

Варто зазначити, що списки із початковими та кінцевими індексами будуть формуватись автоматично за допомогою функції, яку ми напишемо на наступному етапі.

```
def copy_images(start_indexes, end_indexes, source_dir, dest_dir):

    k = 0
    for name in classes:
        curr_dir = source_dir + '/' + name
        files = os.listdir(curr_dir)

        for i, file in enumerate(files):
            if start_indexes[k] <= i < end_indexes[k]:
                        shutil.copy2(os.path.join(curr_dir, file),
                                     os.path.join(dest_dir, name))
        k += 1
```

Тепер створимо функцію для формування підмножин даних. Така функція прийматиме наступні аргуметни:

- *source_dir* - адреса початкового каталогу;
- *dest_dir* - адреса каталогу призначення
- *subset* - підмножина (навчальна, валідаційна або тестова / 'train', 'val', 'test').

Всередині функції *create_dataset()* автоматично визначаються індекси початкових та кінцевих зображень (кожного класу) для кожної

підмножини, а потім викликається раніше створена функція *copy_images()* для копіювання зображені із початкового набору до відповідного каталогу вказаної підмножини.

```
def create_dataset(source_dir, dest_dir, subset):
    start_val_data_idxs = []
    start_test_data_idxs = []
    end_data_idxs = []

    if subset == 'train':
        for name in classes:
            nb_of_images = int(len(os.listdir(source_dir + '/' +
                                              name)))
            start_val_data_idxs.append(nb_of_images * (1 -
                          val_data_portion - test_data_portion))

        copy_images([0]*len(classes), start_val_data_idxs,
                     source_dir, dest_dir)

    elif subset == 'val':
        for name in classes:
            nb_of_images = int(len(os.listdir(source_dir + '/' +
                                              name)))
            start_val_data_idxs.append(int(nb_of_images * (1 -
                          val_data_portion - test_data_portion)))
            start_test_data_idxs.append(int(nb_of_images * (1 -
                                        test_data_portion)))

        copy_images(start_val_data_idxs, start_test_data_idxs,
                    source_dir, dest_dir)

    elif subset == 'test':
        for name in classes:
            nb_of_images = int(len(os.listdir(source_dir + '/' +
                                              name)))
            start_test_data_idxs.append(int(nb_of_images * (1 -
                                        test_data_portion)))
            end_data_idxs.append(nb_of_images)

        copy_images(start_test_data_idxs, end_data_idxs,
                    source_dir, dest_dir)

    else:
        print('subset має бути "train", "val" або "test"!')
```

Застосуємо функцію *create_dataset()* для створення всіх необхідних підмножин даних (навчальна, валідаційна, тестова). В результаті, будуть створені відповідні каталоги, які матимуть структуру, необхідну для подальшої роботи з нейронною мережею.

```
create_dataset(data_dir, train_dir, 'train')
create_dataset(data_dir, val_dir, 'val')
create_dataset(data_dir, test_dir, 'test')
```

5.4. Перенесення навчання

Навчання глибинних нейронних мереж може займати декілька днів і навіть тижнів. В такому випадку, у разі незадовільного результату, ціна помилки буде дуже великою. Тому що на перенавчання буде витрачено занадто багато часу. У зв'язку з цим, популярним є підхід, який називається *transfer learning* - перенесення навчання. Він полягає в тому, що вже колись навчена нейронна мережа з відомою архітектурою використовується для вирішення нових задач, тобто не тих, для яких вона навчалась. Це досягається завдяки наступним крокам:

- Імпортується навчена мережа з відомою архітектурою.
- З мережі видаляються останні прошарки, які відповадають за класифікацію (так звана "вершина" (top, head) мережі).
- Замість видалених прошарків створюються нові. Архітектура цих нових прошарків має відповідати новій задачі, яку повинна буде вирішувати нейронна мережа.

Чому це працює? Справа в тому, що навчена нейронна мережа вже вміє якісно виділяти значущі ознаки із зображення. Тобто немає сенсу знову навчати її знаходити аналоги ознак Хаара - мережа і так вміє це робити, оскільки всі значення синаптичних ваг згорткових прошарків були встановлені під час попереднього навчання. Єдине, що залишається, це навчити мережу правильно класифікувати об'єкти за тим набором ознак, які

вона виділить із зображення. Таким чином, у разі використання *transfer learning* навчається лише та частина мережі, яка відповідає за класифікацію. Це дозволяє значно пришвидшити навчання, а також покращити його якість (оскільки показники ефективності роботи мережі відомі заздалегідь).

Застосуємо підхід *transfer learning* для навчання нейронної мережі для класифікації персонажів фільмів "Зоряні війни". В якості попередньо навченої мережі імпортуємо мережу VGG16 з набором синаптичних ваг, отриманих в результаті навчання на наборі даних *ImageNet*. Цей набір містить 1000 різних класів об'єктів, і мережа VGG16 вже вміє проводити їх класифікацію з високою достовірністю. Але в даній задачі ми будемо застосовувати мережу VGG16 для класифікації всього лише 8 типів об'єктів. Більше того, дані об'єкти не зустрічались мережі під час попереднього навчання. Тому прошарки мережі, які відповідають за класифікацію, потрібно буде відкинути, і замість них створити та навчити свої власні.

Для початку, імпортуємо необхідні модулі (серед яких і сама мережа VGG16).

```
import os
import numpy as np
import tensorflow as tf
from tensorflow.keras.preprocessing.image import ImageDataGenerator
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Activation, Dropout, Flatten, De
nse
from tensorflow.keras.optimizers import Adam
from keras.preprocessing import image

from tensorflow.keras.applications import VGG16

import matplotlib.pyplot as plt
```

Задамо оптимальні параметри роботи відеокарти.

```
from tensorflow.compat.v1 import ConfigProto
from tensorflow.compat.v1 import InteractiveSession

config = ConfigProto()
```

```
config.gpu_options.per_process_gpu_memory_fraction = 0.6
session = InteractiveSession(config=config)

physical_devices = tf.config.list_physical_devices('GPU')
tf.config.experimental.set_memory_growth(physical_devices[0], True)
```

Вкажемо початкові налаштування.

```
# Каталог з даними для навчання
train_dir = '../star_wars/train'
# Каталог з даними для валідації
val_dir = '../star_wars/valid'
# Каталог з даними для тестування
test_dir = '../star_wars/test'

# Назви класів
classes = os.listdir(train_dir)

# Розміри зображення
img_width, img_height = 150, 150
# Розмірність тензора вхідного зображення для входу нейронної мережі
input_shape = (img_width, img_height, 3)
# Розмір батчу
batch_size = 32
```

Створимо об'єкт мережі VGG16 з наступними параметрами:

- *weights='imagenet'* - набір попередньо навчених ваг: ImageNet
- *include_top=False* - не завантажувати частину мережі, призначену для класифікації
- *input_shape=input_shape* - форма вхідного зображення (в нашому випадку - (150, 150, 3)).

```
vgg16_net = VGG16(weights='imagenet', include_top=False,
                  input_shape=input_shape)
```

Заборонимо навчання всіх завантажених прошарків мережі VGG16, встановивши значення атрибуту *vgg16_net.trainable = False*. Після цього переглянемо зведену інформацію щодо мережі і переконаємось, що кількість

внутрішніх параметрів, доступних для навчання, дорівнює нулю (*Trainable params: 0*).

```
vgg16_net.trainable = False
vgg16_net.summary()

>>

Model: "vgg16"
_________________________________________________________________
Layer (type)                 Output Shape              Param #
=================================================================
input_1 (InputLayer)         [(None, 150, 150, 3)]     0
_________________________________________________________________
block1_conv1 (Conv2D)        (None, 150, 150, 64)      1792
_________________________________________________________________
block1_conv2 (Conv2D)        (None, 150, 150, 64)      36928
_________________________________________________________________
block1_pool (MaxPooling2D)   (None, 75, 75, 64)        0
_________________________________________________________________
block2_conv1 (Conv2D)        (None, 75, 75, 128)       73856
_________________________________________________________________
block2_conv2 (Conv2D)        (None, 75, 75, 128)       147584
_________________________________________________________________
block2_pool (MaxPooling2D)   (None, 37, 37, 128)       0
_________________________________________________________________
block3_conv1 (Conv2D)        (None, 37, 37, 256)       295168
_________________________________________________________________
block3_conv2 (Conv2D)        (None, 37, 37, 256)       590080
_________________________________________________________________
block3_conv3 (Conv2D)        (None, 37, 37, 256)       590080
_________________________________________________________________
block3_pool (MaxPooling2D)   (None, 18, 18, 256)       0
_________________________________________________________________
block4_conv1 (Conv2D)        (None, 18, 18, 512)       1180160
_________________________________________________________________
block4_conv2 (Conv2D)        (None, 18, 18, 512)       2359808
_________________________________________________________________
block4_conv3 (Conv2D)        (None, 18, 18, 512)       2359808
_________________________________________________________________
block4_pool (MaxPooling2D)   (None, 9, 9, 512)         0
_________________________________________________________________
block5_conv1 (Conv2D)        (None, 9, 9, 512)         2359808
_________________________________________________________________
block5_conv2 (Conv2D)        (None, 9, 9, 512)         2359808
_________________________________________________________________
block5_conv3 (Conv2D)        (None, 9, 9, 512)         2359808
_________________________________________________________________
```

```
block5_pool (MaxPooling2D)   (None, 4, 4, 512)         0
=================================================================
Total params: 14,714,688
Trainable params: 0
Non-trainable params: 14,714,688
_________________________________________________________________
```

Створюємо власну нейронну мережу, яка буде складатись з завантаженої частини навченої VGG16 та власного класифікатора.

```
model = Sequential()
# Додаємо до моделі мережу VGG16 замість прошарку
model.add(vgg16_net)

# Додаємо до моделі власний класифікатор
model.add(Flatten())
model.add(Dense(256, activation='relu'))
model.add(Dropout(0.2))
model.add(Dense(len(classes), activation='softmax'))
```

Переглянемо інформацію про створену мережу. Як можна побачити, під час навчання доведеться знайти значення лише 2,098,693 параметрів, тоді як загалом наша модель містить 16,813,381 внутрішніх параметрів. Але з них 14,714,688 параметрів вже були попередньо навчені, їх не потрібно модифіковувати (що ми і заборонили робити на попередніх етапах). Це значно пришвидшить процес навчання.

```
model.summary()

>>


Model: "sequential"
_________________________________________________________________
Layer (type)                 Output Shape              Param #
=================================================================
vgg16 (Functional)           (None, 4, 4, 512)         14714688
_________________________________________________________________
flatten (Flatten)            (None, 8192)              0
```

```
_________________________________________________________________
dense (Dense)                (None, 256)               2097408
_________________________________________________________________
dropout (Dropout)            (None, 256)               0
_________________________________________________________________
dense_1 (Dense)              (None, 5)                 1285
=================================================================
Total params: 16,813,381
Trainable params: 2,098,693
Non-trainable params: 14,714,688
_________________________________________________________________
```

Компілюємо модель. Оскільки додана частина мережі VGG16 вже була попередньо навчена і вміє гарно виявляти ознаки, необхідно знизити швидкість навчання *learning_rate*. Це зроблено для того, щоб оптимізатор не пропустив мінімум функції втрат.

```
model.compile(loss='categorical_crossentropy',
              optimizer=Adam(learning_rate=1e-5),
              metrics=['accuracy'])
```

Створюємо об'єкт-генератор зображень *ImageDataGenerator()* для автоматичної стандартизації значень пікселів під час імпорту картинки з каталогу.

```
datagen = ImageDataGenerator(rescale=1. / 255)
```

Створюємо та налаштовуємо генератори для навчальної, валідаційної та тестової підмножин.

```
train_generator = datagen.flow_from_directory(
    train_dir, target_size=(img_width, img_height),
    batch_size=batch_size,
    class_mode='categorical')

>>

Found 892 images belonging to 5 classes.
```

```
val_generator = datagen.flow_from_directory(
    val_dir, target_size=(img_width, img_height),
    batch_size=batch_size,
    class_mode='categorical')

>>

Found 189 images belonging to 5 classes.
```

```
test_generator = datagen.flow_from_directory(
    test_dir, target_size=(img_width, img_height),
    batch_size=batch_size,
    class_mode='categorical')

>>

Found 192 images belonging to 5 classes.
```

Запам'ятовуємо кількість зображень у навчальній та валідаційній мережі (знадобиться для коректного визначення кількості крок за епоху навчання).

```
nb_train_samples = 892
nb_validation_samples = 189
```

Навчаємо модель.

```
history = model.fit(
            train_generator,
            steps_per_epoch=nb_train_samples // batch_size,
            epochs=15, validation_data=val_generator,
            validation_steps=nb_validation_samples // batch_size)

>>

Epoch 1/15
27/27 [==============================] - 14s 516ms/step - loss: 1.6738
- accuracy: 0.2616 - val_loss: 1.4439 - val_accuracy: 0.4187
Epoch 2/15
27/27 [==============================] - 4s 136ms/step - loss: 1.4253
- accuracy: 0.4151 - val_loss: 1.2821 - val_accuracy: 0.5938
Epoch 3/15
27/27 [==============================] - 4s 136ms/step - loss: 1.2727
- accuracy: 0.5093 - val_loss: 1.1702 - val_accuracy: 0.6625
...

Epoch 13/15
27/27 [==============================] - 4s 138ms/step - loss: 0.5298
```

```
- accuracy: 0.8640 - val_loss: 0.6196 - val_accuracy: 0.8000
Epoch 14/15
27/27 [==============================] - 4s 139ms/step - loss: 0.4950
- accuracy: 0.8767 - val_loss: 0.6192 - val_accuracy: 0.8250
Epoch 15/15
27/27 [==============================] - 4s 136ms/step - loss: 0.4675
- accuracy: 0.8907 - val_loss: 0.5932 - val_accuracy: 0.8188
```

Перевіряємо модель на тестових даних.

```
scores = model.evaluate(test_generator)
print(f"Accuracy на тестових даних: {(scores[1]*100):.2f}")

>>

6/6 [==============================] - 2s 368ms/step - loss: 0.6725
- accuracy: 0.7812
Accuracy на тестових даних: 78.12
```

Отже, завдяки застосуванню підходу *transfer learning*, нам вдалось навчити нейронну мережу вирішувати нову задачу з високою ефективністю всього лише за 10-15 епох навчання. Але навіть цей результат не є найкращим. Для його покращення можна застосувати додатковий підхід, який має назву *fine tuning*.

5.5. Тонкі налаштування мережі

Під час використання *transfer learning* виокристовується попередньо навчена нейронна мережа, в якій замінено прошарки, що відповідають за класифікацію. Прошарки для виділення ознак на зображеннях залишаються і "заморожуються" під час навчання. Тобто синаптичні ваги цих прошарків не змінюються, оскільки вони не доступні для навчання. Однак, якщо нове завдання значно відрізняється від того, на якому була попередньо навчена нейронна мережа, деякі з останніх прошарків для виділення ознак можна активувати для навчання. Чим сильніша різниця між попередньою та новою задачею, тим більше останніх прошарків для виділення ознак рекомендується

зробити доступними для навчання. Такий підхід називається тонким налаштуванням мережі, або *fine tuning*.

Застосуємо *fine tuning* для покращення якості мережі, отриманої у попередньому прикладі. Для цього дозволимо навчання останнього згорткового прошарку мережі VGG16, який називається *'block5_conv3'*. Навчання всіх інших прошарків залишаємо забороненим.

```
# Активуємо для навчання всю мережу
vgg16_net.trainable = True
# Перебираємо в циклі прошарки та вимикаємо навчання для всіх прошар
ків, окрім потрібного
trainable = False
for layer in vgg16_net.layers:
    if layer.name == 'block5_conv3':
        trainable = True
    layer.trainable = trainable
```

Перевіряємо кількість параметрів, доступних для навчання. Бачимо, що у порівнянні з попереднім варіантом, їх кількість збільшилась, оскільки прошарок *'block5_conv3'* тепер доступний для навчання.

```
model.summary()

>>

Model: "sequential"
_________________________________________________________________
Layer (type)                 Output Shape              Param #
=================================================================
vgg16 (Functional)           (None, 4, 4, 512)         14714688
_________________________________________________________________
flatten (Flatten)            (None, 8192)              0
_________________________________________________________________
dense (Dense)                (None, 256)               2097408
_________________________________________________________________
dropout (Dropout)            (None, 256)               0
_________________________________________________________________
dense_1 (Dense)              (None, 5)                 1285
=================================================================
Total params: 16,813,381
Trainable params: 4,458,501
```

```
Non-trainable params: 12,354,880
_________________________________________________________________
```

Заново компілюємо модифіковану модель.

```
model.compile(loss='categorical_crossentropy',
              optimizer=Adam(lr=1e-5),
              metrics=['accuracy'])
```

Навчаємо модифіковану модель.

```
history = model.fit(
            train_generator,
            steps_per_epoch=nb_train_samples // batch_size,
            epochs=15,
            validation_data=val_generator,
            validation_steps=nb_validation_samples // batch_size)

Epoch 1/15
27/27 [==============================] - 4s 151ms/step - loss: 0.4377
- accuracy: 0.8837 - val_loss: 0.5352 - val_accuracy: 0.8375
Epoch 2/15
27/27 [==============================] - 4s 139ms/step - loss: 0.3370
- accuracy: 0.9244 - val_loss: 0.4848 - val_accuracy: 0.8562
Epoch 3/15
27/27 [==============================] - 4s 141ms/step - loss: 0.2874
- accuracy: 0.9384 - val_loss: 0.4906 - val_accuracy: 0.8250
...

Epoch 13/15
27/27 [==============================] - 4s 142ms/step - loss: 0.0627
- accuracy: 0.9977 - val_loss: 0.3981 - val_accuracy: 0.8438
Epoch 14/15
27/27 [==============================] - 4s 141ms/step - loss: 0.0570
- accuracy: 0.9988 - val_loss: 0.3639 - val_accuracy: 0.8500
Epoch 15/15
27/27 [==============================] - 4s 145ms/step - loss: 0.0461
- accuracy: 0.9988 - val_loss: 0.3927 - val_accuracy: 0.8687
```

Перевіряємо якість мережі на тестовій підмножині.

```
scores = model.evaluate(test_generator)
print(f"Accuracy на тестових даних: {(scores[1]*100):.2f}")

>>
```

```
6/6 [==============================] - 1s 100ms/step - loss: 0.4672
- accuracy: 0.8594
Accuracy на тестових даних: 85.94
```

Як видно з результатів, використання *fine tuning* дозволило покращити якість роботи мережі на тестових даних майже на 9% у порівнянні з попереднім варіантом, коли навчався лише класифікатор. Аналогічним чином можна розблокувати для навчання і інші частини (прошарки) початкової мережі, до якої застосовується *transfer learning*. Кількість доступних для навчання прошарків залежить від конкретних задач.

Використаємо навчену нейронну мережу для розпізнавання зображення, яке імпортується з жорсткого диску ПК. Виведемо результат (рис. 5.6).

```
from IPython.display import Image
from tkinter.filedialog import askopenfilename

img_path = askopenfilename()

img = image.load_img(img_path, target_size=(img_width, img_height))

x = image.img_to_array(img)
x = x.reshape(-1, img_width, img_height, 3)

prediction = model.predict(x)
prediction = np.argmax(prediction)

plt.figure(figsize=(4, 4))
plt.imshow(img)
plt.title(f"Назва класу: {classes[prediction]}" )
plt.axis("off")

>>
```

Рис. 5.6. Результат роботи мережі

5.6. Завдання для самостійного виконання

Загальні завдання для всіх варіантів:

1. Створіть власний унікальний набір навчальних зображень для згорткової нейронної мережі. Набір має містити зображення як мінімум трьох різних класів об’єктів. Всі зображення в наборі мають бути розподілені на три підмножини – навчальну, валідаційну та тестову. Підмножини мають розміщуватись у окремих папках. Використовувати готові набори з попередніх робіт, які додаються до посібника (включно з усіма варіантами) – заборонено!
2. Завантажте створений набір даних за допомогою генератора. Сформуйте навчальну, валідаційну і тестову множини. Самостійно визначте оптимальний розмір зображень та розмір батчу. Під час формування навчальної множини використайте одну або декілька доступних опцій генератора для аугментації даних.
3. Перевірте роботу генератора на довільному одному зображенні.
4. Використовуючи підхід transfer learning, створіть та навчіть згорткову нейронну мережу на базі архітектури VGG-16 для розпізнавання класів об’єктів на зображеннях. Побудуйте графік навчання.
5. Проведіть оцінку якості роботи навченої мережі на тестових даних.
6. Застосуйте навчену мережу для класифікації довільних зображень, які імпортуються в програму з жорсткого диску ПК.
7. Спробуйте максимально покращити якість створеної нейронної мережі, використавши тонкі налаштування (fine tuning).

ПРАКТИКУМ 6. ДЕТЕКТУВАННЯ ОБ'ЄКТІВ НА ЗОБРАЖЕННЯХ

6.1. Загальні відомості

YOLO (You Only Look Once) — це сімейство глибоких згорткових нейронних мереж, розроблене для задач детектування об'єктів на зображеннях у реальному часі. Основна ідея YOLO полягає в тому, що мережа аналізує зображення лише один раз, розбиваючи його на сітку і передбачаючи прямокутні області (bounding boxes) та ймовірності приналежності об'єктів до певного класу для кожної клітинки цієї сітки. Завдяки цьому підходу YOLO демонструє дуже високу швидкість обробки, що робить її придатною для застосувань, де важлива швидкодія — таких як відеоспостереження, автономні транспортні засоби та робототехніка.

Перші версії YOLO, починаючи з YOLOv1, зробили акцент на об'єднанні задач локалізації та класифікації в єдину модель. З кожною новою версією модель ставала дедалі точнішою, складнішою та ефективнішою. Наприклад, YOLOv3 і YOLOv4 значно підвищили якість детектування за рахунок використання багаторівневих пірамід ознак (feature pyramids) та вдосконаленої архітектури з пропускними з'єднаннями (residual nets). У YOLOv5 вперше з'явилася модульна реалізація на PyTorch, що зробило модель особливо зручною для розробників. Вона також запровадила легші версії моделей (наприклад, YOLOv5n, YOLOv5s), які дозволяють використовувати їх на пристроях з обмеженою обчислювальною потужністю.

Згодом з'явилися YOLOv6, YOLOv7 і YOLOv8, які продовжили розвивати архітектуру, вводячи нові типи прошарків, функції активації та методи оптимізації. YOLOv8 стала повністю фреймворк-незалежною моделлю з підтримкою не лише детектування, а й сегментації, класифікації та

трекінгу. Вона була розроблена командою Ultralytics як повністю переписана з нуля архітектура з акцентом на гнучкість і універсальність.

YOLOv11 — це найновіша на сьогодні модель у цій лінійці, представлена також командою Ultralytics. Вона є подальшим розвитком ідеї YOLOv8, з глибшими оптимізаціями архітектури та вдосконаленням механізмів поширення ознак по мережі. YOLOv11 використовує оновлені блоки згорток, зокрема варіанти RepConv та GhostConv другого покоління, які дозволяють досягати кращого балансу між точністю і швидкістю. Ця модель була створена з урахуванням можливості легкої адаптації як для хмарних середовищ із потужними графічними процесорами, так і для вбудованих систем. Під час навчання YOLOv11 використовує ефективні стратегії оптимізації та функції втрат, які допомагають краще адаптувати модель до особливостей конкретного датасету.

Найважливішою перевагою YOLOv11 є її гнучкість і практичність: модель можна швидко натренувати на власному наборі даних навіть без глибоких знань у сфері машинного навчання, завдяки інтеграції з платформами на кшталт Roboflow, а також простій структурі налаштувань. Крім того, YOLOv11 підтримує різні формати експорту, включно з ONNX, TFLite, CoreML та TorchScript, що дозволяє легко використовувати модель на мобільних пристроях, у браузерах або на edge-пристроях. У підсумку, YOLOv11 є потужним інструментом як для дослідників, так і для розробників практичних застосувань в області комп’ютерного зору.

Опис набору даних

Набір даних Vehicles доступний у Roboflow Universe як частина ініціативи Roboflow 100 (RF100), створеної за підтримки Intel. У його складі міститься приблизно 4 058 зображень транспортних засобів, анотації до яких зберігаються у різних форматах, включно з форматом YOLOv11 з YAML-конфігурацією, що робить дані сумісними з сучасними моделями Ultralytics.

Картинки мають розмір 640×640 пікселів, дані заздалегідь приведені до цього розміру без застосування агментацій під час створення набору.

Структура набору включає розподіл на навчальну, валідаційну та тестову множини: ≈ 65 % зображень у навчальній множині, ≈ 24 % у валідаційній та решта у тестовій. Загалом до набору входить 12 класів транспортних засобів.

Для початку встановимо необхідні бібліотеки:

```
# Встановлюємо бібліотеку Ultralytics
!pip install ultralytics --upgrade --quiet
!pip install roboflow --quiet
```

Далі імпортуємо необхідні модулі:

```
from roboflow import Roboflow
from ultralytics import YOLO
```

Завантажимо набір даних:

```
rf = Roboflow(api_key="ВАШ_КЛЮЧ_API")
project = rf.workspace("roboflow-100").project("vehicles-q0x2v")
version = project.version(2)
dataset = version.download("yolov11")

>>

loading Roboflow workspace...
loading Roboflow project...
```

Після виконання попереднього коду було створено YAML-файл і структуру набору даних на диску. Далі необхідно завантажити попередньо навчену модель YOLOv11. Використання "n" моделі дозволяє почати з мінімальними обчислювальними витратами.

```
model = YOLO("yolo11n.pt")
```

Проведемо навчання моделі. Після навчання модель і логи будуть збережені в */content/yolo11*.

```
model.train(

    # шлях до YAML-файлу з Roboflow
    data=dataset.location + "/data.yaml",
    val=True,                    # проводити валідацію моделі
    epochs=100,                  # кількість епох
    imgsz=640,                   # розмір зображення
    batch=16,                    # розмір батчу
    name="yolov11n_example",     # ім'я моделі
    project="/content/yolo11",   # папка для збереження результатів
)

>>

Ultralytics 8.3.174 🚀 Python-3.11.13 torch-2.6.0+cu124 CUDA:0 (Tes
la T4, 15095MiB)
...

Validating /content/yolo11/yolov11n_example2/weights/best.pt...
Ultralytics 8.3.174 🚀 Python-3.11.13 torch-2.6.0+cu124 CUDA:0 (Tes
la T4, 15095MiB)
YOLO11n summary (fused): 100 layers, 2,584,492 parameters, 0 gradien
ts, 6.3 GFLOPs

Class     Images  Instances   Box(P      R         mAP50  mAP50-95):

all        966     13450      0.502      0.611      0.463      0.328
big bus    210       273      0.827      0.414      0.695      0.522
big truck  404      1162      0.803      0.537      0.675
bus-l-       8         8     0.0607          1     0.0632     0.0299
bus-s-      12        12       0.21      0.833      0.402      0.327
car        927      8537      0.855      0.712      0.824      0.508
mid truck  118       257      0.683      0.412      0.433      0.327
small bus   43        49      0.204      0.224      0.109     0.0639
small truck 517     1721      0.696      0.529      0.616      0.402
truck-l-   266       433      0.501      0.688      0.478      0.354
truck-m-   331       629      0.426      0.695      0.412      0.318
truck-s-   147       221      0.294      0.543      0.238      0.159
truck-xl-  110       148      0.469      0.745      0.606      0.481
Speed: 0.2ms preprocess, 2.0ms inference, 0.0ms loss, 2.3ms postproc
ess per image
Results saved to /content/yolo11/yolov11n_example
```

Проведемо оцінку продуктивності моделі за метриками mAP, Precision, Recall на тестовій множині:

```
metrics = model.val(split='test')
print(metrics)
```

```
>>

Ultralytics 8.3.174 🚀 Python-3.11.13 torch-2.6.0+cu124 CUDA:0 (Tes
la T4, 15095MiB)
val: Fast image access ☑ (ping: 0.0±0.0 ms, read: 1291.2±179.3 MB/
s, size: 48.1 KB)

val: Scanning /content/vehicles-2/test/labels... 458 images, 4 backg
rounds, 0 corrupt: 100%|| 458/458 [00:00<00:00, 2118.98it/s]

Class     Images  Instances   Box(P      R      mAP50     mAP50-95):

all       458       6222      0.512       0.57      0.429      0.293
big bus    82        110      0.822      0.418      0.652      0.452
big truck 240        648      0.771      0.484      0.597       0.38
bus-s-     15         16       0.32        0.5      0.323      0.255
car       445       4021      0.843      0.672      0.776      0.454
mid truck  43         87      0.763      0.402      0.442      0.337
small bus  21         23      0.222      0.261      0.127     0.0669
small truck 255      827      0.673      0.463      0.529      0.334
truck-l-   84        144      0.375      0.611      0.392      0.285
truck-m-  118        283      0.443      0.707      0.441      0.257
truck-s-   19         31      0.136      0.871      0.172      0.129
truck-xl-  29         32       0.26      0.875      0.266      0.199
Speed: 0.9ms preprocess, 3.5ms inference, 0.0ms loss, 1.6ms postproc
ess per image
Results saved to /content/yolo11/yolov11n_example23
```

Тестуємо модель на конкретному зображенні для перевірки якості візуально.

```
import matplotlib.pyplot as plt

# Шлях до зобреження (візьмемо з тестової множини)
img_path = "/content/vehicles-2/test/images/adit_mp4-1171_jpg.rf.299
a223513bab3b60a776cba834a6a82.jpg"
# Виконання детектування без збереження на диск
results = model(img_path, save=False)
# Отримання зображення з нанесеними передбаченнями (у форматі NumPy
array)
rendered_img = results[0].plot()
# Відображення
plt.imshow(rendered_img)
plt.axis("off")
plt.show()

>>
```

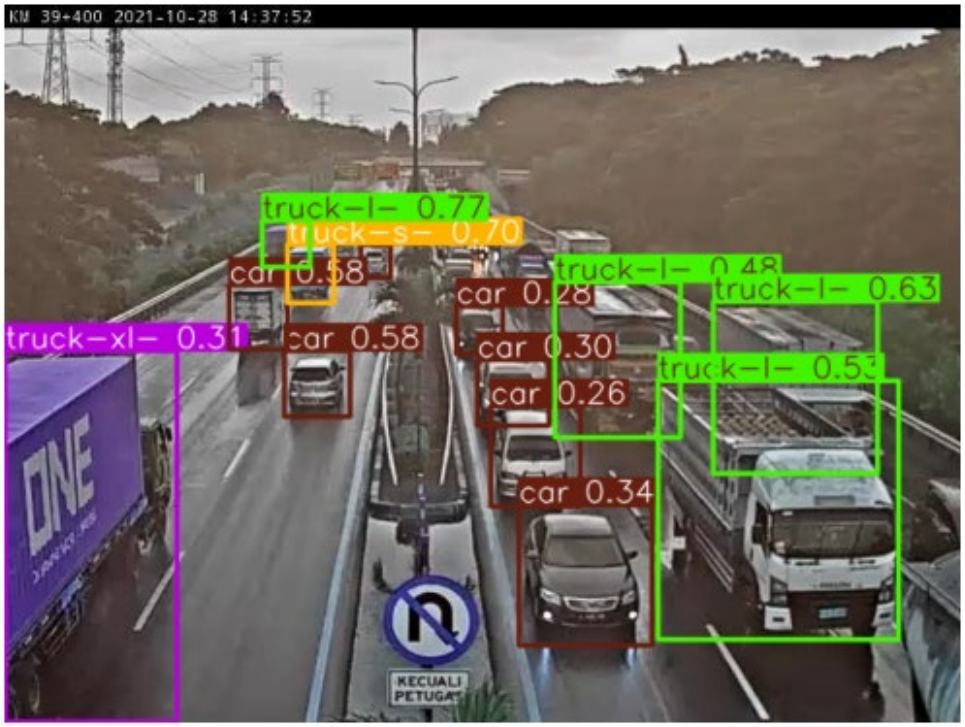

Рис. 6.1. Результат роботи мережі

6.2. Завдання для самостійного виконання

Загальні завдання для всіх варіантів:

1. Завантажте набір даних із використанням доступу до середовища Roboflow через API-ключ.
2. Створіть модель YOLOv11 довільної модифікації (використовуйте модель “n” для найшвидшого навчання).
3. Проведіть навчання і валідацію створеної моделі. Проаналізуйте отримані графіки навчання та матриці помилок.
4. Проведіть оцінку якості роботи навченої мережі на тестових даних.
5. Застосуйте навчену мережу для детектування об’єктів на довільних власних зображеннях.

Варіант 1

Набір даних: гроші (currency).

Опис даних: В наборі містяться зображення 10 різних видів грошей. Необхідно навчити нейронну мережу детектувати їх на зображенні.

Варіант 2

Набір даних: дорожні знаки (road signs).

Опис даних: В наборі містяться зображення 21 виду дорожних знаків. Необхідно навчити нейронну мережу детектувати їх на зображенні.

Варіант 3

Набір даних: друковані плати (printed circuit board).

Опис даних: В наборі містяться зображення 31 виду електронних компонентів. Необхідно навчити нейронну мережу детектувати їх на зображенні.

Варіант 4

Набір даних: CSGO.

Опис даних: В наборі містяться зображення двох видів персонажів з гри «*CSGO*». Необхідно навчити нейронну мережу детектувати їх на зображенні.

Варіант 5

Набір даних: гральні карти (poker cards).

Опис даних: В наборі містяться зображення 53 видів гральних карт. Необхідно навчити нейронну мережу детектувати їх на зображенні.

Варіант 6

Набір даних:рентгенографія (x-ray rheumatology).

Опис даних: В наборі містяться зображення 12 видів ревматологічних об'єктів. Необхідно навчити нейронну мережу детектувати їх на зображенні.

Варіант 7

Набір даних: МРТ (axial MRI).

Опис даних: В наборі містяться зображення МРТ-знімків мозку. Необхідно навчити нейронну мережу детектувати аномалії у них.

Варіант 8

Набір даних: термографія (thermal dogs and people).

Опис даних: В наборі містяться термографічні зображення людей та собак. Необхідно навчити нейронну мережу детектувати їх на зображенні.

Варіант 9

Набір даних: бур'яни (weed crop aerial).

Опис даних: В наборі містяться зображення рослин та бур'янів. Необхідно навчити нейронну мережу розрізняти та детектувати їх на зображенні.

Варіант 10

Набір даних: принипові електричні схеми (circuit voltages).

Опис даних: В наборі містяться зображення 6 видів джерел енергії на електричних принципових схемах. Необхідно навчити нейронну мережу детектувати їх на зображенні.

Варіант 11

Набір даних: меблі (furniture).

Опис даних: В наборі містяться зображення 3 видів меблів. Необхідно навчити нейронну мережу детектувати їх на зображенні.

Варіант 12

Набір даних: тварини (animals).

Опис даних: В наборі містяться зображення 10 видів тварин. Необхідно навчити нейронну мережу детектувати їх на зображенні.

Список рекомендованої літератури

1. Chollet F. Deep Learning with Python, Second Edition / Chollet., 2021. – 504 p.
2. Технології штучного інтелекту та основи машинного зору в автоматизації: теорія і практика: підручник для здобувачів ступеня магістра за спеціальністю 151 "Автоматизація та комп'ютерно-інтегровані технології" / А. І.Жученко, І. Ю. Черепанська, А. Ю. Сазонов, Д. О. Ковалюк. – Київ : КПІ ім. Ігоря Сікорського, 2019. – 386 с.
3. Trask A. Grokking Deep Learning / A. Trask..– Manning Publications, 2019. – 335 p.
4. Burkov A. The Hundred-Page Machine Learning Book / A. Burkov., 2019. – 160 p.
5. Системи штучного інтелекту: навч. посіб. / Н. Б. Шаховська, Р. М. Камінський, О. Б. Вовк; Нац. ун-т "Львів. політехніка". – Львів : Вид-во Львів. політехніки, 2018. – 391 с.
6. Patterson J. Deep Learning / J. Patterson, A. Gibson., 2017. – 530 p.
7. Raschka S. Python Machine Learning: Machine Learning and Deep Learning with Python, scikit-learn, and TensorFlow 2, 3rd Edition 3rd Edition / S. Raschka, V. Mirjalili., 2019. – 770 p.
8. Haykin S. Neural Networks and Learning Machines (3rd Edition) / Haykin., 2016. – 944 p.
9. Goodfellow I. Deep Learning (Adaptive Computation and Machine Learning series) / I. Goodfellow, Y. Bengio, A. Courville., 2016. – 800 p.
10. Rosebrock A. Deep Learning for Computer Vision with Python. Practitioner Bundle / A. Rosebrock., 2017. – 210 p.
11. Schmidhuber, J. Deep Learning in Neural Networks: An Overview // Neural Networks. – 2015. – Vol. 61. – P. 85–117.
12. Weidman S. Deep Learning from Scratch: Building with Python from First Principles / Weidman., 2019. – 252 p.